具身智能机器人研究地图

通往通用性的七条路线、科学问题与 2026 前沿

具身智能机器人领域科研专家 · 研究综述

2026 年 10 月 23 日

Contents

摘要 2

一页纸：十个判断 3

阅读指南 4

1 领域界定、通用性定义与方法 5

2 研究地图总览 12

3 历史演进：从编程机器到具身基础模型 16

4 通用性的七个来源 21

5 七条路线与横切底座 25

6 科学问题树：从总目标到可检验子问题 34

7 路线比较与系统集成 41

8 2024—2026 最新进展 47

9 瓶颈深水区 56

10 未来 3—5 年：研究议程与选题建议 62

11 结论 66

附录 A 核心综述精读卡片 67

附录 B 关键系统与基准速查 70

附录 C 术语表 72

附录 D 近一年中文科技媒体机器人智能体报道索引 73

附录 E 参考文献 74

摘要

具身智能机器人研究正在经历一次罕见的结构性变化：一方面，视觉—语言—动作（VLA）模型、世界模型和人形机器人把 “通用机器人” 从长期愿景推到了可工程化的议程上；另一方面，真实部署中的可靠性、数据成本、跨本体迁移、长程任务、安全与评测问题，又以非常具体的方式暴露出当前路线的边界。

本报告以 “机器人通用性” 为最终目标，梳理 1960—2026 年间该领域的研究路线、发展过程、科学问题与最新进展。方法上，报告以 20 余篇高影响综述的全文/结构化阅读为骨架，以 30 余项代表性系统与基准的原始论文为事实锚点，并对 2024—2026 年的预印本、官方报告和产业部署证据做证据分级。报告不试图穷举文献，而是回答四个问题：

1. 领域走过哪些阶段，每次范式迁移由什么问题驱动？
2. 科研人员为通往通用性探索了哪些路径，每条路径的 “通用性假设” 是什么？
3. 各路径遇到哪些瓶颈，科学问题如何细化为子目标、子任务和可检验指标？
4. 2024—2026 年出现了哪些真正改变研究重心的事情，下一步最值得攻什么？

报告的核心判断是：**通用性不是某一个模型的属性，而是一个 “数据—表征—技能—推理—本体—评测” 系统的属性**。当前领域已经形成了以 VLA/基础模型为主干、以真实机器人数据为燃料、以仿真和世界模型为加速器、以分层控制和安全壳为可靠性保障的 “系统栈”。单点模型规模继续扩大仍然重要，但边际收益正在从 “模型能力” 转向 “数据质量、跨本体接口、部署中学习、评测有效性和安全验证”。

2026 年的新信号进一步支持这一判断：以 GEN-1.5、Skild S1、RoboTTT 为代表的 “物理提示/上下文学习” 正在把任务接口从语言扩展到视频演示；以高德 ABot 为代表的全栈系统把数据/世界模型、导航、执行、Agent、推理放在同一个体系里；以 VLA-JEPA、ABot-PhysWorld、ABot-M0.5 为代表的世界—动作模型则把 “预测” 与 “控制” 进一步耦合。本版新增 8.10 节与附录 D，对这批 “媒体热度—论文证据” 做交叉核对。

报告提出 “通用性的七个来源”：物理模型、交互经验、人类示范、语义先验、预测想象、身体形态、组合架构；并以数据与评测作为跨层 “元来源”。围绕这七个来源，报告给出七条路线的技术谱系、有效边界、瓶颈和最新进展，并构造了一棵包含 6 个一级分支、30 余个可检验问题的科学问题树。报告最后给出未来 3—5 年的研究议程、十个高价值选题和一组 “不该做什么” 的判断。

关键词：具身智能；机器人通用性；VLA；世界模型；跨本体；模仿学习；强化学习；人形机器人；评测；安全

一页纸：十个判断

1. **通用性是带预算的偏序，不是布尔值**。说一个机器人 “通用”，必须同时说明任务分布、环境分布、本体范围、成功率和成本约束；脱离这些条件的 “通用” 没有科学含义。
2. **VLA 解决了语义泛化的 “第一公里”，没有解决物理可靠性的 “最后一公里”**。语言和视觉先验可以迁移，接触、力控、长程误差和本体差异不会自动迁移。
3. **跨本体不是加一个 embodiment token 就能解决**。动作空间、运动学/动力学、传感配置是三重异构；真正需要的是统一动作接口、几何语义对齐和本体特定的适配层。
4. **世界模型的关键不是生成逼真视频，而是动作条件因果一致性**。一个能生成漂亮未来的模型，如果未来不随候选动作变化，就不能用于控制。
5. **模仿学习的天花板正在把领域推向两条后训练路径：部署中 RL 与上下文学习/物理提示**。π*0.6、车队级持续 RL 把真实部署数据、人工纠正和奖励信号接入了后训练闭环；GEN-1.5、Skild S1、RoboTTT 则尝试用一段视频演示直接指定新任务，把 “教几百遍” 变成 “看一遍”。
6. **人形机器人是通用性的重要载体，但不是充分条件**。硬件出货量和产线试点在快速增长，但开放世界自主性、可靠性和成本仍然远离 “通用”。
7. **评测是当前最被低估的瓶颈**。基准分数与真实部署表现的相关性弱，长程任务、统计功效和多轴分布外泛化普遍缺失；“排行榜进步” 不等于 “能力进步”。
8. **安全不能作为事后补丁**。学习型策略需要 “策略 + 安全壳 + 运行时保证” 的分层架构；形式化验证、不确定性量化和对抗鲁棒性仍是开放问题。
9. **未来 3–5 年的突破更可能来自系统级协同，而不是单点模型规模**。统一动作接口、世界–动作模型、物理提示/上下文学习、全栈系统、真实世界评测，这几件事的相互作用决定上限。
10. **科研选题应围绕 “可测量的 generality gap” 设计**。与其再做一个人云亦云的 VLA，不如把一个具体的泛化轴、一个失败模式或一个评测协议做到别人无法绕开。

v1.1 补一句：如果只能从这次增补里记一件事，那就是 2026 年的竞争已经不只是 “谁的 VLA 更大”，而是 “谁能让机器人更快学会新任务”。部署中 RL 与上下文学习/物理提示，是两条并行的答案；全栈系统则决定这两条答案能否变成可靠产品。

阅读指南

本报告面向四类读者：

- **研究者**：第 3—6 章提供历史脉络、路线谱系和科学问题树，可直接用于选题与相关工作定位；第 10 章给出高价值选题建议。
- **实验室/团队负责人**：第 7 章的系统栈与接口分析、第 9 章的瓶颈深潜，适合用于技术路线判断和资源分配。
- **产业与政策读者**：第 8 章的最新进展、第 9 章的部署瓶颈和第 10 章的趋势判断，提供了区分“演示”与“部署”的分析框架。
- **刚进入领域的学生**：先读第 1—2 章和第 4 章，再按兴趣选读第 5 章的一条路线；附录 A 的综述卡片可作为延伸阅读顺序。

报告中使用了三类证据标记：

- **A**：同行评议论文，或已被多个独立团队复现的结果；
- **B**：预印本或官方技术报告，含真实机器人/真实数据实验；
- **C**：公司博客、新闻或未经独立验证的部署声明。

引用编号对应附录 E。报告中的“截至 2026 年 10 月”指文献检索与事实核对的时间点；2026 年的部分预印本尚未经过同行评议，阅读时请保留证据折扣。

修订说明（v1.1，2026-10-23）

本版在 v1.0 基础上做了一次 “媒体—论文” 交叉增补。检索范围包括机器之心、量子位、新智元近一年（2025-10 至 2026-10）的机器人/具身智能/智能体报道，选取 20 余篇报道，回溯其对应的论文、技术报告或官方项目页，新增 8.10 节、附录 D 与 30 条参考文献。

增补的重点不是 “再列一批新闻”，而是回答三个问题：哪些媒体热度有论文支撑，哪些只是公司叙事；这些成果改变了研究地图的哪些假设；以及它们应该被放在七条路线的什么位置。阅读时请继续使用正文的 A/B/C 证据分级：A= 同行评议或独立复现，B= 预印本/官方技术报告，C= 公司博客/新闻/未经独立验证的部署声明。

1 领域界定、通用性定义与方法

1.1 什么是具身智能机器人

“具身智能”（embodied intelligence）并不是 “把大模型装进机器人” 的同义词。更严格地说，它指智能体通过身体与物理（或物理约束下的仿真）环境进行有目的的能量与信息交换，在 “感知—行动—反馈” 的闭环中形成适应、学习与推理能力。Roy 等人在 2021 年的纲领性综述中把这一点概括为 “与物理环境进行有目的的能量与信息交换”，并强调这种交换带来了安全、非独立同分布数据、任务规范、主动数据获取和形态设计等一组不同于互联网 AI 的问题 [3]。

据此，本报告采用一个窄而可操作的定义：

> **具身智能机器人**：具有物理或高保真仿真身体，能够感知环境、在闭环中采取行动、从交互中学习，并在开放任务/环境分布中追求自主性的智能系统。

这个定义包含三个承诺：

1. **身体性（embodiment）**：身体不是智能的 “容器”，而是感知、行动和归纳偏置的一部分。自由度、传感配置、执行器动力学和形态都会改变 “什么容易学、什么难以学”。
2. **交互性（interaction）**：智能不是对静态数据集的函数逼近，而是在动作—观测—奖励/反馈的闭环中涌现。动作会改变世界，也会改变后续的数据分布。
3. **情境性（situatedness）**：任务、环境、人类意图和社会规范共同定义 “什么算成功”。脱离情境的通用性无法评估。

与传统机器人学相比，具身智能更强调学习、泛化和基础模型；与互联网 AI 相比，它更强调物理约束、实时性、安全性和数据稀缺。三者的区别可以概括为表 1。

表 1 传统机器人学、互联网 AI 与具身智能机器人的比较

维度	传统机器人学	互联网 AI	具身智能机器人
核心对象	机构、控制、规划、传感	文本、图像、视频、代码	身体—环境闭环中的智能
数据	模型、标定、专家知识	互联网级静态数据	机器人轨迹、人类视频、仿真、交互
泛化	在建模范围内可靠	在数据分布内强	跨任务/环境/本体，且需物理可行
成功标准	精度、稳定性、安全性	基准分数、生成质量	真实任务成功率、成本、可靠性、安全
主要瓶颈	建模成本、接触、开放世界	事实性、因果、grounding	数据、跨本体、长程、评测、安全

维度	传统机器人学	互联网 AI	具身智能机器人

1.2 “通用性” 的七个维度

“通用机器人” 常被当作一个二元标签，但工程上它至少是七维空间中的一个点。一个系统可以在 “物体泛化” 上很强，却在 “跨本体” 上很弱；可以在 “已知环境多任务” 上很强，却在 “开放世界长程任务” 上失败。因此，本报告把通用性拆成七个维度：

维度	要回答的问题	典型度量
任务通用性	能否执行未见过的指令/目标组合?	新任务 zero-shot/few-shot 成功率
物体/场景通用性	能否处理新物体、新布局、新背景?	OOD 物体/场景成功率
本体通用性	能否迁移到不同自由度、运动学、传感的机器人?	跨本体迁移曲线、负迁移率
环境通用性	能否从仿真/实验室迁移到真实、动态、杂乱环境?	sim-to-real gap、扰动鲁棒性
时间通用性	能否完成长程任务并在部署中持续学习?	成功率随时间跨度的衰减、遗忘率
人类通用性	能否理解不同用户、模糊指令、社会规范?	意图满足率、澄清率、信任
效率/可靠性	在数据、算力、能量、安全预算内是否可负担?	样本效率、延迟、MTBF、成本/任务

这七个维度之间并不独立。提高物体泛化往往需要更多数据，而更多数据又加剧跨本体对齐的难度；提高长程能力往往需要记忆和分层，而分层又引入接口误差。**通用性因此不是 “全能”，而是在一组分布偏移下保持可接受的 “性能–成本–安全” 三角**。这也是本报告反复使用 “有效边界” 而非 “最强能力” 的原因。

1.3 能力阶梯 G0–G5

为了把 “通用” 落到可讨论的阶段，本报告给出一个操作化阶梯。它不是行业标准，而是用于比较路线与系统的分析工具；部分思想参考了 Long 等人提出的 IR-L0–IR-L4 机器人智能分级 [8]，但更强调学习系统的泛化轴。

级别	名称	能力特征	典型系统
G0	遥操作/脚本	人控制或固定程序，无自主决策	工业示教、遥操作
G1	单任务自主	在已知环境完成一个任务	专用抓取、固定装配
G2	多任务/语言条件	在已知环境执行多类任务，接受语言指令	RT-1、Octo、早期 VLA

级别	名称	能力特征	典型系统
G3	开放物体/场景	对新物体、新布局有短期泛化	RT-2、OpenVLA、π0
G4	跨本体/新任务少样本	在新本体/新任务上用少量数据适配	GR00T、Gemini Robotics、π0.5
G5	开放世界持续学习	长期自主、持续学习、安全人机共存	尚未实现

这个阶梯的关键含义是：**当前最强系统大致位于 G3—G4 之间，且“强”通常只在特定任务族、特定本体和有限时间跨度内成立**。产业演示中常见的“通用”叙事，往往把 G2/G3 的能力包装成 G5 的愿景。区分这两者，是阅读本报告后续证据表的第一原则。

1.4 文献与方法

本报告的文献工作分为三层。

第一层：综述骨架。以 arXiv、OpenAlex、Semantic Scholar 和主要期刊/会议为入口，围绕 “embodied AI survey”“robot learning”“vision-language-action”“world model”“sim-to-real”“dexterous manipulation”“humanoid” “task and motion planning”“embodied data/benchmark”“embodied safety” 等主题检索。初筛 60 余篇综述，保留 28 篇作为候选；其中 20 篇进行了全文或结构化全文阅读，重点提取分类体系、时间线、挑战清单、未来方向、数据集/基准。其余 8 篇用于摘要级交叉核对。

第二层：原始论文锚点。对综述中反复出现的里程碑系统，回溯原始论文或官方技术报告，核对时间、数据规模、任务设置、关键数字和证据等级。覆盖 RT-1/RT-2、Open X-Embodiment、Octo、OpenVLA、π0/π0.5/π*0.6、GR00T N1、Gemini Robotics 1.5、RDT-1B、AgiBot World、EgoDex、V-JEPA 2、Cosmos 系列、Genie 3、RoboArena、BEHAVIOR-1K、LIBERO、RoboCasa、ManiSkill3、DROID 等 30 余项工作。

第三层：证据分级与交叉验证。对每一条关键事实，至少用两个来源交叉核对：综述之间、综述与原始论文之间、论文与官方项目页之间。无法交叉验证的产业声明，统一标记为 C 级，并在正文中保留 “公司声明/未经独立验证” 的限定。

引用数来自 OpenAlex 的 2026 年 10 月查询，仅用于 “影响力粗筛”，不用于质量排序。原因有三：不同数据库对 arXiv 的收录差异很大；2025—2026 年的新综述尚未积累引用；综述的引用数与其覆盖范围、资源库影响力并不完全一致。因此，本报告对近年综述更多依据 “覆盖范围、分类框架的复用度、是否提供可复用资源” 来判断影响力。

核心综述样本如下。

综述样本（按引用与覆盖范围排列）

[1] A Survey of Embodied AI: From Simulators to Research Tasks

- 年份/覆盖：2022；仿真器、视觉探索/导航/EQA
- 主要贡献：前基础模型时代的任务金字塔
- 引用：397

[2] Aligning Cyber Space with Physical World: A Comprehensive Survey on Embodied AI

- 年份/覆盖：2025；机器人、仿真器、感知、交互、Agent、sim2real
- 主要贡献：四目标框架与 ARIO 数据标准
- 引用：150

[3] From Machine Learning to Robotics: Challenges and Opportunities for Embodied Intelligence

- 年份/覆盖：2021；具身学习的科学议程
- 主要贡献：归纳偏置、快慢系统、组合性、形态、评测
- 引用：50

[4] Toward General-Purpose Robots via Foundation Models: A Survey and Meta-Analysis

- 年份/覆盖：2023；基础模型用于通用机器人
- 主要贡献：五大挑战与开放问题清单
- 引用：30

[5] A Survey on Vision-Language-Action Models for Embodied AI

- 年份/覆盖：2025；VLA 组件、控制策略、任务规划
- 主要贡献：VLA 的分层分类与资源汇总
- 引用：42

[6] Vision-Language-Action Models for Robotics: A Review Towards Real-World Applications

- 年份/覆盖：2025；真实世界 VLA
- 主要贡献：数据、跨本体、算力与部署建议
- 引用：76

[7] A Comprehensive Survey on World Models for Embodied AI

- 年份/覆盖：2025；世界模型三轴分类
- 主要贡献：决策耦合、时间建模、空间表征
- 引用：0（新）

[8] A Survey: Learning Embodied Intelligence from Physical Simulators and World Models

- 年份/覆盖：2025；仿真器与世界模型
- 主要贡献：IR-L0—L4 分级、显式/隐式路径
- 引用：1

[9] World Model for Robot Learning: A Comprehensive Survey

- 年份/覆盖：2026；机器人世界模型
- 主要贡献：世界—动作模型、因果条件、评测
- 引用：1

[10] Dexterous Manipulation through Imitation Learning: A Survey

- 年份/覆盖：2025；灵巧操作与模仿学习
- 主要贡献：数据、基准、sim2real、实时性
- 引用：15

[11] The Developments and Challenges towards Dexterous and Embodied Robotic Manipulation

- 年份/覆盖：2025；灵巧操作发展史
- 主要贡献：从夹爪到多指手的挑战
- 引用：1

[12] A Survey of Behavior Foundation Model

- 年份/覆盖：2025；人形全身控制
- 主要贡献：行为基础模型、sim2real、本体泛化
- 引用：6

[13] Humanoid Robots and Humanoid AI

- 年份/覆盖：2025；人形机器人与 AI
- 主要贡献：功能/非功能规格、人本维度
- 引用：22

[14] Large Language Models for Robotics: A Survey

- 年份/覆盖：2023；LLM 用于机器人
- 主要贡献：语言规划、grounding、安全
- 引用：57

[15] A Survey of Optimization-based Task and Motion Planning

- 年份/覆盖：2024；TAMP
- 主要贡献：经典—学习融合、长程规划

- 引用：59

[16] A Review of Robot Learning for Manipulation

- 年份/覆盖：2019；操作学习
- 主要贡献：任务族、表征、技能、层级
- 引用：93

[17] Sim-to-Real Transfer in Deep Reinforcement Learning for Robotics

- 年份/覆盖：2020；sim2real RL
- 主要贡献：观测/动作/转移/奖励四类技术
- 引用：1

[18] A Survey of Sim-to-Real Methods in RL

- 年份/覆盖：2025；sim2real + 基础模型
- 主要贡献：保真度、安全、幻觉、算力
- 引用：3

[19] A Survey on Vision-Language-Action Models: An Action Tokenization Perspective

- 年份/覆盖：2025；动作 token 化
- 主要贡献：8 类动作 token 与层级架构
- 引用：1

[20] Vision-Language-Action in Robotics: A Survey of Datasets, Benchmarks, and Data Engines

- 年份/覆盖：2026；VLA 数据/基准/数据引擎
- 主要贡献：保真度—成本、推理基准、grounding
- 引用：0（新）

[21] Data Pyramid for Embodied Manipulation

- 年份/覆盖：2026；具身数据生态
- 主要贡献：五层数据金字塔与数据配方
- 引用：0（新）

[22] Foundation Models in Robotics: A Comprehensive Review

- 年份/覆盖：2026；机器人基础模型
- 主要贡献：五阶段演化、六类挑战
- 引用：0（新）

[23] Safety in Embodied AI: A Survey of Risks, Attacks, and Defenses

- 年份/覆盖：2026；具身安全
- 主要贡献：能力—风险对偶、五层攻击面
- 引用：0（新）

  说明：引用数为 OpenAlex 2026-10-19 查询，arXiv 新论文的引用数尚未累积。表中只列本报告直接依赖的 23 篇综述；另有 5 篇用于交叉核对，未单列。

1.5 本报告的分析框架

本报告不按 “感知/规划/控制” 的传统章节组织，而是按 “通用性从哪里来” 组织。原因很简单：传统分层描述的是系统结构，不能解释为什么某条路线在某个阶段有效、在另一个阶段失效。相反，“通

用性来源” 可以把技术选择、归纳偏置、数据需求和失效模式放在同一个框架里比较。

具体来说，报告使用五个坐标：

1. **时间轴**：六个阶段，从经典自动化到 2026 年的世界—动作模型。
2. **路线轴**：七条路线，分别对应一种 “通用性来源”。
3. **问题轴**：六个一级分支、30 余个可检验问题。
4. **能力轴**：G0—G5 的泛化阶梯。
5. **系统轴**：五层技术栈与五个接口。

这五个坐标会在第 2 章总览，在第 3—7 章展开，在第 8—10 章用于分析最新进展与未来议程。

2 研究地图总览

2.1 五个坐标

把具身智能机器人研究画成一张地图，至少需要五个坐标。只用一个坐标，都会把领域压扁成 “模型年表” 或 “论文分类”。

时间坐标回答 “什么时候发生了什么”。本报告把 1960—2026 年分为六个阶段：经典自动化与符号规划（1960—1990）、概率机器人与示教学习（1990—2012）、深度学习与强化学习（2012—2018）、具身 AI 基准与仿真基础设施（2018—2023）、VLA 与跨本体数据（2023—2024）、经验学习与世界—动作模型（2025—2026）。第 3 章展开。

路线坐标回答 “通用性从哪里来”。本报告识别出七条路线：模型/控制/TAMP、强化学习、模仿/示教/人类数据、基础模型/VLA、世界模型/生成式仿真、本体/灵巧/人形、组合/Agent/认知架构。这一划分与 Liu 等人的 “感知—交互—Agent—sim2real” 四目标框架 [2] 互补：前者回答 “通用性从哪里来”，后者回答 “系统由哪些能力组成”。数据、仿真与评测不是第八条 “竞争路线”，而是所有路线共享的底座。

问题坐标回答 “到底难在哪”。第 6 章给出一棵从总目标到可检验子问题的树，包含感知与表征、技能与控制、学习与泛化、推理与规划、交互与安全、系统与评测六个一级分支。

能力坐标回答 “现在到哪了”。G0—G5 的阶梯把 “通用” 拆成可比较的阶段；第 7 章把路线映射到能力级别。

系统坐标回答 “这些能力如何组装”。第 7 章给出五层技术栈：任务与 Agent、世界模型、通用策略、技能与控制、本体与传感，以及横跨各层的数据/评测/安全底座。

2.2 七条路线

七条路线不是互斥的 “门派”，而是对 “通用性来源” 的七种不同押注。理解它们的假设，比记住它们的模型名字更重要。

路线	通用性假设	一句话技术路线	最擅长	结构性短板
A 模型/控制/TAMP	通用性来自可组合的物理模型与优化	用符号任务规划 + 运动规划/MPC 组合出可解释行为	结构化环境、长程任务、安全约束	开放世界建模成本、接触/形变、感知 grounding
B 强化学习	通用性来自自主交互与奖励优化	在仿真/现实中试错，学习策略或世界模型	运动、灵巧控制、窄域最优性	样本效率、奖励设计、sim2real、安全
C 模仿/示教	通用性来自复制多样的人类技能	遥操作/人类视频 → 行为克隆/扩散策略	灵巧操作、精细任务、快速技能获取	数据成本与覆盖、复合误差、本体差异
D 基础模型/VLA	通用性来自互联网语义先验 + 语言接口	视觉—语言预训练 → 机器人数据微调 → 动作生成	语义泛化、指令跟随、多任务	物理 grounding、动作表示、跨本体、延迟
E 世界模型	通用性来自对未来的预测与想象	学习动作条件动力学，在潜空间/视频空间推演	规划、数据生成、策略评估	因果条件、长程漂移、物理保真、算力

路线	通用性假设	一句话技术路线	最擅长	结构性短板
F 本体/灵巧/人形	通用性来自身体、形态与传感	人形/灵巧手/触觉/柔顺执行器 + 全身控制	物理交互、人形环境适配、硬件平台	可靠性、成本、触觉、能耗、控制复杂度
G 组合/Agent	通用性来自技能与推理的组合	分层策略、LLM 规划、记忆、反思、多智能体	长程任务、工具使用、人机交互	接口误差、幻觉、状态跟踪、延迟
H 数据/评测（底座）	通用性来自覆盖充分、对齐良好的经验	数据集、仿真器、数据引擎、基准与评测协议	规模、复现、跨本体数据	保真度−成本、对齐、基准有效性、长尾

表中最后一行 H 是横切底座，不是第八条竞争路线；它不直接产生能力，但决定其他路线能否规模化、可复现、可比较。

这张表有一个重要含义：**每条路线都只能解释通用性的一部分**。模型/控制路线能给出可靠性，但不能自动获得开放世界语义；VLA 能给出语义泛化，但不能自动获得接触精度；世界模型能给出预测，但不能自动保证控制可行；人形能给出环境适配，但不能自动获得自主性。真正的 “通用” 必然是这些来源的组合。

2.3 一张图：七条路线与关键里程碑

读这张图有三个要点。

第一，横向看 “重心迁移”。1960−1990 年代的重心在模型/控制与符号规划；1990−2012 年转向概率机器人、示教学习和优化式 TAMP；2012−2018 年深度学习与 RL 进入主舞台；2018−2023 年仿真器、基准和跨本体数据成为基础设施；2023−2026 年，VLA、世界模型、人形机器人和真实部署同时加速。重心不是简单 “从模型转向数据”，而是 “模型、数据、本体、评测” 四个轮子交替驱动。

第二，纵向看 “路线收敛”。七条路线并不是七条平行线。2023 年之后，原本分离的路线开始在同一批系统里汇合：VLA 用上了模仿学习的数据和 RL 的后训练；世界模型开始与策略联合训练；人形机器人同时采用 RL 全身控制和 VLA 高层策略；Agent 架构把 LLM 规划、记忆和技能调用组合起来。图中 2023−2026 年的节点密集出现在 D/E/F/G 四条路线上，这本身就是领域成熟的信号。

第三，看 “图没有画出的空白”。图中每一行是一条路线的强项，但 “跨本体 + 长程 + 接触 + 安全” 的交叉区域并没有被任何单条路线覆盖。现有系统在单点上很强，在交叉点上很弱：能跨本体的系统往往接触精度不足；能灵巧操作的系统往往数据成本极高；能长程规划的系统往往实时性差；能实时控制的系统往往语义泛化弱。**这些交叉空白，就是下一阶段最值得攻的科学问题**。

2.4 四个核心结论

结论一：领域已经形成 “主干 + 多条支流” 的格局。主干是 “基础模型（语义先验）+ 机器人数据（动作监督）+ 动作专家（连续控制）”。RT-2、OpenVLA、π0、GR00T N1、Gemini Robotics 1.5 都在这个主干上。支流包括 TAMP/MPC、RL、世界模型、人形硬件、Agent 架构；它们不是被主干取代，而是被主干 “调用”。

结论二：瓶颈已经从 “感知/语义” 转向 “数据/本体/长程/评测”。五年前，领域最痛的是 “机器人看不懂世界”；今天，VLM 已经能提供相当强的开放词汇感知和语义推理。真正卡住部署的是：数据不够

图 1 具身智能机器人研究地图：七条路线与关键里程碑



图 1 具身智能机器人研究地图：七条路线与关键里程碑

多样、跨本体动作对不齐、长程误差累积、接触物理不可控、评测不能预测真实表现、安全无法证明。

结论三：2025—2026 年出现了四个转折。一是从 “离线模仿” 转向 “部署中学习”（π*0.6、车队级 RL）；二是从 “视频生成” 转向 “世界—动作模型”（Cosmos 3、MachEmbodied-U0、VLA-JEPA、ABot-PhysWorld）；三是从 “基准排行榜” 转向 “分布式真实世界评测”（RoboArena）与 “评测有效性反思”[24]；四是任务接口从 “语言指令” 扩展到 “视频演示/物理提示”（GEN-1.5、Skild S1、RoboTTT）[83][84][85]。这四个转折会重塑未来几年的研究议程。

结论四：通用性的下一程是 “系统科学”，不是 “单点模型”。需要研究接口、频率、误差传播、数据配比、安全壳、评测协议和持续学习机制；高德 ABot 这类全栈系统说明，数据/世界模型、导航、执行、Agent、推理正在被同一套体系组织起来 [89][90][91][92][93][109]。这些问题不像 “再训练一个更大的 VLA” 那样直观，但它们决定系统能否从 G3 走到 G4/G5。

3 历史演进：从编程机器到具身基础模型

3.1 六个阶段

领域史不是 “模型越来越大” 的线性史，而是一部 “问题—方法—基础设施” 互相追赶的历史。表 2 给出六个阶段的压缩版本；随后逐段解释每次迁移的驱动力。

表 2 具身智能机器人研究的六个阶段

阶段 / 时间	主导问题	代表方法 / 基础设施	主要瓶颈 / 通用性来源
P0 经典自动化与符号规划（1960—1990）	如何在封闭世界中感知、规划、行动?	Unimate、Shakey、STRIPS、Subsumption；手工地图、符号模型、工业产线	封闭世界、组合爆炸、感知脆弱；物理模型 + 符号推理
P1 概率机器人与示教学习（1990—2012）	如何处理不确定性、噪声和真实环境?	概率机器人、SLAM、POMDP、TAMP、LfD；概率模型、RGB-D、运动捕捉	手工特征、任务专用、泛化弱；概率模型 + 人类示教
P2 深度学习与强化学习（2012—2018）	能否用学习替代特征工程?	AlexNet、DQN、抓取检测、手眼协调、Dactyl、ANYmal；大规模图像、仿真、GPU	数据饥渴、sim2real、窄任务；数据 + 端到端学习
P3 具身 AI 基准与仿真（2018—2023）	能否规模化训练和比较具身智能?	Habitat、AI2-THOR、iGibson、SAPIEN、RoboTHOR、BEHAVIOR-1K；仿真器、3D 场景、任务基准	仿真偏差、短程、缺灵巧；仿真数据 + 基准
P4 VLA 与跨本体数据（2023—2024）	能否用一个策略跨任务/跨机器人?	RT-2、Open X-Embodiment、Octo、OpenVLA、π0、RDT-1B；OXE、DROID、BridgeData V2、AgiBot World	模仿上限、数据稀缺、延迟；语义先验 + 跨本体数据
P5 经验学习与世界—动作模型（2025—2026）	能否从部署中持续变强、并预测物理后果?	π0.5、π*0.6、GR00T N1、Gemini Robotics 1.5、Cosmos 3、Genie 3；真实部署数据、人类视频、世界模型、车队	可靠性、安全、评测、跨本体；经验 + 预测 + 系统集成

P0：经典自动化与符号规划（1960—1990）

1961 年，Unimate 在通用汽车工厂上线，标志着工业机器人进入产线。这一时期的机器人擅长在高度结构化的环境中执行固定轨迹，但 “智能” 主要体现在离线编程和专用夹具，而不是在线感知与决策。

1966—1972 年的 Shakey 是另一个传统：它尝试把视觉、地图、符号规划和运动控制放进同一个移动平台，形成了 “感知—规划—行动” 的经典范式 [75]。Shakey 的意义不在于性能，而在于它第一次把 “机器人智能” 定义为一个跨模块的系统问题。STRIPS 规划器、A* 搜索、符号状态空间等工具，至今

仍是 TAMP 的祖先。

1986 年，Brooks 提出 Subsumption 架构，反对 “感知—建模—规划—行动” 的重型流水线，主张用分层的行为模块直接连接感知与行动 [74]。这是一次重要的认识论转向：智能不需要先建立完整的世界模型，可以在与环境的实时交互中涌现。Subsumption 影响了后来的行为机器人、强化学习和端到端控制，但它也暴露了另一个问题：没有显式模型，系统很难完成需要长期推理和组合的任务。

这一阶段的遗产：系统思维、符号规划、行为分层；**遗留问题**：开放世界、不确定性、学习。

P1：概率机器人与示教学习（1990—2012）

1990 年代到 2000 年代，机器人学的主线从 “确定性符号规划” 转向 “不确定性下的概率推理”。Thrun、Burgard 和 Fox 的《Probabilistic Robotics》系统化了贝叶斯滤波、定位、建图、SLAM 和 POMDP[76]。SLAM 让机器人在未知环境中同时定位与建图，成为移动机器人的基础设施；粒子滤波、扩展卡尔曼滤波、图优化等方法，至今仍在自动驾驶、无人机和移动机器人中广泛使用。

与此同时，任务与运动规划（TAMP）从分开的 “符号规划” 和 “运动规划” 走向联合求解。约束式、采样式和优化式 TAMP 逐渐成熟，能够处理长程任务中的几何可行性、抓取位姿和碰撞约束 [15]。在操作学习方面，示教学习（LfD）成为一条重要路线：Argall 等人的综述把示教学习分为行为克隆、逆强化学习、示教编程等范式，并强调 “示教数据的覆盖度” 和 “复合误差” 是核心难题 [16]。

这一阶段的遗产：不确定性建模、SLAM、TAMP、LfD；**遗留问题**：特征工程、任务专用、感知语义弱。

P2：深度学习与强化学习（2012—2018）

2012 年 AlexNet 引爆深度学习，2013 年 DQN 把深度网络与强化学习结合。机器人领域很快跟进：2015 年前后，基于 RGB-D 的抓取检测、手眼协调抓取、端到端 visuomotor 控制成为热点。Levine 等人 2016 年的工作用大规模真实抓取数据训练手眼协调策略，展示了 “数据 + 深度网络” 在真实机器人上的可行性 [72]。Kober 等人的综述则系统总结了 RL 在机器人中的样本效率、奖励设计和安全挑战 [73]。

这一时期的另一条主线是仿真训练与 sim-to-real。2017—2019 年，域随机化、系统辨识、对抗适应等方法在四足运动、灵巧手和无人机上取得进展。Hwangbo 等人的 ANYmal 工作展示了 RL 训练的策略可以迁移到真实四足机器人 [77]；OpenAI 的 Dactyl 展示了灵巧手在仿真中学习、再迁移到真实手部的可能性 [78]。

这一阶段的遗产：端到端学习、GPU 训练、sim2real；**遗留问题**：数据饥渴、任务窄、语义弱、真实世界泛化差。

P3：具身 AI 基准与仿真基础设施（2018—2023）

2018 年前后，社区意识到 “没有统一的仿真器和基准，具身智能无法比较”。Habitat（2019）、AI2-THOR、iGibson、SAPIEN、RoboTHOR（2020）、BEHAVIOR-1K（2024）等平台相继出现，覆盖导航、交互、物体重排、长程家务等任务 [1][50]。这些平台把 “具身 AI” 从一个模型问题变成了一个 “环境—任务—评测” 的系统问题。

Duan 等人的 2022 年综述用 “仿真器—任务金字塔” 总结了这一时期：视觉探索是底层，视觉导航是中层，具身问答是上层；任务越往上，越依赖记忆、语言和交互 [1]。这一框架在今天仍然有用，但它有两个时代局限：一是任务主要是虚拟环境中的导航/问答，缺少真实灵巧操作；二是评测以离散动作和短程为主，和真实机器人控制差距很大。

这一阶段的遗产：仿真器、任务基准、可复现实验；**遗留问题**：仿真偏差、灵巧操作缺失、真实部署少。

P4：VLA 与跨本体数据（2023—2024）

2022 年底，RT-1 用大规模多任务真实机器人数据训练 Transformer 策略，展示了 “数据规模 + 模型容量 + 任务多样性” 的缩放趋势 [30]。2023 年，RT-2 把视觉—语言模型与机器人动作联合微调，把动作表示为文本 token，第一次让 “互联网语义知识” 大规模进入机器人控制 [31]。同年，Open X-Embodiment 汇集 22 种机器人、21 家机构、527 种技能、160,266 个任务，训练出 RT-X 模型，证明了跨机器人正迁移的可能性 [32]。

2024 年，OpenVLA 以 7B 参数、970k 真实演示开源，绝对成功率超过 RT-2-X 16.5%，参数少 7 倍 [34]；Octo 以 800k 轨迹训练开源通用策略 [33]；π0 用流匹配动作专家，把 VLA 扩展到灵巧操作和多本体 [35]；RDT-1B 用扩散 Transformer 处理双臂操作 [40]。这一阶段的关键词是 “通用策略”“跨本体”“开源”。

这一阶段的遗产：VLA 主干、跨本体数据、开源生态；遗留问题：模仿上限、数据成本、跨本体动作对齐、实时性、评测。

P5：经验学习与世界—动作模型（2025—2026）

2025 年之后，领域出现三个明显变化。

第一，从离线模仿转向部署中学习。π0.5 展示了端到端系统在全新家庭中完成长程清洁任务的能力 [36]；π*0.6 用 RECAP（advantage-conditioned RL）把演示、在线数据和人类纠正结合起来，在最难任务上把吞吐量提高一倍以上、失败率降低约一半 [37]；Learning While Deploying 进一步把 “车队级离线—在线 RL” 作为通用策略的持续后训练框架 [64]。这说明 “模仿学习是上限” 的共识正在被打破。

第二，从视频生成转向世界—动作模型。Cosmos 1（2025-01）把世界基础模型作为物理 AI 的 “数字孪生”[45]；Cosmos-Predict2.5（2025-10）用 2 亿段视频训练 2B/14B 模型 [46]；Cosmos 3（2026-06）把语言、图像、视频、音频和动作统一进一个混合 Transformer，直接 “包含” 世界模拟器和世界—动作模型 [47]。Genie 3（2025-08）展示了 720p、24fps、几分钟一致性的实时交互世界 [48]；V-JEPA 2 用 100 万小时视频 + 62 小时机器人视频，实现零样本 Franka 抓放 [44]。世界模型不再只是 “生成数据”，而是开始进入策略的核心。

第三，人形机器人从演示走向产线试点。Figure 02 在 BMW Spartanburg 工厂进行了 11 个月、每天 10 小时的试点，搬运超过 9 万个钣金件、累计 1,250 多个小时，参与超过 3 万辆 X3 的生产；Figure 官方称其达到 5 毫米级放置精度、约 200 英里等效步行的运行量（公司声明，未经独立审计）[49]。Unitree 2025 年出货超过 5,500 台人形机器人，AgiBot 到 2026 年 3 月累计生产超过 10,000 台（据媒体报道，未经审计）[81]。这些数字说明硬件和产线能力在快速成熟，但也说明当前部署主要是结构化、重复性工位，而不是开放世界通用性。

第四，任务接口从语言扩展到视频演示。GEN-1.5 用 3—12 秒单演示做 one-shot，Skild S1 用一条视频演示做 10 分钟新任务，RoboTTT 把上下文扩展到 8K timesteps[83][84][85]。这条 “物理提示/上下文学习” 路线不替代 VLA，而是给 VLA 加了一层 “快速适配” 接口；它可能改变 “每个新任务都要收集几百条轨迹” 的成本结构。

第五，竞争单元从单模型转向全栈系统。高德 ABot 系列把数据/世界模型（ABot-PhysWorld、ABot-World-0）、导航（ABot-N1）、执行（ABot-M0.5）、Agent（ABot-Claw）、推理（ABot-ER）放进同一个体系 [89][90][91][92][93][109]。这支持本报告 “通用性是系统属性” 的判断，也意味着单点模型比较越来越难解释系统能力。

这一阶段的遗产：部署数据闭环、世界—动作模型、物理提示/上下文学习、全栈系统、人形产线；遗留问题：可靠性、安全、评测、成本、开放世界自主性、独立复现。

3.2 三次范式迁移

把六个阶段压缩，可以看到三次真正的范式迁移。

第一次：从 “手工建模” 到 “概率建模”。 P0 的机器人假设世界是确定的、可符号化的；P1 承认世界有噪声、有不确定性，用概率方法处理部分可观测性。这次迁移解决了 “真实世界不按剧本走” 的问题，但没有解决 “语义开放” 的问题。

第二次：从 “概率建模” 到 “数据驱动学习”。 P2/P3 用深度网络和 RL 替代手工特征，用仿真器和基准替代零散实验。这次迁移解决了 “感知和低层控制的特征工程” 问题，但带来了数据饥渴、sim2real 和评测难题。

第三次：从 “任务专用策略” 到 “基础模型 + 后训练”。 P4/P5 用互联网语义先验和跨本体数据训练通用策略，再通过微调、RL、人类纠正做后训练。这次迁移解决了 “语义泛化” 和 “多任务” 的一部分问题，但把瓶颈推向了物理 grounding、跨本体、长程、安全和评测。

三次迁移有一个共同结构：**每一次都是把上一阶段的 “手工瓶颈” 换成下一阶段的 “数据/系统瓶颈”**。这也是为什么 “通用性” 不会因为某一个模型出现而突然实现；它是一连串瓶颈转移的结果。

3.3 为什么是现在

2023—2026 年的加速不是偶然，至少有六个推力。

1. **语义先验可迁移。** CLIP、LLaVA、Gemini 等视觉—语言模型提供了开放词汇感知、指令理解和常识推理，机器人不再需要从零学习 “杯子是什么”。
2. **动作生成范式成熟。**扩散策略、流匹配、动作 chunk、双系统架构，让连续、多模态、高维动作的建模变得可行 [19][35][38]。
3. **跨本体数据出现。** OXE、DROID、AgiBot World、EgoDex、UMI 等数据集，把 “单实验室数据” 变成 “社区级数据”[20][21][32]。
4. **仿真与 GPU 并行。** Isaac Lab、ManiSkill3、RoboCasa 等平台把训练吞吐量提高了几个数量级，让大规模 RL 和 sim2real 变得实际 [52][53]。
5. **硬件成本下降。**人形机器人、灵巧手、触觉传感器的 BOM 成本快速下降，产线试点成为可能 [81]。
6. **资本与产业需求。**制造业、物流、养老、服务业提供了真实场景和资金，推动 “演示—试点—部署” 的循环。

但这六个推力也带来一个副作用：**演示能力的增长速度，快于可靠性和评测能力的增长速度**。这就是为什么 2025—2026 年的文献里，“评测”“安全”“失败恢复”“部署” 出现的频率显著上升。

3.4 历史留下的五个教训

教训一：通用性声明很容易超过证据。从早期的 “通用机器人” 到今天的 “通用人形”，每一次浪潮都伴随过度承诺。判断一个系统是否真的更通用，要看它在未见任务/环境/本体上的表现，而不是看演示视频的多样性。

教训二：数据覆盖比数据规模更重要。OXE 的价值不只是 “100 万条轨迹”，而是 22 种机器人、527 种技能、160,266 个任务的覆盖 [32]。DROID 的价值不只是 “76k 条轨迹”，而是 564 个场景、84 个任务、50 个实验室的多样性 [54]。单纯重复同一工位的百万条数据，不会带来通用性。

教训三：混合系统往往比纯端到端更可靠。历史反复证明：在安全关键、接触密集、长程任务中，模型/控制/规划的组合比单一黑箱更可控。今天的 VLA 系统也越来越多地采用 “VLA + 低层控制器 + 安全壳” 的混合架构 [6][22]。

教训四：硬件和数据基础设施是“慢变量”。模型可以几个月迭代一代，但机器人的可靠性、触觉传感器、数据采集管线、评测协议需要几年。最终限制通用性的是这些慢变量，而不是参数量。

教训五：安全必须前置。每一次从实验室走向真实世界，都会暴露新的安全风险：对抗攻击、传感器欺骗、记忆投毒、级联失败 [23]。安全不是部署前的最后一步，而是架构设计的第一天就要考虑的问题。

4 通用性的七个来源

如果 “通用性” 不是单一模型的属性，那么它到底从哪里来？本报告把领域内的路线归纳为七个来源。每个来源都是一种 “归纳偏置”：它假设世界具有某种结构，并利用这种结构来减少学习所需的数据、搜索空间或监督信号。理解一个来源的假设，就能理解它的有效边界。

4.1 来源一：物理模型——通用性来自可组合的抽象

核心假设：世界遵循物理规律，任务可以被分解为符号目标与几何/动力学约束；只要模型足够准确，规划器就可以在模型内组合出新的行为。

这是机器人学最古老的信念。TAMP 把任务规划（符号）与运动规划（连续）结合，MPC/最优控制把动力学与约束结合，WBC 把全身平衡与接触约束结合。它们的优势是**可解释、可验证、长程组合能力强**：一个抓取–搬运–放置的任务可以被分解为可检查的子目标，一个碰撞约束可以被形式化，一个安全边界可以被证明。

但物理模型的通用性有一个硬上限：**模型只覆盖它建模过的世界**。接触模式切换、可变形物体、流体、摩擦、磨损、传感器噪声，都是建模的深水区。TAMP 的综述指出，优化式 TAMP 仍然对初值敏感、容易陷入局部最优、难以处理复杂接触和动态环境；LLM 生成的计划往往 “语义合理但物理不可行”，空间推理和长程记忆仍是短板 [15]。

因此，物理模型路线的真正问题不是 “要不要建模”，而是**如何用学习补上模型不确定的部分，同时保留可验证的骨架**。这也是 “VLA + 安全壳 + MPC/WBC” 混合架构流行的原因。

4.2 来源二：交互经验——通用性来自试错与优化

核心假设：如果智能体能在足够多的任务上交互，并用奖励/目标函数优化，它就能学到超越演示数据的行为。

强化学习是这一来源的典型。它的优势是**能找到人类示范之外的最优策略**：四足运动、灵巧手内操作、无人机竞速、游戏，都是 RL 的高光场景。DreamerV3 用单一配置在 150 多个任务上超过专用方法 [62]；TD-MPC2 用隐式世界模型在 104 个任务上取得稳定结果，并展示模型/数据规模的 scaling[63]。

但 RL 的通用性受三个约束。第一是**样本效率**：真实机器人的每一次试错都有时间、磨损和安全成本。第二是**奖励设计**：稀疏奖励、长程信用分配、多任务奖励冲突，仍然需要大量人工。第三是**非平稳性**：真实世界的数据分布会随环境、用户、硬件磨损变化，离线训练的策略很容易失效。

2025—2026 年的重要变化是，RL 不再只是 “从零训练技能”，而是成为**基础模型的后训练机制**。π*0.6 的 RECAP 把演示、在线数据、人类纠正统一为 advantage-conditioned RL，说明 “部署中学习” 可以显著改善真实任务表现 [37]；车队级 RL 进一步把多机器人部署数据汇总为持续后训练信号 [64]。这让 RL 从 “窄域技能工厂” 变成了 “通用策略的进化引擎”。

4.3 来源三：人类示范——通用性来自文化传递

核心假设：人类已经用身体解决了大量物理任务；如果能高效捕获人类示范，机器人就不必从零探索。

示教学习（LfD）、行为克隆、扩散策略、动作 chunk、人类视频学习，都属于这一来源。它的优势是**样本效率高、技能自然、适合精细操作**：ACT/ALOHA 用低成本遥操作完成穿扎带、插电池等精细双臂任务 [57]；Diffusion Policy 用动作扩散处理多模态行为，在 12 个任务上平均提升 46.9%[56]；RDT-1B 用扩散 Transformer 做双臂操作 [40]；EgoDex 用 829 小时第一视角视频、194 个桌面任务，提供了大规模人类手部数据 [43]。

但人类示范有三个结构性难题。第一是**覆盖度**：示范只能覆盖人类示范过的状态，策略一旦偏离就会进入未见状态，误差复合。第二是**本体差异**：人的手、臂、视角和机器人不同，动作不能直接复制；retargeting 可以解决几何映射，但解决不了接触动力学和力限。第三是**数据质量与失败数据**：大多数数据集只保留成功轨迹，模型学不到 “如何失败、如何恢复”[21]。

人类视频路线的最新价值，不是 “用视频替代机器人数据”，而是**把人类视频当作结构化先验**：任务意图、物体可供性、抓取选择、接触顺序、长程结构，这些可以迁移；具体的关节动作和力控，仍需要机器人数据 grounding[25][26]。

2026 年出现了一个更激进的变化：示范不再只用于训练，而是作为**推理时的上下文 prompt**。GEN-1.5 用 3—12 秒视频演示做 one-shot，Skild S1 用一条演示做 10 分钟新任务，RoboTTT 把上下文拉到 8K timesteps[83][84][85]。这把 “人类示范” 从 “数据集” 变成了 “任务接口”：机器人不必为每个新任务收集几百条轨迹，而是从演示中推断意图、对应关系和进度。它是否能取代后训练、能否独立复现，仍是开放问题；但它确实给 “示范” 这条老路线注入了新的通用性机制。

4.4 来源四：语义先验——通用性来自互联网知识 + 语言接口

核心假设：互联网级的视觉—语言预训练已经学到了大量关于物体、属性、关系和常识的知识；语言是人类最自然的任务接口；只要把语义知识接到动作上，机器人就能泛化到新任务。

VLA 是这一来源的集大成者。RT-2 把动作表示为文本 token，与视觉—语言数据联合微调，展示了新物体、新指令和简单语义推理的涌现能力 [31]；OpenVLA 用 970k 真实演示训练 7B 开源模型，在 29 个任务上超过 RT-2-X 16.5%[34]；π0 用流匹配动作专家，把 VLA 扩展到灵巧操作 [35]；GR00T N1 用双系统架构把人形机器人的慢思考与快控制结合 [38]；Gemini Robotics 1.5 用 Motion Transfer 从多本体数据学习，并在动作之间插入多级语言推理 [39]。

但语义先验有一个根本局限：**语义上合理不等于物理上可行**。 VLA 可以理解 “把杯子放到架子上”，但不知道杯子的摩擦、重量、重心、架子边缘的接触稳定性；它可以生成 “看起来对” 的动作序列，但在接触密集任务中失败。2025 年的 VLA 综述把这一组问题概括为 “物理 grounding、动作 token 化、跨本体、长程、评测、安全” 六大瓶颈 [5][6]；2026 年的综述进一步指出 “语义—物理空间错配” 是基础模型进入机器人的核心障碍 [22]。

因此，语义先验的通用性是 “任务空间” 的通用性，不是 “物理空间” 的通用性。它需要与示范、RL、世界模型、控制壳结合，才能转化为可靠行为。2026 年的 ACoT-VLA 进一步把 “推理” 从语言/视觉空间搬到动作空间：先生成粗粒度动作草图，再用隐式动作先验细化，试图把 “语义—运动鸿沟” 变成可训练的中间表示 [87]。这说明语义先验的价值不只是 “理解任务”，还在于为动作空间提供结构化的先验。

4.5 来源五：预测想象——通用性来自对未来的模拟

核心假设：智能体如果能在行动前预测 “如果我这样做，世界会怎样”，就可以用想象替代部分真实试错，进行反事实规划。

世界模型是这一来源的典型。它有三种角色：**策略的预测 backbone**（如 Dreamer、TD-MPC2）、**策略的训练/评估模拟器**（如 Cosmos、Genie）、**数据生成器**（如视频生成、合成轨迹）。Ha 与 Schmidhuber 的早期工作把世界模型定义为 “在潜空间中学习环境动力学，并在想象中训练策略”[79]；DreamerV3 把这一思想扩展到 150 多个任务 [62]；V-JEPA 2 用 100 万小时视频预训练，再用 62 小时机器人视频后训练出动作条件世界模型，零样本部署到 Franka[44]；Cosmos 系列从 “世界基础模型” 走向 “全模态世界模型”[45][46][47]；Genie 3 展示了实时交互、几分钟一致性的生成式世界 [48]。

但世界模型的通用性受三个约束。第一是**因果条件**：如果预测的未来主要依赖历史上下文，而不是候选动作，它就无法用于控制；这是 2026 年世界模型综述指出的 “因果条件缺口”[9]。第二是**长程漂**

移：自回归预测的误差会累积，几分钟后的未来可能已经物理失真。第三是**评测**：FVD/FID 等视觉指标与下游控制效用相关性弱；一个视觉逼真的模型可能对动作不敏感，一个视觉粗糙的模型可能对规划更有用 [24]。

世界模型路线的真正前沿，不是 “生成更逼真的视频”，而是**生成动作条件一致、物理自洽、可用于闭环决策的未来**。这也是 “世界–动作模型”（World-Action Model）在 2026 年兴起的原因：预测与控制不再分开，而是在同一个模型中联合训练。

4.6 来源六：身体形态——通用性来自身体与形态

核心假设：智能不是脱离身体的算法；身体的结构、传感和执行能力本身编码了归纳偏置。设计好的身体，可以让学习问题变简单。

人形机器人、灵巧手、触觉传感器、柔顺执行器、软体机器人，都属于这一来源。人形的优势是**环境适配**：人类环境（门、楼梯、工具、工位）是按人的形态设计的，人形机器人不需要重新改造环境。灵巧手的优势是**操作能力**：多指手可以完成抓取、捏取、旋转、工具使用等夹爪无法完成的任务。触觉的优势是**接触感知**：视觉看不到力、滑移、材料、接触面积，触觉可以直接测量。

但身体形态的通用性也有硬约束。第一是**可靠性**：更多自由度、更多传感器、更复杂的执行器，意味着更多故障点；Figure 02 在 BMW 的 1,250 小时运行中，前臂电子是首要硬件故障点，直接推动了 Figure 03 的腕部电子重构 [49]。第二是**成本**：灵巧手、触觉皮肤、人形关节的成本仍然很高。第三是**控制复杂度**：高自由度、接触丰富的全身控制，需要 RL/MPC/WBC 的深度结合；行为基础模型（BFM）仍受 sim2real、数据瓶颈、本体泛化限制 [12]。

身体形态路线的真正问题不是 “人形还是专用”，而是**形态与任务的匹配**。在结构化工厂，专用机械臂可能比人形更高效；在人类家庭，人形可能更有优势；在危险环境，蛇形/无人机/四足可能更合适。通用性不等于人形，人形只是 “人类环境通用性” 的一种载体。

4.7 来源七：组合架构——通用性来自技能与推理的组合

核心假设：单个策略不需要会做所有事；如果能把感知、技能、规划、记忆、反思组合起来，系统就能完成远超单个策略的任务。

这一来源的祖先是 Subsumption 的分层行为 [74]、选项框架（options）和分层 RL。今天的代表是 LLM 驱动的 Agent 架构：SayCan 用 LLM 生成技能序列，再用价值函数做可行性过滤 [58]；Inner Monologue 用语言反馈闭环规划 [60]；Code as Policies 用代码组合感知 API 和技能 [59]；VoxPoser 用 LLM 生成 3D 价值图，再交给运动规划器 [61]；Voyager 等系统在开放世界中持续探索、写技能、反思 [82]。Gemini Robotics 1.5 把 “思考” 插入动作生成，Embodied-R1.5 把规划、指向、纠正统一到一个具身基础模型 [39][66]。

组合架构的优势是**长程、可解释、可扩展**：新增一个技能不需要重训整个模型；一个失败可以被归因到某个子任务；人类可以用语言插入纠正。但它的瓶颈在**接口**：任务分解的输出如何变成技能的可执行输入？技能的 precondition/effect 如何被准确估计？一个子任务的失败如何传播、检测、恢复？LLM 的幻觉如何被物理可行性过滤？这些问题不解决，组合架构就会变成 “看起来很有条理，实际错误百出”。

4.8 第八个 “元来源”：数据与评测

七个来源都需要一个共同的底座：**数据与评测**。数据决定了哪些来源可以被训练，评测决定了哪些来源被证明有效。

数据侧的核心矛盾是 “规模 vs 机器人对齐”。真实机器人数据最对齐，但最贵；UMI/人类视频更便宜，但存在本体差异；仿真可以无限生成，但存在 sim2real gap；互联网数据语义最丰富，但没有动作监督。2026 年的 “数据金字塔” 把这一矛盾形式化为五层：真实机器人数据、UMI 风格数据、第一/第三人称人类数据、仿真数据、通用视觉—语言数据；越往下越可扩展，越往上越对齐 [21]。

评测侧的核心矛盾是 “基准 vs 部署”。现有基准大多短程、少本体、少场景，且以二元成功率为主要指标；真实部署需要长程、多轴 OOD、统计显著、安全约束和成本指标。RoboArena 用分布式、双盲、成对比较来评估通用策略，在 7 个机构、600 多个真实回合上证明其排名比集中式基准更接近真实表现 [42]。这说明评测本身正在从 “打分” 变成 “研究基础设施”。

来源	对应路线	它解决什么	它不解决什么
物理模型	A	可解释、可验证、长程组合	开放世界建模、接触/形变、感知 grounding
交互经验	B	超越示范的最优性、适应	样本效率、奖励、安全、非平稳
人类示范	C	快速技能获取、精细操作	覆盖度、复合误差、本体差异
语义先验	D	开放词汇、指令跟随、多任务	物理 grounding、动作精度、长程
预测想象	E	反事实规划、数据生成、评估	因果条件、长程漂移、评测
身体形态	F	环境适配、接触感知、物理能力	可靠性、成本、控制复杂度
组合架构	G	长程、可解释、可扩展	接口误差、幻觉、状态跟踪
数据/评测	H	规模、复现、跨本体经验	保真度—成本、对齐、基准有效性

这张表的读法是：不要问 “哪条路线最强”，要问 “在当前任务分布和预算下，哪几个来源的组合最缺”。这就是研究地图的实用价值。

5 七条路线与横切底座

本章按 “通用性来源” 逐条拆解七条路线，并在最后单列数据/评测这条横切底座。需要实践入口的读者，可先读 Capuano 等人的《Robot Learning: A Tutorial》，它从经典控制、RL 到 ACT 给出了可运行的教学路径 [29]。每条路线都回答五个问题：它的核心假设是什么？技术谱系如何演化？在什么条件下有效？瓶颈在哪里？2024—2026 年发生了什么？路线之间的接口是什么？

5.1 路线 A：模型驱动控制与 TAMP——用模型换可靠性

一句话：把任务分解为符号子目标，把每个子目标交给运动规划/最优控制，用显式模型保证可行性与可解释性。

通用性假设：世界具有可抽象的结构；任务可以被分解为离散的符号状态与连续的几何/动力学约束；只要模型足够准确，规划器就能组合出新的行为。

技术谱系：

- **任务规划**：STRIPS、PDDL、分层任务网络（HTN）、行为树；把 “做什么” 与 “怎么做” 分开。
- **运动规划**：采样式（RRT、PRM）、优化式（CHOMP、TrajOpt）、约束式（CBiRRT）；处理碰撞、关节限位、抓取位姿。
- **TAMP**：约束式、采样式、优化式三条主线；把符号搜索与连续可行性交替求解 [15]。
- **实时控制**：MPC、WBC、阻抗/导纳控制；处理接触、平衡、全身协调。
- **学习增强**：神经可行性分类器、学习型启发式、场景图、LLM 生成任务计划、扩散模型生成技能轨迹 [15][19]。

有效边界：在结构化、已知对象、几何/动力学可建模的场景中，TAMP/MPC 仍然是最可靠的选择。工业装配、物流分拣、实验室自动化、四足/人形全身控制，都大量使用这类方法。它们的优势不是 “智能”，而是**可预测、可验证、可调试**。

瓶颈：

1. **混合离散—连续复杂度**：任务层的组合爆炸与运动层的非凸优化相互耦合，长程任务很难实时求解 [15]。
2. **接触与形变**：接触模式切换、摩擦、碰撞、可变形物体、流体，都是解析模型的深水区；接触密集 操作的可行性判断仍然依赖简化。
3. **不确定性**：真实世界的感知噪声、执行误差、动态障碍，要求鲁棒/随机规划；POMDP 的计算复杂度很高。
4. **符号 grounding**：谓词、物体类别、场景图需要从感知中可靠提取；开放世界的开放词汇 grounding 仍然是弱项。
5. **实时性**：高自由度全身规划 + 接触约束的优化，很难在 50—1000 Hz 的控制频率内完成。
6. **人机协作**：人的意图、运动、社会规范难以写成硬约束；安全与效率的权衡需要在线调整。

2024—2026 最新进展：

- 优化式 TAMP 的综述系统梳理了经典方法与学习方法的接口，指出 LLM/VLM 的计划往往 “语义合理但物理不可行”，空间推理、长程记忆、动态环境仍是短板 [15]。
- LLM + TAMP 成为活跃方向：LLM 负责任务分解和代码生成，TAMP 负责可行性检查；代表工作包括 SayCan、Code as Policies、VoxPoser 等 [58][59][61]。
- 扩散模型开始作为 TAMP 的技能采样器：Diffusion Policy 生成多模态轨迹，TAMP 负责组合和约束 [56]。
- GPU 并行仿真、可微物理、Isaac Lab/ManiSkill3 等基础设施，让 “大规模 RL + 模型控制” 的混合训练变得可行 [52][53]。

接口：TAMP/MPC 是 VLA 和世界模型的 “可靠性底座”。VLA 输出任务意图或子目标，TAMP/MPC 负责可行性、约束和低层执行；世界模型提供预测，MPC 提供闭环校正。没有这个底座，VLA 很难在安全关键场景中部署。

5.2 路线 B：强化学习——用经验换最优性

一句话：让机器人在仿真或现实中试错，用奖励/目标函数优化策略，从经验中找到超越示范的行为。

通用性假设：如果智能体在足够多的任务上交互，并用一个可优化的目标来评价行为，它就能学到可迁移的技能，甚至发现人类没有示范过的解法。

技术谱系：

- 无模型 **RL**：PPO、SAC、TD3、DDPG；适合高维连续控制，但样本效率低。
- 基于模型的 **RL**：Dreamer、TD-MPC2、PlaNet；学习潜空间动力学，在想象中优化策略 [62][63]。
- 离线 **RL**：CQL、IQL、AWAC；从固定数据集中学习，避免在线试错。
- 模仿初始化 **+ RL** 微调：先用示范初始化，再用 RL 提升；这是当前 VLA 后训练的主流。
- **sim2real**：域随机化、系统辨识、域适应、残差学习；把仿真策略迁移到真实机器人 [17][18]。
- 真实世界 **RL**：SERL、HIL-SERL、人类干预、奖励模型；在真实机器人上做样本高效的在线学习。

有效边界：RL 在低层控制、窄域最优性、仿真可并行的场景中最强。四足运动、人形全身控制、灵巧手内操作、无人机竞速、游戏，都是 RL 的成功案例。它擅长 “给定一个明确的目标函数，找到比人类示范更好的策略”。

瓶颈：

1. 样本效率：真实机器人的每次试错都有时间、磨损、安全成本；百万级 episode 在真实世界不可行。
2. 奖励设计：稀疏奖励、长程信用分配、多任务奖励冲突，仍然需要大量人工；VLM 自动奖励是一个有希望的方向，但可靠性不足。
3. 探索：高维连续动作空间的探索很难；不安全探索可能导致硬件损坏或人身伤害。
4. **sim2real**：动力学、传感、执行器延迟、接触参数的差异，会让仿真策略在真实世界失效 [17][18]。
5. 非平稳性：环境、用户、硬件磨损会改变数据分布；离线策略需要持续适应。
6. 安全与可验证性：RL 策略的黑箱性质，使其难以满足安全认证要求。

2024—2026 最新进展：

- DreamerV3 用单一配置在 150 多个任务上超过专用方法，展示了 “通用世界模型 + 想象训练” 的潜力 [62]；TD-MPC2 用 317M 参数的单代理在 80 个任务、多个本体和动作空间上训练，展示了规模 scaling[63]。
- GPU 并行仿真（Isaac Lab、ManiSkill3）把训练吞吐量提高几个数量级，让大规模 RL 和 sim2real 变得实际 [52][53]。
- **RL** 回归机器人基础模型：π*0.6 的 RECAP 用 advantage-conditioned RL 把演示、在线数据、人类纠正结合，在最难任务上吞吐量翻倍、失败率减半 [37]；Learning While Deploying 把车队级离线—在线 RL 作为通用策略的持续后训练框架 [64]。
- VLM 自动生成奖励/课程：LLM 自动生成奖励/课程是活跃方向，可降低 reward engineering 的成本 [14]。

接口：RL 是 VLA 的 “后训练引擎” 和 “低层技能工厂”。VLA 提供语义先验和动作初始化，RL 用真实/仿真经验做精细优化；世界模型提供安全的想象环境，减少真实试错。

5.3 路线 C：模仿/示教/人类数据——用示范换技能

一句话：把人类遥操作、动作捕捉、第一视角视频转化为机器人可学习的轨迹，用行为克隆/扩散策略/动作 chunk 直接学习技能。

通用性假设：人类已经用身体解决了大量物理任务；如果能高效捕获人类示范，机器人就不必从零探索；多样化的示范可以覆盖任务、物体和场景的变化。

技术谱系：

- **任务族框架**：Kroemer 等人把操作学习形式化为 "任务族上的策略/模型学习"，强调对象中心表征、技能前置条件/效果、层级组合 [16]。
- **行为克隆（BC）**：直接学习观测到动作的映射；简单、样本效率高，但有复合误差。
- **逆强化学习/GAIL**：从示范中推断奖励或占用度量；比 BC 更鲁棒，但训练更复杂。
- **扩散/流匹配策略**：用生成模型建模多模态动作分布；Diffusion Policy、π0、RDT-1B 是代表 [56][35][40]。
- **动作 chunk/ACT**：一次预测一段动作，减少复合误差；ALOHA/ACT 用低成本双臂遥操作完成精细任务 [57]。
- **分层模仿**：高层子任务 + 低层技能；处理长程任务。
- **持续模仿**：在新数据上增量学习，避免灾难性遗忘 [10]。
- **人类视频学习**：从 Ego4D/EgoDex 等第一视角视频中提取手—物交互、任务结构、可供性 [25][26][43]。

有效边界：模仿学习在**高质量示范、相对固定的本体、短中程任务**中最有效。它特别适合灵巧操作、双臂协调、精细装配，因为这些任务的探索空间太大，RL 很难从零试错。

瓶颈：

1. **数据成本与覆盖**：真实遥操作数据昂贵；示范往往集中在成功轨迹，缺少失败、恢复、长尾场景 [21]。
2. **复合误差**：策略一旦偏离示范分布，就会进入未见状态，误差随时间累积；DAgger/交互式模仿可以缓解，但需要人类在线纠正。
3. **多模态动作分布**：同一个任务有多种做法，MSE 会平均出 "中间动作"；扩散/流匹配可以缓解，但推理成本高。
4. **人类—机器人差异**：视角、手部形态、关节拓扑、力限、接触动力学都不同；retargeting 只能解决几何映射，解决不了物理差异 [21]。
5. **长程任务**：示范通常是短程技能；如何组合成长程任务，需要分层和记忆。
6. **评测**：真实机器人实验成本高，难以做统计显著的泛化评估。

2024—2026 最新进展：

- Diffusion Policy 用动作扩散处理多模态行为，在 12 个任务上平均提升 46.9%[56]；ACT/ALOHA 用低成本硬件完成精细双臂操作 [57]；RDT-1B 用扩散 Transformer 做双臂基础模型 [40]。
- π0 用流匹配动作专家，把模仿学习扩展到多本体、多任务、灵巧操作 [35]；π0.5 用异构 co-training 实现开放世界家庭任务 [36]。
- 数据侧：Open X-Embodiment 22 种机器人、527 种技能 [32]；DROID 76k 轨迹、564 场景、84 任务 [54]；AgiBot World 100 万 + 轨迹、217 任务 [41]；EgoDex 829 小时人类视频、194 任务 [43]；UMI 让数据采集脱离机器人本体；Mobile ALOHA 用低成本全身遥操作做移动双臂任务 [71]。
- 人类视频从 "辅助数据" 升级为 "结构化先验"：任务意图、可供性、抓取选择、接触顺序可以迁移，具体动作仍需机器人数据 grounding[25][26]。
- **上下文学习/物理提示**：GEN-1.5 用 3—12 秒演示做 one-shot（平均 59%），Skild S1 把新任务拉到 10 分钟（OOD 66% vs 语言 VLA 9%），RoboTTT 把上下文扩展到 8K timesteps[83][84][85]；TwinDEX 用三指 "数采—执行同构" 与数百条无本体数据完成后训练 [96][99]。

接口：模仿学习是 VLA 的 “数据与技能来源”。VLA 用大规模示范预训练，再用 RL/纠正做后训练；世界模型可以生成合成示范，弥补长尾覆盖。

5.4 路线 D：基础模型与 VLA——用语义换泛化

一句话：把视觉–语言预训练模型接到机器人动作上，用语言作为任务接口，用跨本体数据训练通用策略。

通用性假设：互联网级的视觉–语言预训练已经学到了大量物体、属性、关系和常识；语言是人类最自然的任务接口；只要把语义知识接到动作上，机器人就能泛化到新任务、新物体、新指令。

技术谱系：

- 单体 **VLA**：RT-1、RT-2、OpenVLA、Octo；一个模型直接从观测 + 语言预测动作 [30][31][34][33]。
- 双系统 **VLA**：System 2（VLM）负责慢思考，System 1（动作专家）负责快控制；GR00T N1、π0、Gemini Robotics 1.5 采用类似思想 [38][35][39]。
- 分层 **VLA**：高层 planner 输出子任务/关键点/代码，低层 policy 执行；SayCan、Code as Policies、VoxPoser 是早期代表 [58][59][61]。
- 动作 **token** 化：语言描述、代码、可供性、轨迹、目标状态、潜变量、原始动作、推理；不同 token 适合不同层级 [19]。
- 跨本体训练：OXE、DROID、AgiBot World；统一动作空间、本体 token、运动迁移 [32][54][41][39]。
- 后训练：监督微调、RL、人类纠正、偏好学习；π*0.6、LWD 是代表 [37][64]。

有效边界：VLA 在语义泛化、指令跟随、多任务、开放词汇方面明显优于传统策略。它可以把 “未见过的物体/指令” 映射到合理的动作，也可以利用互联网知识做简单推理（如 “拿最小的物体”“拿一个可以当锤子的东西”）。在短中程、桌面级、相对结构化的任务中，VLA 已经展示出可用性。

瓶颈：

1. 物理 **grounding**：语义合理不等于物理可行；VLA 对接触、摩擦、质量、重心、力限的理解很弱 [5][6][22]。
2. 动作表示：离散 token 会损失精度；连续扩散/流匹配更好，但推理成本高；动作频率、action chunk、控制接口不统一 [19]。
3. 跨本体：动作空间、运动学、动力学、传感配置不同；简单混合数据会导致负迁移；Motion Transfer/本体 token 只是初步方案 [39][21]。
4. 数据：真实机器人数据稀缺、昂贵、长尾不足；互联网数据没有动作监督；仿真数据有 sim2real gap[21]。
5. 长程：大多数 VLA 是反应式/短窗；缺少记忆、进度跟踪、失败恢复 [6][22]。
6. 实时性：大模型推理延迟与 50—1000 Hz 控制频率矛盾；双系统/异步推理/量化是缓解，不是根治 [22]。
7. 评测：基准短、少本体、少场景；真实世界泛化难以统计显著 [24][42]。

2024—2026 最新进展：

- RT-2（2023）证明互联网语义可以迁移到机器人动作 [31]；OpenVLA（2024）用 7B 开源模型、970k 演示，超过 RT-2-X 16.5%[34]；π0（2024）用流匹配动作专家，扩展到灵巧操作 [35]。
- π0.5（2025）用多机器人、网络数据、语义子任务 co-training，在全新家庭中完成长程清洁 [36]；π*0.6（2025）用 RECAP 做真实世界 RL 后训练，把吞吐量翻倍、失败率减半 [37]。
- GR00T N1（2025）用双系统架构做人形机器人基础模型 [38]；Gemini Robotics 1.5（2025）用 Motion Transfer 和多级语言推理，提升多本体、多步任务能力 [39]。
- 开源侧：Octo、OpenVLA、RDT-1B、UniVLA、MolmoAct2 等形成生态；UniVLA 用任务中心潜动作统一视频/机器人数据 [70]；闭源侧：Gemini Robotics、GR00T 等推进产品化。

- 2026 年的两个新方向：LingBot-VLA 2.0 用 6 万小时、20 种构型、统一动作空间和 130 ms 推理推进跨本体规模化 [86]；ACoT-VLA 把思维链从语言/视觉搬到动作空间，LIBERO 平均 98.5%[87]。

接口：VLA 是“语义—动作接口”，上游接 LLM/世界模型的任务意图，下游接技能/控制/安全壳。它不能替代 TAMP/MPC，而是为它们提供任务和子目标；它也不能替代世界模型，而是需要世界模型做预测和评估。

5.5 路线 E：世界模型与生成式仿真——用想象换试错

一句话：学习一个动作条件的世界模型，在潜空间/视频空间预测未来，用想象做规划、评估和数据生成。

通用性假设：如果智能体能在行动前预测“如果我这样做，世界会怎样”，就可以用想象替代部分真实试错，进行反事实规划；世界模型还可以生成合成数据，扩展训练分布。

技术谱系：

- **潜空间动力学**：Dreamer、TD-MPC2、PlaNet；用低维潜状态预测未来，在想象中训练策略 [62][63]。
- **视频世界模型**：Sora、Cosmos、Genie；用大规模视频预训练，生成动作条件/文本条件的未来视频 [45][46][47][48]。
- **联合嵌入预测**：V-JEPA 2；在表征空间预测未来，避免像素级生成，提升效率 [44]。
- **3D/4D 世界模型**：占用栅格、神经辐射场、3D 高斯、场景图；强调几何一致性。
- **符号/混合世界模型**：对象、关系、谓词、规则；强调长程组合和可解释性。
- **世界—动作模型（WAM）**：预测与控制联合训练，动作作为条件，未来作为监督；Cosmos 3、MachEmbodied-U0 是代表 [47][69]。

有效边界：世界模型在**模型-based RL**、**数据生成**、**策略评估**、**长程规划**方面有潜力。Dreamer/TD-MPC2 证明了潜空间想象可以提升样本效率；Cosmos/Genie 证明了大规模视频模型可以生成逼真的未来；V-JEPA 2 证明了自监督视频预训练可以支持零样本机器人规划。

瓶颈：

1. **因果条件**：预测的未来可能依赖历史/任务意图，而不是候选动作；这样的模型不能用于控制 [9]。
2. **长程漂移**：自回归预测误差累积，几分钟后可能物理失真；长程一致性仍是难题 [7][9]。
3. **物理保真**：接触、摩擦、形变、流体、多物体交互，视频模型很难准确建模；视觉逼真不等于物理正确 [7][24]。
4. **算力**：高分辨率视频扩散的训练/推理成本很高；实时闭环控制很难承受 [7]。
5. **多模态**：触觉、力、本体感觉的整合不足；视觉主导会忽略接触信息 [9][28]。
6. **评测**：FVD/FID 等视觉指标与下游控制效用相关性弱；缺乏标准化的“动作条件一致性/闭环效用”指标 [24]。

2024—2026 最新进展：

- Cosmos 1（2025-01）把世界基础模型定位为物理 AI 的“数字孪生”[45]；Cosmos-Predict2.5（2025-10）用 2 亿段视频训练 2B/14B 模型，统一 Text2World/Image2World/Video2World[46]；Cosmos 3（2026-06）把语言、图像、视频、音频、动作统一进一个混合 Transformer，直接覆盖世界模拟器和世界—动作模型 [47]。
- Genie 3（2025-08）展示 720p、24fps、几分钟一致性的实时交互世界，但仍是研究预览，存在长程一致性/物理限制 [48]。
- V-JEPA 2（2025-06）用 100 万小时视频 + 62 小时 Droid 机器人视频，后训练出动作条件世界模型，零样本部署到 Franka 做抓放 [44]。

- “世界–动作模型” 成为 2026 年的热词：预测与控制不再分开，而是联合训练；但评测仍滞后于架构创新 [9][24]。
- 2026 年：VLA-JEPA 用 “无泄漏” 潜空间预测做 VLA 预训练 [88]；ABot-PhysWorld 用 14B DiT + 物理 DPO 做动作条件视频世界模型 [89]；ABot-M0.5 把 WAM 扩展到移动操作 [90]。

接口：世界模型是 “预测层”，向上接任务/语言，向下接策略/控制。它可以为 VLA 提供未来监督，为 RL 提供想象环境，为评测提供反事实场景；但它不能替代真实数据，也不能单独保证物理可行性。

5.6 路线 F：本体、灵巧与人形——用身体换环境适配

一句话：设计更接近人类/生物的身体、灵巧手、触觉和柔顺执行器，让机器人能在人类环境中完成物理交互。

通用性假设：智能不是脱离身体的算法；身体的结构、传感和执行能力本身编码了归纳偏置；人形/灵巧手可以复用人类环境、工具和示范。

技术谱系：

- **人形机器人**：人形机器人的功能/非功能规格（外观、认知、感知、行为、交互、组织、控制、泛化）在 Cao 的综述中有系统讨论 [13]；灵巧操作从夹爪到多指手的发展史见 Li 等人的综述 [11]。双足/轮足、全身自由度、人形尺寸；代表 Figure、Unitree、AgiBot、Tesla Optimus、Boston Dynamics Atlas、UBTech Walker。
- **灵巧手**：多指、欠驱动、腱驱动、连杆驱动、直驱；Shadow Hand、Leap Hand、Inspire Hand 等。
- **触觉/力传感**：视触觉（GelSight）、电容/压阻阵列、关节力矩传感器；从指尖扩展到全手/全身。
- **柔顺/软体**：串联弹性执行器、变阻抗、软体手；提高安全性和接触适应性。
- **全身控制**：MPC/WBC/RL；平衡、行走、跑跳、跌倒恢复、移动操作。
- **行为基础模型（BFM）**：在人形运动数据上预训练全身控制器，再微调到下游任务 [12]。

有效边界：人形机器人在**人类环境适配、工具使用、移动操作**方面有独特优势；灵巧手在**精细操作、工具使用、多指协调**方面优于夹爪；触觉在**接触密集、可变形、易碎物体**操作中不可替代。硬件平台也是数据采集、评测和产业试点的载体。

瓶颈：

1. **可靠性**：更多自由度/传感器/执行器意味着更多故障点；Figure 02 在 BMW 的 1,250 小时运行中，前臂电子是首要故障点 [49]。
2. **成本**：灵巧手、触觉皮肤、人形关节的成本仍然很高；大规模部署需要 BOM 和维护成本下降。
3. **触觉**：传感器形态、分辨率、耐久性、标定、标准化都不成熟；触觉数据稀缺 [28]。
4. **控制复杂度**：高自由度、接触丰富、全身协调的控制很难；BFM 仍受 sim2real、数据、本体泛化限制 [12]。
5. **能源/散热**：人形机器人的功率、续航、散热，限制了算力和执行器的选择。
6. **标准化/安全**：人形机器人的安全标准、测试协议、责任边界仍不完善。

2024—2026 最新进展：

- Figure 02 在 BMW Spartanburg 完成 11 个月、每天 10 小时的产线试点：90,000+ 钣金件、1,250+ 小时、30,000+ X3，5 毫米级放置精度、约 200 英里等效步行；Figure 称这是 “从实验室到产线” 的关键一步（公司声明）[49]。
- Unitree 2025 年出货超过 5,500 台人形机器人，AgiBot 到 2026 年 3 月累计生产超过 10,000 台（据媒体报道）[81]。硬件规模化速度超过自主性成熟速度。
- GR00T N1 用人形数据 + 人类视频 + 合成数据训练双系统 VLA[38]；行为基础模型（BFM）用大规模运动数据预训练全身控制，探索 “人形通用控制器”[12]。

- VioLA（2026）从人类数据学习人形全身控制策略 [67]；Whole-body UMI（2026）把 UMI 的便携采集扩展到人形全身操作；这些工作试图缓解 “人形数据稀缺”。

接口：本体是 “物理接口”，决定了动作空间、传感模态、数据采集方式和安全边界。VLA/世界模型/RL 的输出最终都要落到本体的执行器和控制器上；本体的可靠性/成本也反过来决定哪些算法可以部署。

5.7 路线 G：组合/Agent/认知架构——用组合换长程

一句话：把感知、技能、规划、记忆、反思、多智能体组合成一个系统，用语言/代码/结构化表示连接模块，完成单个策略无法完成的长程任务。

通用性假设：单个策略不需要会做所有事；如果能把技能和推理组合起来，系统就能完成远超单个策略的任务；语言/代码提供了可组合的接口。

技术谱系：

- **行为分层**：Subsumption、行为树、状态机；用层次化的反应行为处理动态环境 [74]。
- **选项/分层 RL**：options、skill discovery、hierarchical RL；把技能作为可复用的时间抽象。
- **LLM 任务规划**：SayCan、Inner Monologue、Code as Policies、VoxPoser；用语言/代码分解任务、调用技能、闭环重规划 [58][59][60][61]。
- **记忆/反思**：Voyager、Reflexion、记忆增强 Agent；用经验库、技能库、失败反思提升长程能力 [82]。
- **多智能体**：角色分配、通信、协同操作；处理单人无法完成的任务。
- **VLA Agent**：把 VLA 作为 “感知—动作” 模块，外面套记忆、规划、反思、工具调用；2026 年的一个明显趋势 [19][66]。

有效边界：组合架构在**长程任务、工具使用、人机交互、错误恢复**方面有优势。它可以把一个复杂任务分解为可检查的子任务，把失败归因到某个模块，允许人类用语言插入纠正。对于 “整理房间” “准备早餐”“仓库补货” 这类多步骤任务，组合架构比单一策略更可控。

瓶颈：

1. **接口误差**：任务分解的输出如何变成技能的可执行输入？技能的 precondition/effect 如何被准确估计？一个子任务的失败如何传播？这些接口问题是组合架构的核心难题。
2. **幻觉**：LLM 可能生成不存在的物体、错误的步骤、不可行的计划；需要物理可行性过滤和 grounding。
3. **状态跟踪**：长程任务需要维护世界状态、进度、已完成的子目标；上下文窗口有限，记忆容易丢失。
4. **错误恢复**：失败检测、诊断、重规划需要多模态反馈；现有系统大多把失败当终止事件 [6]。
5. **延迟**：LLM/VLM 的推理延迟与实时控制矛盾；需要快慢系统、异步推理、缓存。
6. **评测**：长程任务的评测很难；成功/失败是稀疏的，中间步骤的贡献难以归因。

2024—2026 最新进展：

- SayCan/Inner Monologue/Code as Policies/VoxPoser 奠定了 “LLM 规划 + 技能调用 + 闭环反馈” 的范式 [58][59][60][61]。
- Gemini Robotics 1.5 把多级语言推理插入动作生成，让机器人 “先思考再行动”，提升多步任务的可解释性 [39]。
- Embodied-R1.5 把规划、指向、纠正统一到一个具身基础模型，用 Planner-Grounder-Corrector 闭环提升物理智能 [66]。
- VLA Agent 成为新方向：在 VLA 外面加记忆、规划、反思、工具调用；但多数工作仍是初步系统，缺少标准化评测 [19]。

- ABot-Claw 把 Agent 做成 “统一本体接口 + 跨本体多模态记忆 + critic 闭环反馈/重规划” 的具身运行时，代表 2026 年 “Agent 系统化” 的方向 [91]。

接口：组合架构是 “ orchestration 层”，把 VLA、世界模型、TAMP/MPC、技能库、人类反馈连接起来。它的成熟度取决于底层模块的可靠性和接口的标准化，而不是 LLM 本身的能力。

5.8 路线 H：数据、仿真与评测基础设施——用经验换规模

一句话：构建大规模、多样化、对齐良好的机器人数据，配套高保真仿真器和能预测真实部署的评测协议，为所有路线提供燃料和标尺。

通用性假设：通用性需要覆盖充分的经验；数据的多样性、对齐质量、物理保真度，比单纯的数据量更重要；评测协议决定了哪些能力会被优化。

技术谱系：

- **真实机器人数据**：RT-1、BridgeData V2、DROID、AgiBot World、RoboMIND；覆盖多任务、多场景、多本体 [30][54][41][55]。
- **跨本体聚合**：Open X-Embodiment；统一格式、动作空间、技能/任务标注 [32]。
- **便携采集**：UMI、DexUMI、Whole-body UMI；脱离机器人本体，保留末端执行器/手部监督。
- **人类视频**：Ego4D、EgoDex、Epic-Kitchens；第一/第三人称视频，提供任务结构、手—物交互、可供性 [43][25]。
- **仿真器**：MuJoCo、Isaac Sim/Lab、SAPIEN、Habitat、AI2-THOR、RoboCasa、BEHAVIOR-1K、ManiSkill3；物理、渲染、传感器、并行化 [50][52][53]。
- **基准**：LIBERO、CALVIN、RLBench、RoboCasa、BEHAVIOR-1K、SimplerEnv、RoboArena；从桌面到长程、从仿真到真实 [51][50][42]。
- **数据引擎**：视频转数据、硬件辅助采集、生成式数据；2026 年的数据综述把它们归为三类 [20]。

有效边界：数据/评测基础设施是 “元能力”。它本身不产生通用性，但决定了其他路线能否规模化、可复现、可比较。没有 OXE，就没有 RT-X/OpenVLA 的跨本体训练；没有 Habitat/BEHAVIOR，就没有具身导航/长程任务的基准；没有 RoboArena，就很难公平比较通用策略。

瓶颈：

1. **保真度—成本权衡**：真实数据最对齐但最贵；仿真最便宜但有 gap；人类视频最丰富但缺动作；通用视觉—语言数据语义强但无物理 grounding[21]。
2. **跨本体对齐**：动作空间、坐标系、控制模式、传感配置不同；统一格式不等于统一语义；几何语义对齐比存储格式更难 [21]。
3. **长尾/失败数据**：大多数数据集只保留成功轨迹；失败、恢复、near-miss 数据稀缺 [21]。
4. **触觉/力数据**：传感器异构、标定复杂、数据格式不统一；触觉仍是 “缺失的接触层”[28]。
5. **基准有效性**：短程、少本体、少场景、二元成功率；与真实部署相关性弱；统计功效不足 [24][42]。
6. **可复现性**：硬件、软件、标定、评测协议差异大；跨实验室复现困难。

2024—2026 最新进展：

- Open X-Embodiment（2023）22 种机器人、21 家机构、527 种技能、160,266 个任务 [32]；DROID（2024）76k 轨迹、350 小时、564 场景、84 任务、50 个实验室 [54]；AgiBot World（2025）100 万 + 轨迹、217 任务、5 类场景 [41]；EgoDex（2025）829 小时、194 任务的人类手部数据 [43]。
- 数据金字塔（2026）把数据分为真实机器人、UMI、ego/exo、仿真、通用五层，用 “可扩展性 vs 机器人对齐” 组织；指出数据配方、动作空间对齐、失败/触觉数据是未来重点 [21]。
- 评测侧：RoboArena 用分布式、双盲、成对比较，在 7 个机构、600+ 个真实回合上评估 7 个通用策略 [42]；BEHAVIOR-1K 提供 1,000 个日常活动、50 个场景、9,000+ 物体 [50]；ManiSkill3 用 GPU 并行把仿真吞吐量提高到 30,000+ FPS[53]。

- 2026 年的 “世界模型评测” 综述指出：世界模型的视觉指标与下游控制效用脱节，需要动作条件一致性、闭环任务效用、物理可执行性等多维指标 [24]。
- 2026 年：ABot-3DGS/PhysWorld 用真实场景重建 + 物理对齐生成训练数据 [89][98]；TwinDEX 用数采—执行同构把无本体数据推到后训练中心 [96][99]；LingBot-VLA 2.0 用 6 万小时/20 构型验证跨本体数据配方 [86]。

接口：数据/评测是所有路线的 “底座”。它决定了 VLA 能学什么、RL 能试什么、世界模型能预测什么、TAMP 能验证什么。没有高质量的数据和评测，任何 “通用性” 声明都不可检验。

6 科学问题树：从总目标到可检验子问题

6.1 如何构造 “好问题”

一个可研究的科学问题，至少要满足四个条件：

1. **可测量**：能用任务成功率、泛化 gap、样本效率、延迟、力误差、干预率等指标度量；
2. **可证伪**：存在能推翻假设的实验设计，而不是 “再做一个 demo”；
3. **预算感知**：明确数据、算力、时间、安全约束，否则 “通用” 没有工程含义；
4. **分布明确**：说清楚在哪个任务/环境/本体分布上泛化，避免用 “开放世界” 掩盖评测集的狭窄。

据此，本报告把总目标 Q0 分解为六个一级分支、31 个可检验问题。图 2 是总览，以下逐分支展开。

6.2 Q1 感知与表征：机器如何形成 “可行动” 的世界表征?

感知的目的不是 “识别物体”，而是**为行动提供足够的信息**：物体在哪里、能不能抓、抓了会怎样、需要多少力、会不会滑。传统 2D 视觉擅长语义，缺少几何、接触和不确定性；3D/4D 感知擅长几何，缺少开放语义；触觉擅长接触，缺少全局上下文。Q1 的核心是**多模态、跨本体、带不确定性的可行动表征**。

Q1.1 如何构建支持规划的 4D 场景表征，并维持对象永久性?

- **为什么难**：遮挡、动态、多视角、传感器噪声；2D VLM 缺少深度/占用；3D 重建在线成本高
- **近期子任务**：4D 场景图、开放词汇 3D 分割、占用/光流、记忆融合
- **可检验指标**：深度/位姿误差、占用 IoU、遮挡恢复成功率、下游任务成功率

Q1.2 如何表征可操作的物理属性（可供性、摩擦、质量、形变)?

- **为什么难**：视觉只能间接推断；接触是潜变量且不连续；材料/表面属性难以标注
- **近期子任务**：交互式感知、触觉增强可供性、物理参数估计、视觉–触觉融合
- **可检验指标**：接触预测准确率、抓取成功率、力跟踪误差、材料分类

Q1.3 如何让触觉/力/本体感觉成为一等模态?

- **为什么难**：传感器异构、稀疏、高频；视觉主导融合；缺少标准化数据
- **近期子任务**：统一触觉表征、事件式触觉、滑移检测、力感知策略
- **可检验指标**：滑移检测延迟、力跟踪误差、跨传感器迁移、接触密集 任务成功率

Q1.4 如何量化并利用不确定性进行主动感知?

- **为什么难**：OOD 检测、校准、信息增益计算都很难；探索有成本/安全风险
- **近期子任务**：保形预测、贝叶斯最后层、主动视角规划、OOD 检测
- **可检验指标**：ECE、AUROC、每次动作的信息增益、失败预测率

Q1.5 如何实现跨本体的感知/表征对齐?

- **为什么难**：相机位置、视野、运动学、传感器套件不同；同一场景的观测分布不同
- **近期子任务**：规范空间坐标系、本体 token、形态条件编码器、跨本体预训练
- **可检验指标**：零/少样本迁移成功率、表征相似度、下游任务 gap

这一分支的关键判断：感知的瓶颈已经从 “语义识别” 转向 “物理属性 + 不确定性 + 跨本体对齐”。未来的感知系统不会是一个静态的 3D 重建器，而是一个**主动的、多模态的、任务驱动的表征系统**：它知道什么时候该看、该摸、该问，以及自己的表征有多不确定。

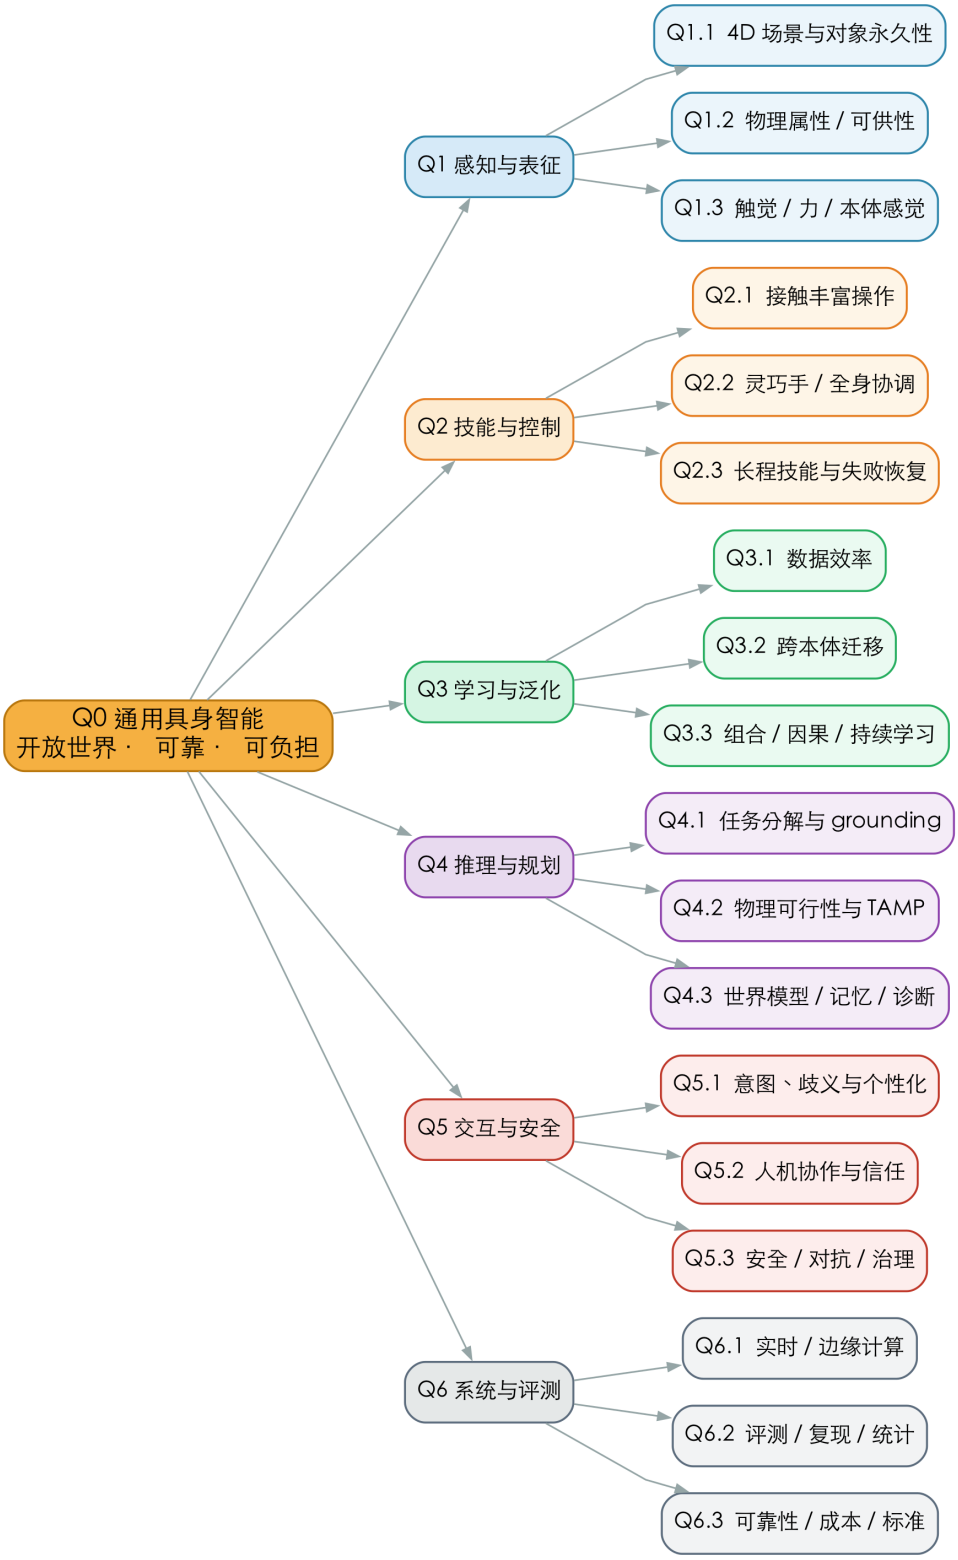


图 2 具身智能科学问题树

6.3 Q2 技能与控制：机器如何获得灵巧、可靠、可复用的物理技能?

技能是 “把意图变成物理动作” 的层。它面对的是高维、接触丰富、欠驱动、非线性的控制问题。Q2 的核心是**在接触模式切换、长程执行和实时约束下，保持稳定、精确、可恢复**。

Q2.1 如何在接触模式切换下学习稳定操作?

- **为什么难**：混合动力学、摩擦、碰撞、形变；小状态变化会翻转接触模式
- **近期子任务**：接触感知模型、可微物理、残差 RL、触觉反馈、柔顺控制
- **可检验指标**：插入成功率/公差、力超限率、恢复率、接触状态估计误差

Q2.2 如何实现人类级灵巧手内操作?

- **为什么难**：高自由度、欠驱动、触觉遮挡、数据稀缺；仿真接触不准
- **近期子任务**：灵巧遥操作、仿真 RL、人类视频 retargeting、触觉手套、手内操作基准
- **可检验指标**：物体重定向成功率、掉落率、任务时间、跨物体泛化

Q2.3 如何统一移动与操作的全身控制?

- **为什么难**：全身动力学、接触规划、平衡、高自由度；传统上分开处理
- **近期子任务**：全身 MPC/RL、行为基础模型、移动操作基准、人形数据、身体/手部潜先验（CoorDex）、任意关键点全身控制（AnyBody）
- **可检验指标**：平衡裕度、任务成功率、能耗、扰动恢复时间

Q2.4 如何让长程技能链可靠?

- **为什么难**：复合误差、终止条件、资源约束、状态跟踪；失败会传播
- **近期子任务**：分层策略、options、进度监控、恢复策略、记忆
- **可检验指标**：成功率随时间跨度的衰减、干预率、恢复成功率、完成时间

Q2.5 如何满足实时/安全约束?

- **为什么难**：VLA 延迟 100ms−1s，控制需 50−1000Hz；安全壳增加开销
- **近期子任务**：双系统/异步推理、动作 chunk、边缘量化、CBF/MPC 安全层
- **可检验指标**：端到端延迟、抖动、约束违反率、延迟下的任务成功率

这一分支的关键判断：技能层的核心矛盾是 “精度/实时性” 与 “泛化/语义” 的权衡。VLA 可以提供语义和粗动作，但不能替代低层控制；RL/MPC 可以提供精度和稳定性，但不能自动获得开放世界语义。未来的技能层大概率是**分层、多频率、带安全壳的混合架构**。

6.4 Q3 学习与泛化：如何从有限、异构、带噪的经验中高效学习并持续泛化?

学习是 “从经验中提取可复用结构” 的层。它面对的是数据稀缺、分布偏移、任务异构、本体异构、非平稳等挑战。Q3 的核心是**在有限预算下，获得可迁移、可组合、可持续的学习机制**。

Q3.1 如何用有限数据获得可泛化技能?

- **为什么难**：机器人数据稀缺；互联网数据无动作；仿真有 gap；示范覆盖有限
- **近期子任务**：人类视频、UMI、数据增强、世界模型、自监督预训练、数据配比、视频演示上下文学习（GEN-1.5/S1/RoboTTT）
- **可检验指标**：成功率 vs 示范数、迁移曲线、数据 scaling 曲线

Q3.2 如何实现跨本体策略迁移?

- **为什么难**：动作空间、运动学、动力学、传感不同；简单混合会负迁移
- **近期子任务**：统一动作空间、本体 token、retargeting、模块化适配、元学习

- 可检验指标：零/少样本迁移、负迁移率、适配速度

Q3.3 如何实现组合/因果泛化?

- 为什么难：模型容易学伪相关；基准容易饱和；反事实数据难采
- 近期子任务：组合基准、反事实数据、因果世界模型、对象中心表征
- 可检验指标：新组合成功率、反事实准确率、因果干预测试

Q3.4 如何持续学习而不遗忘?

- 为什么难：非平稳世界、部署数据、灾难性遗忘、安全约束
- 近期子任务：回放、弹性权重巩固、LoRA 适配、车队学习、离线—在线 RL
- 可检验指标：后向迁移、遗忘率、前向迁移、部署性能提升

Q3.5 如何从模仿走向经验学习?

- 为什么难：模仿有上限、示范次优、缺少恢复；RL 样本成本/安全
- 近期子任务：RL 微调、advantage conditioning、人类纠正、VLM 奖励、世界模型 RL、上下文学习/物理提示
- 可检验指标：吞吐量、失败率下降、样本成本、安全违规

Q3.6 如何跨越 **sim-to-real**?

- 为什么难：物理、渲染、传感、执行器差异；域随机化有上限
- 近期子任务：系统辨识、可微物理、real2sim、域适应、数字孪生
- 可检验指标：迁移 gap、真实成功率、扰动鲁棒性

这一分支的关键判断：学习的瓶颈不是 “模型不够大”，而是 “数据分布不够对”。跨本体、组合、持续、sim2real 本质上都是**分布对齐**问题：把不同来源的经验映射到共享的表征/动作空间，同时保留物理意义。谁能把这件事做好，谁就能把 “数据规模” 转化为 “泛化能力”。

6.5 Q4 推理与规划：如何把语义意图转化为物理可行的长程行动?

推理与规划是 “把任务变成步骤、把步骤变成动作” 的层。它面对的是语义歧义、物理可行性、长程依赖、失败恢复。Q4 的核心是**语义—物理的双向 grounding**：语言要落到物体/可供性/动作上，物理反馈要回到任务状态/计划上。

Q4.1 如何把语言意图分解为可执行子任务?

- 为什么难：歧义、指代、能力边界、长程依赖；LLM 容易生成抽象/错误计划
- 近期子任务：LLM 规划、code-as-policy、可供性 grounding、能力模型、重规划、动作思维链（ACoT-VLA）
- 可检验指标：计划有效率、可执行率、人工评分、重规划成功率

Q4.2 如何保证计划的物理可行性?

- 为什么难：LLM 计划抽象；TAMP 组合爆炸；接触可行性难判
- 近期子任务：TAMP、学习型可行性分类器、运动规划、约束检查、场景图
- 可检验指标：碰撞率、不可行计划率、规划时间、任务成功率

Q4.3 如何用世界模型进行反事实规划?

- 为什么难：动作条件因果、长程漂移、算力；视觉逼真 ≠ 控制有用
- 近期子任务：动作条件视频/潜模型、想象 MPC、不确定性 rollout、符号混合、潜空间世界模型（VLA-JEPA）、物理对齐视频世界模型（ABot-PhysWorld）
- 可检验指标：动作敏感性、rollout 一致性、控制效用、规划延迟

Q4.4 如何维持长程记忆与状态?

- **为什么难**：上下文有限、部分可观测、进度跟踪；记忆容易污染
- **近期子任务**：情景记忆、场景图、潜记忆、摘要/检索、状态估计
- **可检验指标**：记忆召回率、进度准确率、长程成功率

Q4.5 如何检测、诊断、恢复失败?

- **为什么难**：失败异构、标注稀缺、恢复数据少；失败会级联
- **近期子任务**：失败数据集、异常检测、VLM 诊断、恢复策略、运行时监控
- **可检验指标**：检测延迟、诊断准确率、恢复成功率、停机时间

这一分支的关键判断：规划的未来不是 "LLM 直接输出动作"，而是 "LLM/世界模型提出候选，物理可行性层过滤，执行层监控，失败层重规划" 的闭环。**推理的价值在于缩小搜索空间，而不是替代物理验证。**

6.6 Q5 交互与安全：机器如何理解人类意图并在共享空间中安全行动?

交互与安全是 "机器与人/社会" 的接口。它面对的是意图歧义、人类不可预测、社会规范、对抗攻击、安全认证。Q5 的核心是**在开放、动态、有人类的环境中，保持可预测、可纠正、可验证的行为**。

Q5.1 如何 grounding 模糊/个性化的人类意图?

- **为什么难**：语言歧义、指代、用户偏好、上下文；不同用户有不同规范
- **近期子任务**：对话澄清、个性化偏好、共享表征、心智理论
- **可检验指标**：意图满足率、澄清率、用户信任

Q5.2 如何实现安全、流畅的人机协作?

- **为什么难**：人类不可预测、安全/效率权衡、可读性、交接
- **近期子任务**：人体运动预测、共享控制、阻抗/导纳、可读运动、信任校准
- **可检验指标**：碰撞率、流畅度、交接成功率、信任评分

Q5.3 如何为学习型机器人提供可验证的安全保证?

- **为什么难**：黑箱策略、开放世界、形式方法不可扩展
- **近期子任务**：CBF、可达性分析、运行时保证、保形预测、屏蔽层
- **可检验指标**：约束违反率、认证覆盖率、干预率

Q5.4 如何抵御对抗/后门/记忆投毒?

- **为什么难**：多模态攻击面、物理攻击、Agent 记忆
- **近期子任务**：对抗训练、认证防御、输入净化、记忆完整性、红队测试
- **可检验指标**：攻击成功率、认证鲁棒性、检测率

Q5.5 如何符合社会规范与隐私要求?

- **为什么难**：规范随上下文变化；隐私、同意、责任
- **近期子任务**：社会导航、偏好学习、隐私保护学习、治理框架
- **可检验指标**：规范遵守率、隐私泄漏、用户接受度

这一分支的关键判断：安全不是 "加一个过滤器"，而是**分层保证**：策略层做风险感知，控制层做约束满足，系统层做运行时监控，组织层做认证/治理。学习型策略越强，越需要可验证的安全壳；否则能力越强，风险越大。

6.7 Q6 系统与评测：如何构建可部署、可比较、可复现的通用机器人系统?

系统与评测是 “把能力变成产品/知识” 的层。它面对的是实时性、可靠性、成本、数据基础设施、评测有效性。Q6 的核心是**让通用性可测量、可复现、可负担**。

Q6.1 如何满足边缘实时计算?

- **为什么难**：模型大小 vs 延迟/功耗/散热；云端依赖
- **近期子任务**：量化、蒸馏、早退、异步推理、软硬协同
- **可检验指标**：延迟、吞吐、每任务能耗、精度损失

Q6.2 如何保证长期可靠性?

- **为什么难**：MTBF、磨损、传感器漂移、软件更新
- **近期子任务**：故障预测、冗余、失效安全、远程干预、OTA
- **可检验指标**：MTBF、正常运行时间、干预率、恢复时间

Q6.3 如何建立跨本体的数据基础设施?

- **为什么难**：格式、元数据、对齐、许可；统一格式 ≠ 统一语义
- **近期子任务**：统一 schema、动作规范化、标定元数据、版本管理
- **可检验指标**：对齐误差、复用率、跨实验室复现

Q6.4 如何评测通用性?

- **为什么难**：基准过拟合、sim-real gap、任务选择偏差、统计功效不足
- **近期子任务**：留出任务集、多轴 OOD、分布式真实评测、预注册、置信区间
- **可检验指标**：泛化 gap、与部署排名的相关性、统计功效

Q6.5 如何评估成本/标准/治理?

- **为什么难**：ROI、安全认证、责任边界
- **近期子任务**：成本建模、ISO 标准、审计轨迹、保险
- **可检验指标**：每任务成本、认证周期、事故率

这一分支的关键判断：评测不是 “最后一步”，而是 “第一性设计”。你选择什么基准，就会优化什么能力；你忽略什么轴，系统就会在什么轴上失败。**通用性评测必须多轴、长程、真实、统计显著，否则只是另一种过拟合。**

6.8 优先级：哪些问题最 “卡脖子”?

把 31 个问题按 “影响 × 难度” 放入二维矩阵，可以得到一个粗略的优先级判断。这里的 “影响” 指对 G3→G4/G5 的瓶颈作用，“难度” 指未来 3–5 年能否取得实质进展。

	低难度	高难度
高影响	数据/动作空间对齐、失败/恢复数据、评测协议、边缘推理、安全壳工程	接触密集 灵巧操作、跨本体迁移、因果世界模型、长程记忆、形式化安全验证
低影响	又一个短程基准、轻微架构变体、单任务 SOTA	通用人形 AGI、通用物理模拟器、完全自主开放世界

这个矩阵不是绝对判断，而是一个资源分配建议：

- **近期（1—2 年）**：优先做 “高影响、低难度” 的基础设施——数据对齐、失败数据、评测协议、边缘推理、安全壳。这些工作不一定 “炫”，但会显著降低整个领域的摩擦。
- **中期（3—5 年）**：集中攻 “高影响、高难度” 的科学问题——接触密集 操作、跨本体、世界模型因果性、长程记忆、安全验证。这些是 G4/G5 的关键。
- **长期（5—10 年）**：通用人形、通用物理模拟器、完全自主开放世界。这些是愿景，不适合作为近期考核指标。

7 路线比较与系统集成

7.1 七条路线与底座的对比

以下按路线比较七条路线与数据/评测底座。需要强调：这里的 “成熟度” 是作者基于公开证据的评估，不是统一的 TRL 评分；“最擅长” 也只是相对优势，不意味着其他路线做不到。

A 模型/控制/TAMP

- 通用性来源 / 最擅长：可组合的物理模型/约束；结构化环境、安全关键、长程规划、可解释
- 结构性短板：开放世界建模、接触/形变、感知 grounding、实时性
- 代表系统 / 成熟度：优化式 TAMP、MPC、WBC；工业高；开放世界中低

B 强化学习

- 通用性来源 / 最擅长：自主交互/奖励优化；运动、灵巧控制、窄域最优性、仿真可并行
- 结构性短板：样本效率、奖励、sim2real、安全、非平稳
- 代表系统 / 成熟度：DreamerV3、TD-MPC2、π*0.6、LWD；窄域中高；开放世界低

C 模仿/示教

- 通用性来源 / 最擅长：人类示范/文化传递；灵巧操作、双臂、精细任务、快速技能获取
- 结构性短板：数据成本/覆盖、复合误差、本体差异、长程
- 代表系统 / 成熟度：ACT/ALOHA、Diffusion Policy、RDT-1B、π0；实验室中高；部署中

D 基础模型/VLA

- 通用性来源 / 最擅长：互联网语义 + 语言接口；语义泛化、指令跟随、多任务、开放词汇
- 结构性短板：物理 grounding、动作表示、跨本体、延迟、长程
- 代表系统 / 成熟度：RT-2、OpenVLA、π0.5、GR00T N1、Gemini 1.5；早期部署；G3—G4

E 世界模型

- 通用性来源 / 最擅长：预测/想象/反事实；规划、数据生成、策略评估、长程预测
- 结构性短板：因果条件、长程漂移、物理保真、算力、评测
- 代表系统 / 成熟度：Dreamer、TD-MPC2、V-JEPA 2、Cosmos 3、Genie 3；研究中；工具化早期

F 本体/灵巧/人形

- 通用性来源 / 最擅长：身体/形态/传感；人类环境适配、接触感知、工具使用
- 结构性短板：可靠性、成本、触觉、能耗、控制复杂度
- 代表系统 / 成熟度：Figure 02、Unitree、AgiBot、GR00T、BFM；硬件中；自主性低

G 组合/Agent

- 通用性来源 / 最擅长：技能/推理的组合；长程任务、工具使用、HRI、错误恢复
- 结构性短板：接口误差、幻觉、状态跟踪、延迟、评测
- 代表系统 / 成熟度：SayCan、Inner Monologue、VoxPoser、Gemini 思考、Embodied-R1.5；系统研究中低

H 数据/评测

- 通用性来源 / 最擅长：覆盖充分、对齐良好的经验；规模、复现、跨本体数据、比较
- 结构性短板：保真度—成本、对齐、基准有效性、长尾
- 代表系统 / 成熟度：OXE、DROID、AgiBot World、EgoDex、RoboArena；基础设施中；快速建设中

这张表最重要的不是 “谁高谁低”，而是**互补性**：

- A 提供可靠性和可验证性，但缺少开放语义；
- B 提供超越示范的最优性，但缺少安全和样本效率；
- C 提供技能和自然性，但缺少覆盖和本体泛化；
- D 提供语义和任务泛化，但缺少物理 grounding；
- E 提供预测和想象，但缺少因果和评测；
- F 提供身体和环境适配，但缺少自主性；
- G 提供长程和组合，但缺少接口可靠性；
- H 提供规模和比较，但不直接产生能力。

任何一条路线单独走向通用性，都会撞上自己的结构性短板。这就是为什么 2023 年之后的系统越来越像 “混合体”：VLA + RL、VLA + 世界模型、VLA + TAMP、人形 + BFM + VLA、Agent + 技能库。

7.2 通用性技术栈：五层闭环

图 3 把系统分成五层，每层有不同的时间尺度和接口：

- **L5 任务与 Agent（0.1—1 Hz）**：核心问题：做什么、为什么、下一步；代表方法：LLM/VLM、记忆、任务分解、反思；失败模式：幻觉、错误分解、状态丢失。
- **L4 世界模型（1—10 Hz）**：核心问题：如果我这样做，会发生什么；代表方法：视频/潜空间/3D 世界模型、反事实；失败模式：因果错误、长程漂移、物理失真。
- **L3 通用策略（1—50 Hz）**：核心问题：看到/听到什么，应该做什么动作；代表方法：VLA、扩散/流匹配、动作 chunk；失败模式：物理 grounding 弱、跨本体差、延迟。
- **L2 技能与控制（50—1000 Hz）**：核心问题：如何稳定、精确、安全地执行；代表方法：RL、MPC、WBC、阻抗控制、安全壳；失败模式：接触失败、约束违反、抖动。
- **L1 本体与传感（硬件）**：核心问题：身体能感知/执行什么；代表方法：人形、灵巧手、触觉、执行器；失败模式：故障、磨损、噪声、成本。

这个栈的核心思想是**频率分层**：不同层以不同频率运行，通过接口交换 “任务意图/预测/动作/状态”。通用性不是某一层 “什么都会”，而是**各层在自己的频率上可靠工作，接口不丢失关键信息**。

7.3 五个接口：系统集成的真正瓶颈

多层架构的难点不在单层，而在接口。以下五个接口是当前系统集成最容易被低估的地方。

接口一：任务接口（语言/目标 → 子任务）

L5 输出的是自然语言/代码/目标状态，L4/L3 需要的是可执行的子任务、约束、动作空间。接口问题包括：子任务粒度是否合适？前置条件/效果是否被准确描述？失败如何回传？能力边界如何表达？

SayCan 用价值函数做 “能不能做” 的过滤 [58]；Code as Policies 用代码把感知 API 和技能组合起来 [59]；VoxPoser 用 3D 价值图把语言映射到空间 [61]。这些方法都在解决同一个问题：**把语言的 “意图” 变成物理的 “可执行”**。

2026 年，任务接口不再只有语言：GEN-1.5 和 Skild S1 用视频演示作为 prompt，ACoT-VLA 用粗粒度动作草图作为中间表示，目标图像、代码、关键点也都是可选的接口 [83][84][87]。这意味着 “任务接口” 本身正在成为一个独立的研究对象：不同接口的粒度、歧义、数据效率和可验证性不同，不能再用 “语言指令” 一把尺子量所有系统。



图 3 通用性技术栈：五层闭环与跨层底座

接口二：动作接口（语义动作 → 关节/力矩）

VLA 输出的是末端位姿、动作 chunk、离散 token 或潜动作；L2 需要的是关节位置/速度/力矩、阻抗参数、抓取力。接口问题包括：动作空间是否统一？频率是否匹配？坐标系是否一致？动作 chunk 多长？如何处理延迟？

RT-2 把动作表示为文本 token[31]；π0 用流匹配生成连续动作 [35]；GR00T N1 用双系统把慢思考与快动作分开 [38]。这些方案都在解决 "语义—动作" 的表示问题，但没有解决 "跨本体动作语义" 的问题。

接口三：状态接口（感知/预测 → 任务状态）

L3/L4 需要知道 "任务进行到哪一步、物体状态如何、是否失败"；L1/L2 提供的是关节状态、触觉、力、图像。接口问题包括：状态表征是否任务相关？不确定性是否传递？记忆是否更新？失败信号是否可检测？

Inner Monologue 用语言反馈把成功/失败/物体信息回传给 LLM[60]；RoboArena 用真实 episode 的成对比较评估策略 [42]；世界模型综述强调 "状态级理解" 比像素生成更重要 [7]。这些工作说明：**状态接口的核心不是 "更多传感器"，而是 "任务相关的抽象"**。

接口四：数据接口（多源数据 → 可训练经验）

真实机器人、UMI、人类视频、仿真、通用视觉—语言数据的格式、动作空间、坐标系、频率、标注都不同。接口问题包括：如何对齐动作语义？如何保留物理意义？如何处理缺失模态？如何配比数据？

Open X-Embodiment 用统一格式聚合 22 种机器人 [32]；Data Pyramid 用 "可扩展性 vs 机器人对齐" 组织五层数据 [21]；DROID 用标准化采集管线保证跨场景一致性 [54]。这些工作说明：**数据接口的核心不是 "存得下"，而是 "对得齐"**。

接口五：安全接口（学习策略 → 可验证行为）

学习策略输出的是 "概率上合理的动作"，安全层需要的是 "约束满足、可解释、可干预"。接口问题包括：如何把安全约束传递给策略？如何检测 OOD？如何做运行时监控？如何形式化验证？

CBF/可达性分析、保形预测、运行时保证、屏蔽层，都是安全接口的技术 [22][23]。但当前的安全壳大多是 "外挂式" 的：策略不知道安全层的存在，安全层只能在动作输出后拦截。**未来的安全接口需要 "策略—安全层联合设计"**，让策略在训练时就考虑约束，而不是事后修补。

7.4 八个争论

领域内有八个反复出现的争论。它们不是 "谁对谁错"，而是不同假设下的权衡。

争论一：单体 VLA vs 分层系统

单体派认为：端到端的大模型可以隐式学习物理，分层会引入接口误差和工程复杂度。**分层派认为**：长程任务、安全约束、可解释性需要显式分解；单体模型难以调试和验证。

当前证据：单体 VLA 在短中程、语义泛化上强；分层系统在长程、安全关键、工具使用上更可靠。2025—2026 年的趋势是 "单体 + 分层" 的混合：VLA 作为底层策略，外面套 planner/memory/safety shell[6][22]。

争论二：显式世界模型 vs 隐式 scaling

显式派认为：没有世界模型，VLA 只能学表面相关，无法反事实推理，容易在 OOD 中幻觉。**隐式派认为**：大模型 + 大数据可以隐式内化物理，显式世界模型计算成本太高、评测太难。

当前证据：世界模型在模型-based RL、数据生成、规划上有明确价值；但 "显式世界模型是否比纯 scaling 更有效" 仍缺乏公平的大规模对比。2026 年的世界模型评测综述指出，现有基准无法回答 "世界模型是否真的让机器人更好"[24]。这是一个开放的科学问题，不是已解决的工程选择。

争论三：仿真数据 vs 真实数据

仿真派认为：仿真可扩展、可并行、有特权信息，是解决数据稀缺的唯一途径。**真实派认为**：sim2real gap 太大，真实数据的多样性/物理保真度不可替代。

当前证据：仿真在低层控制、locomotion、灵巧手方面成功；真实数据在开放场景、接触密集、长尾方面不可替代。最实际的方案是 "仿真预训练 + 真实后训练 + 世界模型增强"，而不是二选一 [17][18][21]。

争论四：人形 vs 专用形态

人形派认为：人类环境是按人的形态设计的，人形可以复用工具、门、楼梯、工位，是通用性的最佳载体。**专用派认为**：通用性不等于人形；专用机器人（轮式、四足、机械臂）在特定任务上更高效、更可靠、更便宜。

当前证据：人形在人类环境适配上有优势，但在结构化工厂，专用机械臂可能更优。通用性是 "任务分布 + 环境分布" 的函数，不是 "形态" 的函数。人形是重要载体，但不是充分条件。

争论五：模仿 vs 强化

模仿派认为：人类示范提供了最直接的技能监督，样本效率高；RL 的奖励设计和安全问题太难。**RL 派认为**：模仿有上限，无法超越示范，也无法学习恢复；RL 可以从经验中自我改进。

当前证据：模仿是当前 VLA 的主要训练方式；RL 是后训练/精细化的关键。π*0.6 的 RECAP 证明两者可以结合：先用示范预训练，再用 RL + 人类纠正提升 [37]。未来的主流是 "模仿预训练 + RL 后训练"，而不是二选一。

争论六：端到端 vs 模块化

端到端派认为：模块化会丢失信息、引入接口误差；端到端可以联合优化。**模块化派认为**：端到端难以调试、验证、复用；模块化可以替换/升级单个组件。

当前证据：端到端在感知—动作映射上强；模块化在安全、长程、工程化上强。两者不是架构 vs 优化的对立：一个系统可以 "模块化架构 + 端到端训练"，也可以是 "端到端主干 + 模块化安全壳"[4][22]。

争论七：开源 vs 闭源

开源派认为：开源模型/数据/基准可以加速复现、降低门槛、形成社区。**闭源派认为**：大规模机器人数据/算力/安全测试是竞争壁垒，闭源可以更快迭代。

当前证据：开源生态（Octo、OpenVLA、RDT、LeRobot）显著降低了研究门槛；闭源系统（Gemini Robotics、GR00T 等）在数据/硬件/部署上有优势。未来的格局可能是 "开源基础模型 + 闭源数据/部署服务" 的混合。

争论八：基准 vs 真实部署

基准派认为：没有标准化基准，就无法比较、复现、积累知识。**部署派认为**：基准容易过拟合，真实部署才是唯一标准。

当前证据：两者都重要，但当前基准与部署的相关性弱。RoboArena 用分布式真实评测试图填补这个缺口 [42]；2026 年的评测综述呼吁 “功能感知” 的指标，而不是只看视觉保真或二元成功率 [24]。未来的评测应该是 “基准筛选项 + 真实部署验证” 的组合。

7.5 什么才是 “通用” 的系统答案?

综合以上分析，本报告给出一个系统答案：

> **通用具身智能 = 多来源先验的覆盖度 × 分层系统的组合能力 × 部署数据闭环的适应速度 ÷ 任务/环境/本体的分布偏移 × 安全/成本的约束。**

这个公式不是数学定理，而是一个思考框架。它意味着：

1. **覆盖度**：数据/语义/物理先验要覆盖任务分布的关键轴；
2. **组合能力**：系统能把技能、预测、推理、控制组合起来，而不是依赖单个策略；
3. **适应速度**：能从部署数据中持续学习，而不是一次性训练；
4. **分布偏移**：通用性总是相对于某个分布；分布越宽，难度越大；
5. **安全/成本**：没有安全/成本约束的 “通用” 不是工程上的通用。

因此，下一阶段的竞争不是 “谁的模型更大”，而是 “谁的系统能更快地把部署数据转化为可靠能力”。这也是第 8 章最新进展和第 10 章研究议程的主线。

8 2024—2026 最新进展

8.1 一条时间线

下表列出 2022—2026 年最具代表性的系统与事件。它不是 “最强模型榜”，而是 “改变研究重心” 的节点。

时间 / 成果	关键主张	意义	证据
2022-12 / RT-1	大规模真实数据 + Transformer，展示数据/模型/多样性 scaling	开启 “机器人 Transformer” 路线	A
2023-07 / RT-2	动作作为文本 token，互联网语义迁移到机器人	第一次让 VLM 知识大规模进入控制	A
2023-10 / Open X-Embodiment	22 种机器人、21 家机构、527 技能、160,266 任务	跨本体数据聚合的里程碑	A
2024-05 / Octo	800k 轨迹，支持多种传感器/动作空间	开源通用策略的基线	A/B
2024-06 / OpenVLA	7B、970k 演示，超过 RT-2-X 16.5%	开源 VLA 生态的起点	A
2024-10 / π0	多本体、灵巧操作、动作专家	连续动作生成的范式转变	B
2024-10 / RDT-1B	统一动作空间、双臂操作	双臂/扩散路线代表	B
2025-03 / AgiBot World	100 万 + 轨迹、217 任务、5 类场景	真实数据规模的量级提升	B
2025-03 / GR00T N1	双系统、人形基础模型、真实 GR-1 部署	人形通用控制的主干	B
2025-04 / π0.5	异构 co-training，全新家庭长程任务	开放世界泛化的标志	B
2025-05 / EgoDex	829 小时、194 任务、3D 手部追踪	人类视频规模化	B
2025-06 / V-JEPA 2	100 万小时视频 + 62 小时机器人视频，零样本 Franka	自监督世界模型的可行性	B
2025-06 / RoboArena	7 机构、600+ 个真实回合、7 策略	分布式真实世界评测	B
2025-10 / Gemini Robotics 1.5	Motion Transfer、多级语言推理	多本体 + 思考式控制	B
2025-11 / π*0.6	RECAP，最难任务吞吐翻倍、失败率减半	部署中学习的标志	B
2026-05 / Learning While Deploying	离线—在线持续后训练	把 “部署” 变成学习闭环	B
2026-06 / Cosmos 3	语言/图像/视频/音频/动作统一	世界模型与策略融合	B

时间 / 成果	关键主张	意义	证据
2026-09 / MachEmbodied-U0	理解/生成专家 + MoT	统一理解与生成的尝试	B
2026-10 / VioLA	从人类数据学习全身控制	人形数据瓶颈的突破尝试	B
2025 / Figure 02 @ BMW	11 个月、90k+ 件、1,250+ 小时、30k+ X3	人形产线试点的最佳证据	C

8.2 VLA 的规模化与跨本体

2023—2026 年，VLA 经历了三代架构演进。

第一代：离散动作 token。RT-2 把动作离散化为文本 token，与视觉—语言数据联合微调 [31]。优点是可以直接复用 LLM 的解码器；缺点是连续动作精度损失、推理慢、动作频率低。

第二代：连续动作专家。π0 用流匹配（flow matching）生成连续动作，RDT-1B 用扩散 Transformer 处理双臂多模态动作 [35][40]。优点是动作平滑、多模态、精度高；缺点是推理成本高，需要动作 chunk/异步推理。

第三代：双系统/分层。GR00T N1 用 System 2（VLM）做慢思考、System 1（扩散 Transformer）做快控制 [38]；Gemini Robotics 1.5 用 Motion Transfer 和多级语言推理，把 "思考" 插入动作生成 [39]。优点是兼顾语义和实时性；缺点是系统复杂、接口多、训练难度大。

开源侧还在探索更可部署的动作推理模型：MolmoAct2（2026）强调开放、低延迟、可部署的动作推理 [65]；CLIFT（2026）探索闭源 Gemini Robotics 在设备端的闭环微调 [68]。跨本体是 VLA 规模化的核心难题。Open X-Embodiment 用 22 种机器人、527 种技能、160,266 个任务证明 "跨机器人正迁移" 是可能的 [32]；OpenVLA 用 970k 演示训练 7B 模型，超过 RT-2-X 16.5%[34]；GR00T N1 用人形数据 + 人类视频 + 合成数据训练人形基础模型 [38]；Gemini Robotics 1.5 用 Motion Transfer 从异构多本体数据学习 [39]。

但跨本体仍然没有 "通用解"。当前的做法可以归为四类：

1. **统一动作空间**：把不同机器人的动作映射到末端位姿、关节空间或潜动作；RDT-1B 的 "物理可解释统一动作空间" 是代表 [40]。
2. **本体条件化**：给模型输入本体描述/本体 token，让模型学习 "不同本体的动作差异"；GR00T/Gemini 采用类似思想 [38][39]。
3. **运动迁移**：从人类/其他机器人数据中提取可迁移的运动先验，再适配到目标本体；Gemini Motion Transfer、VioLA 是代表 [39][67]。
4. **模块化适配**：共享感知/语义主干，低层控制按本体微调；这是工程上最现实的方案。

关键判断：VLA 已经解决了 "语义泛化的第一公里"，但没有解决 "物理可靠性的最后一公里"。2026 年的研究重心，正在从 "更大的 VLA" 转向 "更好的动作接口、更强的后训练、更可靠的低层控制"。

8.3 从模仿到经验：RL 的回归

2024 年之前，VLA 的主流训练方式是模仿学习（行为克隆/扩散/流匹配）。模仿学习的优点是稳定、样本效率高；缺点是有上限：策略不会超过示范，也不会从失败中学习。

2025—2026 年，RL 以 "后训练" 的形式回归。

π*0.6 的 RECAP：把演示、在线收集的数据、人类遥操作纠正统一为 advantage-conditioned RL。先用离线 RL 预训练一个通用 VLA（π*0.6），再在真实机器人上做在线后训练。结果：在叠衣服、装盒子、意式咖啡机等任务上，最难任务的吞吐量提高一倍以上，失败率降低约一半 [37]。

Learning While Deploying（LWD）：把 “部署” 变成持续学习闭环。预训练 VLA 部署到车队后，收集分布偏移、长尾失败、人类纠正，用离线—在线 RL 做持续后训练。核心不是 “一次性训练”，而是 “部署—收集—后训练—再部署” 的飞轮 [64]。

为什么现在可行：

- 动作专家（扩散/流匹配）让 RL 的连续动作优化更稳定；
- GPU 并行仿真 + 真实数据基础设施降低了试错成本；
- 人类纠正/遥操作可以在部署中提供安全、稀疏的监督；
- VLM 可以自动生成奖励/课程，降低 reward engineering 成本；
- 商业部署提供了真实的长尾数据。

仍未解决：RL 的安全探索、非平稳性、奖励对齐、离线—在线切换的稳定性、评测的可复现性。π*0.6/LWD 是重要证据，但不是 “RL 通用机器人已解决”。

8.4 世界模型与世界—动作模型

世界模型在 2024—2026 年经历了从 “视频生成” 到 “世界—动作模型” 的转向。

Cosmos 系列：Cosmos 1（2025-01）把世界基础模型定位为物理 AI 的 “数字孪生”，提供视频策展、预训练、后训练和 tokenizer[45]；Cosmos-Predict2.5（2025-10）用 2 亿段视频训练 2B/14B 模型，统一 Text2World/Image2World/Video2World[46]；Cosmos 3（2026-06）把语言、图像、视频、音频、动作统一进一个混合 Transformer，直接覆盖世界模拟器和世界—动作模型 [47]。

Genie 3（2025-08）：文本生成可交互世界，720p、24fps、几分钟一致性；这是 “生成式世界” 的重要里程碑，但仍是研究预览，存在长程一致性/物理限制 [48]。

V-JEPA 2（2025-06）：在 100 万小时视频上自监督预训练，再用 62 小时 Droid 机器人视频后训练动作条件世界模型（V-JEPA 2-AC），零样本部署到两个实验室的 Franka 上做抓放 [44]。这说明 “视频预训练 + 少量机器人数据” 可以产生可用的世界模型。

世界—动作模型（WAM）：2026 年的新趋势。传统做法是 “世界模型预测未来，策略再决定动作”；WAM 把预测和控制联合训练，动作作为条件，未来作为监督，代表工作包括 Cosmos 3、MachEmbodied-U0 等 [47][69]。目标是让模型不仅 “生成看起来合理的未来”，而是 “生成对动作敏感、可用于控制的未来”。

关键判断：世界模型的瓶颈已经从 “生成质量” 转向 “因果条件 + 长程一致性 + 控制效用 + 评测”。视觉逼真不等于物理正确，物理正确不等于控制有用。2026 年的世界模型评测综述指出，现有基准无法回答 “世界模型是否真的让机器人更好”[24]。

8.5 人形机器人与灵巧操作

人形机器人在 2025—2026 年从 “演示” 走向 “产线试点”，但离 “通用” 仍有距离。

Figure 02 @ BMW：11 个月、每天 10 小时、90,000+ 钣金件、1,250+ 小时、30,000+ X3；5 毫米级放置精度、约 200 英里等效步行；Figure 称这是 “从实验室到产线” 的关键一步（公司声明，未经独立审计）[49]。这个案例的价值在于：它提供了人形机器人在真实产线上 “持续运行” 的证据，而不仅是一次性 demo。

Unitree/AgiBot 的规模化：Unitree 2025 年出货超过 5,500 台人形机器人，AgiBot 到 2026 年 3 月累计生产超过 10,000 台（据媒体报道，未经审计）[81]。硬件规模化速度超过自主性成熟速度；这也意味着 “数据采集/遥操作/远程协助” 会成为短期的重要环节。

GR00T N1：双系统人形基础模型，System 2 用 VLM 理解环境/指令，System 1 用扩散 Transformer 生成动作；在 Fourier GR-1 上做语言条件双臂操作 [38]。

行为基础模型（BFM）：用大规模运动数据预训练全身控制器，再微调到下游任务；Motivo、BFM-Zero、SONIC 等展示了 “人形通用控制器” 的潜力，但仍受 sim2real、数据、本体泛化限制 [12]。

VioLA / Whole-body UMI：VioLA（2026）从人类数据学习人形全身控制策略 [67]；Whole-body UMI（2026）把 UMI 的便携采集扩展到人形全身操作。这些工作试图解决 “人形数据稀缺 + 人类—机器人形态差异” 的双重难题。

关键判断：人形机器人的硬件和产线能力在快速成熟，但当前部署主要是结构化、重复性工位；开放世界自主性、可靠性、成本、安全仍然是瓶颈。**人形是通用性的重要载体，但不是通用性的充分条件。**

8.6 数据引擎与人类视频

数据是 2024—2026 年最明显的基础设施竞赛。

真实机器人数据：Open X-Embodiment（22 机器人、527 技能、160,266 任务）[32]、DROID（76k 轨迹、350 小时、564 场景、84 任务、50 实验室）[54]、AgiBot World（100 万 + 轨迹、217 任务、5 类场景）[41]。

人类数据：EgoDex（829 小时、194 任务、3D 手部追踪）[43]、Ego4D、Epic-Kitchens；人类视频提供任务结构、手—物交互、可供性、长程顺序，但缺少机器人动作和力控。

便携采集：UMI 让采集脱离机器人本体，保留末端执行器/手部监督；DexUMI、Whole-body UMI 扩展到灵巧手/人形全身。这是 “数据金字塔” 中 “可扩展性 vs 机器人对齐” 的关键折中 [21]。

数据金字塔（2026）把数据分为五层：真实机器人、UMI、ego/exo、仿真、通用视觉—语言；用六个维度评估：可扩展性、机器人对齐、质量、多样性、可复用性、物理保真度 [21]。核心结论：**数据配方（data recipe）比单纯的数据量更重要；动作空间对齐、失败/恢复数据、触觉数据是当前最大的缺口。**

关键判断：数据竞赛已经从 “谁有更多轨迹” 转向 “谁有更好的覆盖、对齐和物理 grounding”。一个百万条重复工位数据，不如一个覆盖多本体、多场景、多失败模式的中等数据集。

8.7 评测改革

评测是 2025—2026 年最被重视、也最不成熟的方向。

传统基准：LIBERO（终身学习/多任务）[51]、CALVIN（长程语言条件）、RLBench（多任务）、RoboCasa（厨房场景）[52]、BEHAVIOR-1K（1,000 活动、50 场景、9,000+ 物体）[50]、ManiSkill3（GPU 并行、30,000+ FPS）[53]、SimplerEnv（real-to-sim 评估）。

真实世界评测：RoboArena 用分布式、双盲、成对比较，在 7 个机构、600+ 个真实回合上评估 7 个通用策略；相比集中式基准，它更能反映真实表现，也更可扩展 [42]。

问题：

1. **基准过拟合**：模型/团队针对基准调参，分数上涨但真实能力不涨。
2. **sim-real gap**：仿真基准与真实部署相关性弱。
3. **短程/少本体**：大多数基准是桌面级、单本体、短任务；无法评估长程、跨本体、开放世界。

4. **二元指标**：成功率无法反映部分完成、效率、安全性、恢复能力。
5. **统计功效不足**：真实机器人试验样本少，置信区间宽；很多 “提升” 不显著。
6. **任务选择偏差**：基准任务由研究者选择，可能偏向 “容易演示” 的能力。

关键判断：评测不是 “最后一步”，而是 “第一性设计”。未来的评测需要：多轴 OOD、长程任务、真实世界分布式评估、统计显著、安全/成本指标、可复现协议。没有这些，“通用性” 无法成为科学结论。

8.8 安全与可信

安全在 2025—2026 年从 “附加项” 变成 “核心议题”。

能力—风险对偶：2026 年的具身安全综述提出，具身系统的每一层能力扩展都带来新的攻击面：感知（对抗/后门/传感器欺骗）、认知（推理操纵/世界模型污染）、规划（越狱/后门/轨迹攻击）、行动与交互（控制劫持/人机交互攻击）、Agent（工具滥用/记忆投毒/级联失败）[23]。

攻击面：对抗样本、后门、传感器 spoofing/jamming、CoT 劫持、VLA 后门、记忆投毒、级联失败。物理世界的后果比数字世界更严重：错误感知可能导致碰撞、伤害、设备损坏。

防御：对抗训练、认证防御、输入净化、运行时监控、CBF/可达性分析、保形预测、安全壳、红队测试。当前防御大多是 “外挂式” 的，难以证明端到端安全。

关键判断：安全需要 “策略—控制—系统—治理” 的分层保证；学习型策略越强，越需要可验证的安全壳。形式化验证、不确定性量化、对抗鲁棒性仍是开放问题。

8.9 最新进展的七个判断

1. **VLA 主干已经确立**。语义先验 + 机器人数据 + 动作专家，是当前通用策略的主流架构；未来的差异不在 “有没有 VLA”，而在 “数据、动作接口、后训练、系统集成”。
2. **RL 从部署中回归**。π*0.6/LWD 证明 “部署数据 + 人类纠正 + RL 后训练” 可以显著提升真实任务表现；这是 2025—2026 年最重要的范式变化。
3. **世界—动作模型是最有希望的架构赌注，但评测滞后**。预测与控制联合训练可能解决 VLA 的物理 grounding/长程问题，但目前缺乏公平的闭环评测。
4. **人形部署是真实的，但范围狭窄**。Figure 02/Unitree/AgiBot 的数据说明硬件和产线在成熟；开放世界自主性、可靠性、成本仍是瓶颈。
5. **评测与安全是下一阶段的 “约束条件”**。没有可靠的评测，通用性无法证明；没有安全壳，通用性无法部署。
6. **上下文学习/物理提示是 2026 年的第二组变量**。GEN-1.5、Skild S1、RoboTTT 把任务接口从语言扩展到视频演示；它不替代 VLA，而是给 VLA 加了一层 “快速适配” 接口，并可能改变数据效率的算法。
7. **全栈系统成为竞争单元**。高德 ABot 的论文矩阵说明，数据/世界模型、导航、执行、Agent、推理正在被同一套体系组织起来；单点模型比较仍然重要，但不再足以解释系统能力。

8.10 补论：近一年中文科技媒体热度背后的五条新线索

8.10.1 为什么补这一节

v1.0 的文献骨架以英文综述和 arXiv 论文为主，对中文科技媒体的覆盖不足。中文媒体（机器之心、量子位、新智元等）在选题速度、产业触达和 “把论文讲成人话” 方面有明显优势，但也容易把公司叙事、单次演示和实验室结果混在一起。本版补做了一次 “媒体–论文” 交叉检索：先从近一年报道中提取被反复讨论的成果，再回溯论文/技术报告/项目页，最后判断它是否足以修正研究地图。

检索时间为 2026-10-23。筛选标准有三条：报道讨论的是机器人/具身智能/智能体，而不是泛 AI；报道对应至少一个可核验的论文、技术报告或官方项目页；报道的主张对 “通用性” 的某个维度有实质影响。最终保留 20 余篇报道，映射到 15 项左右的一手成果。下面五条线索，是这次增补中最值得写进研究地图的部分。

8.10.2 线索一：从 “语言提示” 到 “物理提示”/上下文学习

2026 年最值得注意的变化，不是又一个更大的 VLA，而是**任务接口本身在变化**。

传统 VLA 用语言指令指定任务：`pick up the cup`、`clean the kitchen`。语言接口的优点是通用、自然；缺点是粗粒度、歧义大，难以表达精细的接触、力度、顺序和 “做到什么程度算完成”。2026 年出现了一批用**视频演示作为 prompt** 的工作：机器人看一段人类/机器人示范，不更新权重，直接执行新任务。这条路线可以称为 “物理提示”（physical prompting）或 “机器人上下文学习”（in-context learning, ICL）。

代表工作有三项。

Generalist GEN-1.5：用 3–12 秒的单条演示作为上下文，模型直接执行新任务；官方博客报告 one-shot 平均成功率 59%（±10%），few-shot 升到 83%（±9%），输出 100 Hz 动作，上下文包含 30 秒视频记忆；还展示了组合泛化、仿真演示到真实的 zero-shot 迁移、人类手到机器人手的模仿 [83]。官方明确说任务 “简单、短 horizon”，这是重要的限定。

Skild AI S1：把上下文学习推到最长 10 分钟、训练中未见过的新任务；只看一条演示视频、不做 post-training，在 OOD 任务上成功率 66%，而语言提示 VLA 只有 9%；单条演示大致相当于 380 条后训练示范（约 50–100 小时遥操作）[84]。这个 “380 条” 的换算很有冲击力，但它来自公司自己的基准和博客，尚无论文/独立复现。

RoboTTT：把视觉运动上下文扩展到 8K timesteps，比现有策略高三个数量级，同时不增加推理延迟；在这个上下文长度下，出现 one-shot 人类视频模仿、在线策略改进、扰动鲁棒和多阶段长程任务能力 [85]。这更像 “上下文 scaling law” 的论文版证据。

怎么放进研究地图：这不是第八条主路线，而是**路线 C（模仿/示教）与路线 D（VLA）之间正在长出的一个新子路线**，可以叫 “C-D 之间的上下文学习层”。它改变的是 “任务如何被指定” 和 “新技能需要多少数据”，而不是 “机器人如何获得物理身体”。它和 VLA 不是替代关系：VLA 提供语义先验和动作专家，ICL 提供任务接口和快速适配；两者可以共享主干，只是 prompt 从语言换成视频。

仍待验证：演示视频的视角/本体/任务分布能有多远；10 分钟任务的成功率是否可独立复现；失败恢复、长尾和安全边界；以及 “单条演示 ≈380 条示范” 是否只在特定任务族成立。媒体把它称为 “机器人 GPT 时刻”，现在下结论还太早。

8.10.3 线索二：从 “单模型” 到 “全栈具身系统”

第二类报道来自高德 ABot。量子位、机器之心在 2026 年 4–10 月连续报道了 ABot 的 “全栈具身技术体系”，包括数据/世界模型、导航基座、执行基座、Agent 操作系统，并声称在 15 项指标上取得

SOTA[98][101]。这类“全栈 + 15 项 SOTA”的表述很容易被视为营销，但回溯 arXiv 后可以看到，它确实对应一组论文，而不是单一 demo：

- **ABot-PhysWorld**：14B Diffusion Transformer 的交互式世界基础模型，用 300 万条操作视频、物理感知标注和 DPO 后训练来抑制“穿模/反重力”等非物理行为；引入 EZSbench 评估零样本物理泛化 [89]。
- **ABot-M0.5**：面向移动操作的 World-Action Model，从时间粒度、动作空间、训练—测试一致性三个层面做对齐，用中间潜动作连接视频潜空间和本体控制 [90]。
- **ABot-Claw**：面向长程、多机器人、自我进化的具身 Agent 基础，包含统一本体接口、跨本体多模态记忆、critic 闭环反馈与重规划 [91]。
- **ABot-ER**：统一具身推理模型，覆盖空间/场景/时序推理、长程动作组织、point grounding 与可供性；用“Agentic Data-Model Co-Evolution”让数据策略随模型能力演化 [92]。
- **ABot-World-0**：面向实时、长程闭环交互的动作条件视频世界模型，用教师蒸馏 + LongForcing 缓解自回归漂移，目标是在单张桌面 GPU 上做无限交互 rollout[93]。
- **ABot-N1**：视觉语言导航基础模型，用“慢推理 + 快动作专家”的双视觉语言信号解耦认知与控制 [109]。

怎么放进研究地图：ABot 的意义不是“又一套 SOTA”，而是把本报告第 7 章说的“系统栈”具体化了：数据/世界模型（L4）、导航/执行基座（L3）、Agent/推理（L5）被放在同一个体系里做。它支持本报告的核心判断——**通用性竞争的单位正在从“单模型”变成“全栈系统”**。同时也要保留两点：15 项 SOTA 是公司/媒体口径，论文是 B 级预印本；全栈系统的耦合度高，单点组件的可复现性和跨实验室迁移仍需验证。

8.10.4 线索三：世界—动作模型从概念走向系统

v1.0 把“世界—动作模型（WAM）”列为 2026 年的新趋势，但证据主要来自 Cosmos 3、Genie 3 等通用世界模型。近一年的中文报道和论文显示，WAM 正在变成一类**具体的机器人系统**，而不只是视频生成；机器之心对“世界模型嵌入具身系统”的三种架构（模块化/顺序/统一）做了系统梳理 [108]：

- **VLA-JEPA**：用 JEPA 式潜空间世界模型做 VLA 预训练，关键是“无泄漏的状态预测”——目标编码器看未来帧，学生只看当前观测，未来只作为监督；这样学到的动力学对相机运动/背景变化更鲁棒，避免像素级 latent action 的 appearance bias[88]。
- **ABot-PhysWorld**：把“物理对齐”作为世界模型的一等目标，用 DPO 抑制非物理行为，并用 EZSbench 分离评估物理真实性与动作对齐 [89]。
- **ABot-M0.5**：把 WAM 从“桌面操作”扩展到“移动操作”，解决粗粒度视频 chunk、导航—操作动作纠缠、训练/推理不一致三个问题 [90]。
- **LingBot-VLA 2.0**：在 VLA 中加入未来深度预测和语义特征预测，用当前/未来 query token + LingBot-Depth + DINO-Video 蒸馏，让策略在生成动作时同时预测未来状态 [86]。

量子位在 2026-10 还报道了千诀科技的预测式世界模型 Polibrain：它不追求逐帧视频生成，而是在任务相关的潜空间中预测状态变化，并用“多项式表征/因果记忆”提升跨场景、跨本体的复用；公司称已在四足、人形、轮式、双臂上适配 [110]。这条路线与 LeCun 的 JEPA 路线有理论亲缘：千诀与清华团队的 ICML 2025 论文从多任务低阶偏好出发，证明神经网络在温和假设下可恢复隐变量 [111]；LeCun 团队 2026 年的 LeJEPA 论文则给出线性可辨识性结果 [112]。两篇理论工作都不是机器人系统论文，但它们解释了“为什么潜空间预测可能比像素预测更可迁移”。Polibrain 的系统效果目前主要是公司演示，证据等级 C；理论部分是 B/A。

怎么放进研究地图：WAM 应该从 v1.0 的“新兴方向”上调为“**主流架构赌注之一**”，但保留“评测滞后”的判断。四条工作分别代表四种路线：潜空间预测（VLA-JEPA）、物理对齐视频（ABot-PhysWorld）、移动操作 WAM（ABot-M0.5）、VLA 内部未来预测（LingBot-VLA 2.0）。它们的共同问题是：**动作条件因**

果是否足够强、长程 **rollout** 是否稳定、闭环控制效用是否真的超过纯 **VLA**。EZSbench 是朝这个方向的一步，但还不足以回答 “世界模型是否让机器人更好”。

8.10.5 线索四：动作空间推理与灵巧全身控制

第三类新线索是 “推理” 从语言/视觉空间迁移到**动作空间**，以及 “灵巧手 + 全身” 从分开控制走向协调控制。

ACoT-VLA（智元 + 北航，CVPR 2026）提出 Action Chain-of-Thought：不再只预测子任务（语言 CoT）或目标图像（视觉 CoT），而是先生成粗粒度参考轨迹（显式动作推理 EAR），再从 VLM 内部特征提取隐式动作先验（IAR），最后用动作引导预测（AGP）生成精细动作。报告的结果是 LIBERO 平均 98.5%、LIBERO-Plus 84.1%、Genie Sim 3.0 零样本 sim-to-real 82.9%（π0.5 为 77.5%）[87]。这为 “语义—运动鸿沟” 提供了一个可操作的中间表示：**动作草图**。

CoorDex（UNC/Berkeley，RSS 2026 Workshop）把 29 DoF Unitree G1 + 20 DoF 五指手（共 49 DoF）拆成 “身体先验 + 手部先验”，蒸馏到 16 维/12 维潜空间，再用协调残差策略学习 “边走边抓”。仿真成功率 WalkGrab 55%、OpenFridge 66%、WalkPickTurn 89%；真实 G1 上只做了运动学兼容的轨迹验证，不是完整视觉闭环 sim2real[94]。**AnyBody** 进一步用任意关键点子集驱动统一全身控制器，支持只给手腕/躯干/双脚的稀疏控制，真实 G1 + Vision Pro 验证，到达任务成功率 >95%[95]。

怎么放进研究地图：这两条工作分别回应了 Q4（推理）和 Q2（技能/全身控制）的深水区。ACoT 说明 “推理” 不必只发生在语言里；CoorDex/AnyBody 说明 “灵巧” 不必等五指手完全成熟，身体—手—任务的协调才是关键。它们也暴露了共同短板：ACoT 的增益主要来自仿真 benchmark，CoorDex 的真实闭环验证不足，AnyBody 的任务仍以到达/遥操为主。

8.10.6 线索五：数据金字塔正在被重构

v1.0 用 “真实机器人—UMI— ego/exo—仿真—通用数据” 五层描述数据金字塔。近一年的报道显示，中间层正在快速变厚，塔尖的 “真机遥操” 不再是唯一的高质量来源。

- **LingBot-VLA 2.0**（蚂蚁灵波）：6 万小时预训练数据，其中 5 万小时机器人轨迹覆盖 20 种构型，1 万小时第一视角人类视频；统一动作空间扩展到头部、腰部、移动底盘、灵巧手；RTX 4090 推理延迟低于 130 ms；GM-100 上 66.2/34.4，高于 π0.5 的 59.1/32.2[86][97]。
- **TwinDEX**（自变量）：三指 9 DoF 的 “数采—执行同构” 系统，用可穿戴外骨骼采集数百条无本体数据，在后训练阶段不使用目标机器人真机遥操，完成化学实验中的旋盖、注射器推注等精细操作；单位时间有效轨迹约为传统真机遥操的 5.3 倍 [96][99]。这直接挑战了 “高质量数据必须来自真机遥操” 的假设。
- **新智元 “数据基建” 报道**：介绍 EMG 神经腕带 + 全景头环 + 姿态/视觉同步的 “人类操控数据层”，把意图、发力趋势、微控制、反馈修正纳入数据；对应 Nature 2025 的 sEMG 人机接口工作 [103][106]。这提醒我们：数据金字塔缺的不只是 “动作轨迹”，还有 “人为什么这样动、什么时候发力、接触后如何修正”。
- **ABot-3DGS / ABot-PhysWorld**：用城市/室内空间数据重建可编程 3DGS 场景，赋予质量/摩擦等物理属性，批量生成训练轨迹；再用物理对齐世界模型做数据/评估 [98][89]。这是 “仿真数据” 从 “物理引擎” 走向 “真实场景重建 + 生成” 的路线。

怎么放进研究地图：数据金字塔的 “中层” 正在从 UMI/人类视频扩展到 “无本体执行器数据、EMG/神经信号、3DGS 重建数据、世界模型生成数据”。真机遥操不会消失，但它不再是唯一的高质量来源；“数据配方/对齐” 比 “数据量” 更重要。TwinDEX 的 “无本体数据接近 100% 替代真机遥操” 是公司实验结论，需独立复现；但它指出的方向——**把本体对齐提前到数据产生之前**——很重要。

8.10.7 媒体叙事与论文证据的对照

下面把这一轮增补中最值得记录的 “媒体主张 → 论文锚点 → 证据等级 → 对地图的修正” 放在一起。它不是 “媒体可信度排名”，而是提醒读者：同一句话，背后的证据强度可能差一个数量级。

量子位 **2026-08**

- 核心主张：Skild S1 看一遍视频学会 10 分钟新任务；OOD 66% vs 语言 VLA 9%
- 论文/一手来源：Skild AI 官方博客 [84]
- 证据：B/C；对地图的修正：增加 “物理提示/ICL” 子路线

量子位/官方 **2026**

- 核心主张：Generalist GEN-1.5 用 3—12 秒演示 one-shot 学新任务
- 论文/一手来源：Generalist 官方博客 [83]
- 证据：B/C；对地图的修正：ICL 与 VLA 并列任务接口

量子位/机器之心 **2026-07**

- 核心主张：LingBot-VLA 2.0：6 万小时、20 构型、130 ms
- 论文/一手来源：技术报告 arXiv:2607.06403[86]
- 证据：B；对地图的修正：跨本体数据/统一动作空间

智元/**CVPR 2026**

- 核心主张：ACoT-VLA 在动作空间做思维链，LIBERO 98.5%
- 论文/一手来源：arXiv:2601.11404[87]
- 证据：B/A；对地图的修正：推理从语言/视觉转向动作

机器之心/量子位 **2026-04**

- 核心主张：高德 ABot 全栈体系、15 项 SOTA
- 论文/一手来源：ABot 系列论文 [89][90][91][92][93][109]
- 证据：B/C；对地图的修正：“全栈系统” 成为竞争单元

量子位 **2026-09**

- 核心主张：TwinDEX 无本体数据后训练，精细操作不再依赖遥操
- 论文/一手来源：自变量项目页/报道 [99]
- 证据：C；对地图的修正：数据金字塔中层变厚

量子位 **2026-04**

- 核心主张：WALL-B 世界统一模型、100 个家庭、自进化
- 论文/一手来源：公司报道 [100]
- 证据：C；对地图的修正：保留为产业信号，不升为研究事实

量子位 **2026-04**

- 核心主张：高德世界模型在 CVPR 2026 Workshop 挑战赛超谷歌/英伟达
- 论文/一手来源：ABot-PhysWorld[89]
- 证据：B/C；对地图的修正：世界模型评测开始被重视

新智元 **2026**

- 核心主张：EMG + 全景头环 + 姿态的 “人类操控数据层”
- 论文/一手来源：Nature 2025 sEMG[106]
- 证据：B/C；对地图的修正：数据模态从 “动作” 扩展到 “意图/发力”

新智元 **2026**

- 核心主张：首篇 LLM 控制机器人安全综述：具身鸿沟、越狱/后门/注入
- 论文/一手来源：arXiv:2601.02377[104]
- 证据：B；对地图的修正：安全从语义对齐转向物理后果

机器之心 **2026**

- 核心主张：世界模型嵌入 VLA/导航的三种架构：模块化/顺序/统一
- 论文/一手来源：TechRxiv 综述 [105]
- 证据：B；对地图的修正：细化世界模型耦合强度分类

8.10.8 对研究地图的五点修正

修正一：在路线 C 与 D 之间增加 “物理提示/上下文学习” 子路线。它不改变七条主路线的骨架，但改变了 “任务如何指定、技能如何快速获得” 的假设。未来的 VLA 可能同时支持语言 prompt 和视频 prompt；评测需要增加 “单演示/少演示” 的指标。

修正二：把 WAM 从 “新兴方向” 上调为 “主流架构赌注之一”。VLA-JEPA、ABot-PhysWorld、ABot-M0.5、LingBot-VLA 2.0 分别从潜空间、物理对齐、移动操作、VLA 内部预测四个方向推进；但 “世界模型是否真的让机器人更好” 仍是开放问题，EZSbench 只是开始。

修正三：把 “全栈系统” 作为分析单元。ABot 的论文矩阵说明，数据/世界模型、导航、执行、Agent、推理正在被同一套体系组织起来。单点模型比较仍然重要，但不再足以解释系统能力。

修正四：数据金字塔的中层变厚，真机遥操不再是唯一塔尖。TwinDEX、LingBot-VLA 2.0、EMG 数据、3DGS 重建数据都在削弱 “真机遥操 = 高质量” 的强绑定。但 “无本体数据可以替代真机” 仍是公司实验结论，需要独立复现；更稳妥的表述是 “真机遥操不再是唯一的高质量来源”。

修正五：媒体叙事要降权，但不能忽视。WALL-B、“2 万元人形机器人” 等报道提示了产业侧的真实进展（成本、家庭试点、消费级产品），但它们不是科学证据。研究地图应该把 “产品叙事” 和 “论文证据” 分开：前者用于判断产业节奏，后者用于判断技术边界。

9 瓶颈深水区

第 5–8 章反复出现一些 “卡住所有人” 的问题。本章把它们单独拎出来，按 “症状–根因–已有解法–仍未解决–可能突破口” 拆解。这些问题是下一阶段科研选题的高价值区。

9.1 数据三角：规模、对齐、物理 grounding

症状：数据越多，模型不一定越好；跨数据集混合经常出现负迁移；仿真数据在真实世界掉点；人类视频很难直接变成机器人动作。

根因：机器人数据同时受三个约束——规模（scale）、机器人对齐（robot alignment）、物理保真（physical fidelity）。三者很难同时最大化。真实机器人数据最对齐、最保真，但最贵、最难扩；仿真数据最可扩，但有 sim2real gap；人类视频最丰富，但缺少动作和力；互联网数据语义最强，但没有物理 grounding[21]。

已有解法：

- 数据金字塔/数据配方：按 “可扩展性 vs 机器人对齐” 分层，混合真实、UMI、ego、仿真、通用数据 [21]。

- 2026 年的新证据：LingBot-VLA 2.0 用 6 万小时、20 种构型验证 “跨本体数据配方”[86]；TwinDEX 用 “数采—执行同构” 把无本体数据推到后训练中心，单位时间有效轨迹约为真机遥操的 5.3 倍 [96][99]。
- 统一格式/动作空间：OXE 的统一 schema、RDT 的统一动作空间、UMI 的末端执行器监督 [32][40]。
- 数据增强/生成：世界模型、视频生成、域随机化、合成轨迹 [45][46]。
- 人类视频先验：任务意图、可供性、抓取选择、接触顺序的迁移 [25][26]。

仍未解决：

- 如何定义/度量 “数据质量”？多样性、覆盖度、物理保真度、失败覆盖，缺少统一指标。
- 如何做 “数据配方” 的因果归因？现有消融大多是 compute-matched 之外的黑箱。
- 如何低成本获取触觉/力/失败/恢复数据？
- 如何在不泄露隐私/不违反许可的情况下跨机构共享数据？

可能突破口：

- 以 “能力轴” 为单位设计数据收集，而不是以 “数据集” 为单位堆量；
- 把失败/恢复/ near-miss 作为一等数据；
- 用 UMI/人类视频做 “结构化先验”，用少量真实机器人数据做 “物理 grounding”；
- 建立数据卡（datasheet）和标准化元数据，让跨数据集训练可复现。

指标：数据覆盖度（任务/物体/场景/本体/失败模式）、动作对齐误差、跨数据集迁移矩阵、每单位数据带来的成功率提升。

9.2 跨本体三重异构：动作、形态、传感

症状：在 A 机器人上训练的 VLA，换到 B 机器人上性能大幅下降；简单混合多本体数据会出现负迁移；人形/灵巧手的数据很难用于夹爪机器人，反之亦然。

根因：跨本体不是 “换一个机器人” 这么简单，而是三重异构：

1. **动作异构**：关节数、自由度、控制模式（位置/速度/力矩）、动作频率、末端执行器都不同。
2. **形态异构**：连杆长度、质量分布、运动学、动力学、可达空间不同。
3. **传感异构**：相机数量/位置/视野、触觉/力/本体感觉的配置不同。

统一格式只能解决 “存得下”，不能解决 “语义对齐”。同一个末端位姿在不同基座/相机坐标系下可能有不同的数值；同一个 “抓取” 动作在不同手型上需要不同的关节配置 [21]。

已有解法：

- 统一动作空间：末端位姿、EEF delta、潜动作、物理可解释动作空间 [40]。
- 本体条件化：本体 token、形态描述、本体特定的适配层 [38][39]。
- 运动迁移：从人类/其他机器人数据提取运动先验，再 retargeting[39][67]。
- 模块化：共享感知/语义主干，低层控制按本体微调。

仍未解决：

- 如何定义 “语义等价” 的动作？末端位姿相同，接触力/稳定性可能完全不同。
- 如何处理 “缺失模态”（没有触觉、没有力传感器）？
- 如何避免负迁移？什么时候应该共享，什么时候应该分开？
- 如何评估跨本体泛化？需要标准化的本体 splits 和迁移指标。

可能突破口：

- 以 “接触状态/物体状态变化” 而不是 “关节轨迹” 作为跨本体中间表示；

- 学习本体无关的 “技能原型”，再用少量数据适配到目标本体；
- 建立跨本体动作语义标准（类似 ROS 接口，但包含物理语义）。

指标：零/少样本迁移成功率、负迁移率、适配所需数据量、跨本体动作语义一致性。

9.3 长程与接触：误差累积 + 接触不连续

症状：短任务成功率高，长任务成功率急剧下降；接触密集 任务（插拔、拧螺丝、叠衣服、开抽屉）在演示之外很脆弱；失败后无法恢复。

根因：长程任务同时受两个数学困难影响。

第一是**误差累积**：策略的 微小误差 会改变状态分布，把机器人推入训练分布之外；行为克隆的复合误差是经典问题，长程会放大。第二是**接触不连续**：接触模式切换导致动力学分段连续，微小的位置/力误差可能让 “插入” 变成 “卡住” 或 “撞坏”；接触状态是潜变量，视觉很难观测。

已有解法：

- 动作 chunk/ACT：一次预测一段动作，减少复合误差 [57]。
- 上下文学习/物理提示：用一段视频演示指定长程任务，不更新权重；GEN-1.5、Skild S1、RoboTTT 展示了 3—12 秒到 10 分钟的任务跨度 [83][84][85]。
- 分层策略：高层子任务 + 低层技能，减少单策略的时间跨度。
- 扩散/流匹配：建模多模态动作分布，避免平均动作 [56][35]。
- 触觉/力反馈：直接感知接触状态，做闭环力控 [28]。
- 失败检测/恢复：运行时监控、VLM 诊断、恢复策略 [6][22]。

仍未解决：

- 如何在接触模式切换时保持稳定？需要接触感知的动力学/策略。
- 如何从失败中学习？失败数据稀缺、异构、难标注。
- 如何做长程信用分配？哪个子任务/动作导致了失败?
- 如何评估长程能力？需要标准化的长程基准和衰减曲线。

可能突破口：

- 把 “接触状态” 作为一等表征，融合视觉/触觉/力/本体感觉；
- 用世界模型做 “接触后果” 预测，提前避免不稳定接触；
- 用分层 RL/模仿 + 恢复策略，把长程任务拆成可恢复的子任务；
- 建立失败/恢复数据集和长程评测协议。

指标：成功率随时间跨度的衰减曲线、接触状态估计误差、力超限率、失败检测延迟、恢复成功率。

9.4 语义—物理鸿沟：VLA 的 “知道” 与 “做到”

症状：VLA 能理解 “把杯子放到架子上”，但实际执行时可能撞倒杯子、抓不稳、放不到位；在 OOD 场景中，模型会生成 “看起来合理但物理错误” 的动作。

根因：VLA 的语义先验来自互联网图文数据，这些数据缺少接触、摩擦、质量、重心、力限等物理监督。模型学到的是 “视觉—语言—动作” 的统计相关，而不是 “动作—物理后果” 的因果模型。2025 年的 VLA 综述把这一组问题概括为物理 grounding、动作 token 化、跨本体、长程、评测、安全 [5][6]；2026 年的综述把 “语义—物理空间错配” 列为核心挑战 [22]。

已有解法：

- 世界模型：预测动作后果，提供物理监督 [9][44]。

- 触觉/力反馈：直接感知接触，做闭环控制 [28]。
- 混合架构：VLA 出意图，TAMP/MPC 做可行性/安全壳 [15][22]。
- 动作空间推理：ACoT-VLA 先生成粗粒度动作草图，再用隐式动作先验细化，试图把 “语义−运动鸿沟” 变成可训练的中间表示 [87]。
- 仿真/物理先验：可微物理、域随机化、物理约束损失 [17][18]。
- RL 后训练：用真实后果优化策略 [37][64]。

仍未解决：

- 如何让 VLA 知道 “自己不知道”？不确定性量化/校准仍是弱项。
- 如何把物理约束注入大模型训练，而不牺牲语义泛化？
- 如何评估 “物理理解” 而不是 “任务成功”？需要反事实/干预测试。
- 如何让世界模型的动作条件因果足够强？当前模型可能依赖历史/意图而非动作 [9]。

可能突破口：

- “语义模型 + 物理模型” 双系统：语义模型提出候选，物理模型验证/修正；
- 用接触/力数据训练 “物理常识” 表征；
- 在训练中加入反事实/干预目标，而不只是下一步预测；
- 建立 “物理理解” 基准：同一场景、不同动作、预测后果。

指标：反事实动作预测准确率、接触后果预测误差、OOD 物理任务成功率、失败前的风险预警率。

9.5 评测有效性：基准分数不等于部署能力

症状：模型在基准上 SOTA，真实部署却频繁失败；不同论文的 “提升” 无法比较；真实机器人试验样本少，统计不显著；基准任务越来越像 “刷分游戏”。

根因：评测同时受四个问题影响。

1. 基准过拟合：任务/场景/指标被研究者选择，模型/团队针对基准调参。
2. **sim-real gap**：仿真基准与真实部署的物理/传感/环境差异。
3. 短程/少本体：大多数基准是桌面级、单本体、短任务，无法评估长程/跨本体/开放世界。
4. 统计功效不足：真实机器人试验成本高，样本少，置信区间宽；二元成功率无法反映部分完成/效率/安全/恢复。

已有解法：

- 多轴 OOD 基准：THE COLOSSEUM 等组合扰动 [20]。
- 分布式真实评测：RoboArena 用双盲、成对比较、跨机构评估 [42]。
- 长程/多本体基准：BEHAVIOR-1K、RoboCasa、LIBERO、ManiSkill3[50][52][51][53]。
- 统计协议：置信区间、预注册、足够试验、效应量 [6]。
- 世界模型专用评测：EZSbench 用 “真实 + 合成未见机器人/任务/场景” 分离评估物理真实性与动作对齐 [89]。

仍未解决：

- 如何定义 “通用性” 的可操作指标？需要多轴、预算感知的评分。VLN 等真实世界系统评测仍缺乏统一协议 [27]。
- 如何保证基准与部署的相关性？需要纵向研究/工业数据。
- 如何评估 “失败恢复/安全/交互” 而不只是成功率？
- 如何让评测可复现？硬件/软件/标定/环境的标准化。

可能突破口：

- “基准筛选项 + 真实部署验证” 的两阶段评测；
- 建立公开的 “部署相关性” 数据集：同一策略在基准和真实场景的表现；
- 用主动学习/自适应测试选择最有信息量的任务；
- 评测协议预注册 + 开源 harness。

指标：基准排名与部署排名的相关性、泛化 gap、统计功效、评测可复现率、每美元试验的信息量。

9.6 安全与实时：学习系统的可验证性

症状：VLA/世界模型的推理延迟与实时控制矛盾；对抗攻击/后门/传感器欺骗可以导致危险动作；安全壳通常是外挂的，无法证明端到端安全。

根因：学习型策略是黑箱、非线性的，输入维度高、分布开放；形式化验证的可扩展性差；实时控制要求 50—1000 Hz，而大模型推理可能是 100 ms—数秒 [22]。安全与性能的权衡缺乏理论工具。

已有解法：

- 安全壳：CBF、可达性分析、运行时监控、屏蔽层 [22][23]。
- 不确定性：保形预测、贝叶斯方法、OOD 检测 [4][22]。
- 对抗防御：对抗训练、认证防御、输入净化 [23]。
- 混合架构：VLA 出意图，MPC/WBC 做安全执行 [6][22]。
- 形式化方法：神经符号、约束生成、运行时验证 [22]。
- LLM 控制链路安全：2026 年的安全综述把具身越狱、后门、提示词注入、逻辑/物理防御脱节作为独立问题域 [104]。

仍未解决：

- 如何为含大模型的系统提供端到端安全保证?
- 如何认证 “学习型组件” 在 OOD 中的行为?
- 如何在低延迟下做不确定性量化/安全监控?
- 如何防止 Agent 记忆投毒/工具滥用/级联失败 [23]?

可能突破口：

- ISO 10218:2025 等标准为工业机器人安全提供框架，但学习型组件的认证仍不充分 [80]；需要把标准要求转译为可测试的安全案例。
- “策略—安全层联合训练”：让策略在训练时就学习约束，而不是事后拦截；
- 安全壳的标准化接口（观测约束、动作约束、干预协议）；
- 运行时保证 + 形式化验证的组合；
- 安全案例（safety case）方法：把数据、模型、测试、监控、治理组织成可审计的论证。

指标：约束违反率、认证覆盖率、干预率、攻击成功率、端到端延迟、事故率。

9.7 硬件可靠性与成本：通用性的物理约束

症状：人形/灵巧手在演示中很酷，但长时间运行故障率高、维护成本高、BOM 成本高；触觉传感器易损、标定复杂；续航/散热限制算力。

根因：通用性要求更多的自由度、传感器、执行器，而每一个增加都是故障点/成本点。Figure 02 在 BMW 的 1,250 小时运行中，前臂电子是首要故障点，直接推动了 Figure 03 的腕部电子重构 [49]。这说明硬件可靠性不是 “工程细节”，而是通用性的必要条件。

已有解法：

- 模块化设计：前臂/腕部/手部可更换；减少动态线缆。
- 可靠性工程：加速寿命测试、故障树、冗余、失效安全。
- 低成本硬件：ALOHA/UMI/Leap Hand 等低成本平台。
- 触觉传感器：视触觉、柔性阵列、耐用材料。
- 边缘计算：Jetson/专用加速器、模型压缩。

仍未解决：

- 如何定义/测量人形机器人的 MTBF/正常运行时间？
- 如何在成本约束下实现高自由度/触觉/力控？
- 如何做跨本体的硬件标准化？
- 如何保证安全（人机共存）而不牺牲效率？

可能突破口：

- 硬件—控制—数据 co-design：为学习设计硬件，而不是为硬件设计学习；
- 可更换模块 + 标准化接口；
- 触觉/力传感器的 “皮肤化” 和低成本化；
- 以 “每任务成本/正常运行时间” 而不是 “自由度” 作为硬件指标。

指标：MTBF、正常运行时间、维护成本、BOM 成本、每任务能耗、触觉传感器寿命。

9.8 理论缺失：没有具身学习的 “缩放定律”

症状：语言/视觉有 scaling law，机器人没有；什么样的数据/模型/任务组合会产生泛化，缺少理论预测；很多结论是 “经验观察”，难以外推。

根因：具身学习的分布由任务、环境、本体、数据采集策略共同决定，不是单一的数据规模；奖励/目标/安全约束也影响学习；物理交互的样本成本高，难以做大规模受控实验。

已有解法：

- 经验 scaling 研究：RT-1/RT-2/OpenVLA 的数据/模型/多样性 scaling[30][31][34]。
- 世界模型 scaling：TD-MPC2 的模型/数据 scaling[63]。
- 数据配方研究：Data Pyramid 的六维评估 [21]。
- 评测科学：RoboArena 的分布式评估 [42]。

仍未解决：

- 什么是具身学习的 “有效数据单位”？轨迹？技能？接触事件？任务？
- 泛化如何随任务/环境/本体分布变化？有没有可预测的规律？
- 数据/模型/算力/安全预算如何分配最优？
- 如何从少量真实数据 + 大量仿真/人类数据中预测真实性能？

可能突破口：

- 建立 “能力轴 × 数据轴 × 本体轴” 的受控 benchmark；
- 用因果推断/迁移学习理论分析数据配比；
- 用世界模型做 “性能预测器”，减少真实试验；
- 公开 negative results/失败曲线，建立领域知识库。

指标：scaling 曲线的可预测性、数据配比的因果效应、跨本体外推误差、真实性能预测误差。

10 未来 3–5 年：研究议程与选题建议

10.1 十个趋势判断

下表给出本报告对未来 3–5 年的趋势判断。置信度是作者基于当前证据的主观评估：高 = 已有明确信号，中 = 方向清晰但路径不确定，低 = 早期探索。

趋势	证据	置信度	影响
VLA 成为通用策略主干	RT-2/OpenVLA/π0/GR00T/Gemini 的连续演进	高	研究门槛降低，竞争转向数据/动作接口/后训练
部署中 RL 成为差异化能力	π*0.6 RECAP、LWD 车队级 RL	高	从 “离线训练” 转向 “部署–学习” 飞轮
世界–动作模型融合预测与控制	Cosmos 3、MachEmbodied-U0	中	可能解决 VLA 的物理 grounding/长程问题
人类视频/UMI 成为主要数据来源	EgoDex、UMI、Data Pyramid	中高	降低数据成本，但需解决本体差异
跨本体动作接口标准化	OXE、RDT 统一动作空间、Gemini Motion Transfer	中	决定数据/模型能否复用
真实世界分布式评测	RoboArena、部署相关性研究	中	基准分数不再是唯一标准
安全壳/运行时保证成为标配	具身安全综述、CBF/保形预测	中高	决定能否进入安全关键场景
边缘推理/模型压缩	双系统、量化、蒸馏、CLIP 级小模型	高	决定 VLA 能否在机器人上实时运行
人形机器人产线试点扩大	Figure 02、Unitree/AgiBot 规模化	中高	硬件/数据/就业结构受影响
触觉/力基础模型	触觉综述、视触觉融合	中	接触密集 操作的关键缺口

10.2 十个高价值选题

以下选题按 “科学价值 × 工程杠杆 × 可测量性” 筛选。每个选题给出 “为什么现在、第一步、成功指标、风险”。

选题一：跨本体动作接口与语义对齐

为什么现在：OXE/GR00T/Gemini 已经证明跨本体数据有价值，但动作空间/坐标系/控制模式不统一，负迁移严重 [32][38][39][21]。

第一步：定义一个 “接触状态/物体状态变化” 为中心的中间动作表示，先在 2–3 种本体上做受控迁移实验。

成功指标：零/少样本迁移成功率、负迁移率、适配数据量、跨本体动作语义一致性。

风险：过度抽象会丢失物理细节；过度具体又无法迁移。

选题二：动作条件世界模型的因果一致性

为什么现在：Cosmos/Genie/V-JEPA 2 展示了世界模型的潜力，但“动作条件因果”仍是缺口[9][24][44][47]。

第一步：构造反事实动作对（同一状态、不同动作、预测不同未来），训练/评估动作敏感性。

成功指标：反事实动作预测准确率、动作敏感性、闭环控制效用、长程一致性。

风险：视频生成模型可能学到“意图条件”而不是“动作条件”；评测本身很难。

选题三：部署中的持续 RL 与车队学习

为什么现在：π*0.6/LWD 证明部署数据可以显著提升真实任务表现 [37][64]；但安全、非平稳、评测仍是问题。

第一步：在受控场景中建立“部署—收集—后训练—再部署”的闭环，记录失败/纠正/恢复数据。

成功指标：吞吐量、失败率、样本成本、安全违规、跨任务迁移。

风险：真实世界 RL 的安全/成本；奖励黑客；数据偏差。

选题四：人类视频/UMI 的可扩展 grounding

为什么现在：EgoDex/UMI/Data Pyramid 提供了大规模人类数据，但人类—机器人差异仍是瓶颈[43][21][25][26]。

第一步：把人类视频分解为“任务意图/可供性/接触顺序/物体状态变化”，用少量机器人数据 grounding 动作。

成功指标：跨本体技能迁移、接触成功率、数据效率、任务覆盖。

风险：人类视频缺少力/触觉；retargeting 可能物理不可行。

选题五：触觉—力—本体感觉多模态基础模型

为什么现在：触觉是接触密集 操作的“缺失模态”，但传感器/数据/标准化都不成熟 [28][10][11]。

第一步：建立跨传感器/跨本体的触觉表征，先在滑移检测/力跟踪/抓取稳定性上验证。

成功指标：滑移检测延迟、力跟踪误差、跨传感器迁移、接触密集 任务成功率。

风险：硬件异构、数据采集成本、触觉仿真不准。

选题六：长程记忆与分层 Agent

为什么现在：VLA 大多是反应式/短窗；长程任务需要记忆、进度跟踪、失败恢复 [6][22][19]。

第一步：构造“多阶段、可失败、可恢复”的长程基准，评估记忆/进度/恢复的贡献。

成功指标：长程成功率、进度准确率、恢复成功率、干预率。

风险：接口误差、状态表示、评测难度。

选题七：可验证安全壳

为什么现在：VLA/世界模型的黑箱性质与安全认证矛盾；CBF/运行时保证/保形预测提供了工具，但缺少端到端方案 [22][23]。

第一步：为 VLA+ 低层控制器设计标准化安全接口（约束、监控、干预、回退），在接触密集 任务上验证。

成功指标：约束违反率、认证覆盖率、干预率、任务成功率损失。

风险：安全壳过于保守会降低性能；形式化方法扩展性差。

选题八：真实世界评测与统计协议

为什么现在：基准与部署相关性弱；RoboArena 提供了分布式评测的雏形 [42][24]。

第一步：建立 "基准—部署" 配对数据集，测量同一策略在两边的排名相关性；设计多轴 OOD/长程/安全指标。

成功指标：排名相关性、统计功效、评测可复现率、每美元信息量。

风险：真实评测成本高；任务选择偏差；社区采纳难。

选题九：高效边缘推理与软硬协同

为什么现在：VLA/世界模型的延迟/功耗与机器人实时控制矛盾 [22]；双系统/量化/蒸馏是缓解，不是根治。

第一步：以 "控制频率/延迟/功耗" 为约束，做模型—硬件 co-design；在真实机器人上测端到端延迟。

成功指标：端到端延迟、抖动、每任务能耗、精度损失、任务成功率。

风险：硬件迭代快；模型压缩可能损失物理精度。

选题十：失败/恢复数据引擎

为什么现在：大多数数据集只保留成功轨迹；失败/恢复数据是长程可靠性的关键 [21]。

第一步：在数据采集管线中系统记录失败、near-miss、人工干预、恢复动作；建立失败分类/标注协议。

成功指标：失败检测率、诊断准确率、恢复成功率、数据复用率。

风险：失败数据涉及安全/隐私；标注成本高；失败定义异构。

10.3 三条路线图

近期（1—2 年）：把基础设施做对

- 建立跨本体动作/数据标准；
- 建立失败/恢复/触觉数据采集管线；
- 建立真实世界分布式评测协议；
- 把安全壳/运行时监控做成标准组件；
- 在边缘端做 VLA/世界模型的延迟/功耗优化。

判断标准：不是 "又一个大模型"，而是 "别人能否在你的数据/评测/接口上做实验"。

中期（3–5 年）：把闭环跑通

- 世界–动作模型的因果一致性；
- 部署中 RL/车队学习的稳定性和安全性；
- 人类视频/UMI 的规模化 grounding；
- 触觉/力基础模型；
- 长程记忆/分层 Agent；
- 跨本体迁移的理论/评测。

判断标准：系统能否在 “未见任务/环境/本体” 上，用少量数据达到可接受的性能/成本/安全。

长期（5–10 年）：把通用性变成可测量

- 开放世界持续学习；
- 人形/多本体通用系统；
- 可验证的安全/治理；
- 具身学习的 scaling law/理论；
- 通用物理模拟器/世界模型。

判断标准：不是 “演示”，而是 “可复现、可审计、可部署、可负担”。

10.4 给不同角色的建议

给研究者

- **选一个可测量的 gap**：不要做 “又一个 VLA”，要做 “某个泛化轴/失败模式/评测协议” 的第一。
- **建立数据/评测闭环**：没有自己的数据/评测，很难做出差异化。
- **重视 negative results**：失败曲线、负迁移、OOD 失败，比 SOTA 更有信息量。
- **跨层合作**：VLA 研究者需要懂控制/硬件；控制研究者需要懂学习/数据。

给实验室/团队负责人

- **投资数据引擎 + 评测 + 一个差异化能力**，而不是只追模型规模。
- **建立 “研究–部署” 双回路**：部署数据反哺研究，研究结果回到部署。
- **安全/可靠性前置**：不要让安全成为最后一个月的工程问题。
- **人才结构**：需要 ML、控制、硬件、HRI、评测的复合团队。

给产业

- **先做结构化场景**：工厂、仓库、实验室、餐饮后厨，比开放家庭更容易落地。
- **用 “正常运行时间/每任务成本/安全” 而不是 “自由度/演示效果” 做 KPI**。
- **建立数据飞轮**：部署–收集–后训练–再部署。
- **不要过度承诺通用性**：通用性是曲线，不是发布会。

给资助者/政策制定者

- **投资基础设施**：数据、仿真、评测、安全标准，比单点模型更有公共品价值。
- **支持长周期研究**：具身智能的 “慢变量” 是硬件/数据/评测，不是一年一代的模型。
- **建立安全/伦理/标准框架**：人形机器人进入人类空间，需要认证、责任、保险、隐私规则。

10.5 不该做什么

1. **不要再做“在 OXE 上再训练一个更大 VLA”的同质化工作**，除非你有新的动作接口、数据配方、本体或评测。
2. **不要做“又一个短程桌面抓取基准”**，除非它能诊断一个具体的失败模式。
3. **不要用演示视频代替失败分析**：一个不能复现、不能统计、不能恢复的 demo，不是科学证据。
4. **不要用 FVD/FID 证明世界模型“有用”**：视觉逼真不等于控制有用。
5. **不要在人形机器人上只报“自由度/身高/负载”**：MTBF、正常运行时间、每任务成本、安全才是部署指标。
6. **不要把安全当“最后加一个过滤器”**：安全壳需要和策略/控制联合设计。
7. **不要过度承诺“通用”**：说清楚任务/环境/本体分布，以及失败边界。

11 结论

具身智能机器人研究正在从“能不能学会一个任务”走向“能不能构建一个持续变强、可靠、可负担的通用系统”。这条路上，VLA 提供了语义泛化的起点，世界模型提供了预测/想象的杠杆，RL 提供了经验优化的引擎，人形/灵巧手提供了物理载体，数据/评测提供了规模与标尺，安全/控制提供了部署的底线。

但通用性不会由某一个模型、某一篇论文、某一次演示突然实现。它更像一条**可测量的曲线**：每增加一个泛化轴、每降低一次失败率、每缩短一次适配时间、每提高一次评测有效性，曲线就向前移动一点。领域的下一程，不是寻找“终极模型”，而是把数据、接口、预测、控制、评测、安全组织成一个能持续进化的系统。

如果说过去十年的核心问题是“如何让机器人从数据中学习”，那么未来十年的核心问题可能是：

> **如何让机器人在真实世界中学习，并且在学习中保持可靠、安全、可负担？**

这个问题的答案，不会只属于某一个学科。它需要机器人学、机器学习、控制、认知科学、人机交互、安全工程和评测科学的共同参与。这也是“研究地图”存在的意义：不是为了列出所有论文，而是为了看清哪些路已经走过，哪些路正在汇合，哪些路还没有人走。

附录 A 核心综述精读卡片

以下卡片按 “对本报告框架的贡献” 排序，不是引用数排序。每张卡片给出出处、核心框架、主要挑战和读后判断，便于快速定位。

A1. Duan et al. 2022 — 前基础模型时代的 “任务金字塔”

- 出处：IEEE TETCI，2022；arXiv:2103.04918[1]。
- 核心框架：仿真器（9 个）+ 三类任务（视觉探索、视觉导航、具身问答），构成 “探索 → 导航 → 问答” 的任务金字塔。
- 主要挑战：仿真器的真实感/可扩展性/交互性；长程记忆；混合经典与学习；多智能体；评测。
- 读后判断：这是理解 “具身 AI 基准时代” 的最佳入口，但它的任务主要是虚拟环境中的导航/问答，缺少真实灵巧操作；在 VLA 时代需要与后续综述配合阅读。

A2. Roy et al. 2021 — 具身学习的科学议程

- 出处：arXiv:2110.15245[3]。
- 核心框架：具身智能的五个挑战（安全、非独立同分布（non-IID）、任务规范、主动数据、形态），以及四条研究路线（归纳偏置、快慢系统、逻辑/组合性、形态）。
- 主要挑战：如何选择归纳偏置；如何做多尺度抽象；如何用逻辑/组合性表示世界；如何评测/验证学习系统。
- 读后判断：这是本报告 “通用性来源” 框架的重要思想来源。它提醒我们：具身智能不是 “把 ML 应用到机器人”，而是对 ML 本身提出新要求。

A3. Liu et al. 2025 — 后 MLM 时代的四目标框架

- 出处：IEEE TMech，2025；arXiv:2407.06886[2]。
- 核心框架：机器人、仿真器、四个研究目标（具身感知、具身交互、具身 Agent、sim2real）、MLM/WM。
- 主要挑战：高质量机器人数据、长程任务、因果推理、统一评测、安全/隐私。
- 读后判断：目前覆盖最全的 “后基础模型” 综述之一；四目标框架适合做领域地图，但对 “通用性” 的定义比较宽，需要本报告的五维/七维框架补充。

A4. Hu et al. 2023 — 基础模型与通用机器人的五挑战

- 出处：arXiv:2312.08782[4]。
- 核心框架：通用机器人的五大挑战（泛化、数据稀缺、模型/原语要求、任务规范、不确定性与安全）；基础模型在感知、规划、动作、grounding、数据生成中的角色。
- 主要挑战：grounding、安全/不确定性、端到端 vs 模块化、形态适应、世界模型 vs 无模型、持续学习、标准化、仿真 vs 真实、工业部署。
- 读后判断：虽然写于 2023 年，但它的开放问题清单今天仍然成立；特别适合做 “问题导向” 的选题。

A5. Ma et al. 2025 — VLA 的分层分类

- 出处：arXiv:2405.14093[5]。
- 核心框架：VLA 组件（RL、视觉表征、视频表征、动力学、世界模型、推理）、低层控制策略、高层任务规划器、数据/基准。
- 主要挑战：数据稀缺、跨本体、长程、实时、评测、安全。

- 读后判断：适合作为 VLA 的入门综述；它的 “组件 + 控制 + 规划” 分层很清楚，但对 2025—2026 年的世界—动作模型覆盖不足。

A6. Kawaharazuka et al. 2025 — 真实世界 VLA 的工程视角

- 出处：IEEE Access，2025；arXiv:2510.07077[6]。
- 核心框架：VLA 的设计策略、架构、训练、数据、真实应用、实践建议。
- 主要挑战：数据需求/稀缺、跨本体、算力/训练成本、推理、持续学习、失败恢复、安全、评测。
- 读后判断：最接近 “工程落地” 的 VLA 综述；它反复强调 “数据/本体/算力” 而不是模型结构，和本报告的判断一致。

A7. Li et al. 2025 — 世界模型的三轴分类

- 出处：arXiv:2510.16732[7]。
- 核心框架：决策耦合 vs 通用；序列模拟 vs 全局差分预测；潜空间/显式几何/神经场。
- 主要挑战：数据/评测、计算效率、建模策略（长程/空间/因果）。
- 读后判断：世界模型综述里分类最清晰的一篇；它把 “功能—时间—空间” 三轴分开，避免了 “视频生成 = 世界模型” 的混淆。

A8. Long et al. 2025 — 仿真器与世界模型的 “显式/隐式” 路径

- 出处：arXiv:2507.00917[8]。
- 核心框架：IR-L0—L4 智能分级；移动/操作/交互；物理仿真器；世界模型作为神经模拟器/动力学模型/奖励模型。
- 主要挑战：高维/部分可观测、因果 vs 相关、抽象/语义、评测、记忆、人机交互、可解释/可验证、组合泛化、数据偏差。
- 读后判断：把 “仿真器（显式）” 与 “世界模型（隐式）” 放在同一个框架里，是理解 sim2real 与生成式仿真关系的好入口。

A9. Hou et al. 2026 — 以策略为中心的世界模型综述

- 出处：arXiv:2605.00080[9]。
- 核心框架：世界模型作为策略（逆动力学、单骨干、MoE/MoT、统一 VLA、潜空间）；作为模拟器（RL、评估）；机器人视频生成。
- 主要挑战：因果条件缺口、效率、多模态、经典控制集成、符号结构、评测。
- 读后判断：目前最贴近 “世界—动作模型” 前沿的综述；它把 “世界模型是否有用” 落到闭环控制效用，而不是视觉保真。

A10. An et al. 2025 — 灵巧操作模仿学习的路线图

- 出处：IEEE TASE，2025；arXiv:2504.03515[10]。
- 核心框架：行为克隆、IRL、GAIL、分层 IL、持续 IL；末端执行器；遥操作/视频示范；数据/基准。
- 主要挑战：数据融合/质量/稀疏、基准/复现、泛化、sim2real、实时、安全、高精度。
- 读后判断：灵巧操作领域最系统的 “问题—方法—路线图” 综述之一；它把 “数据采集” 而非 “模型结构” 放在第一位，值得注意。

A11. Yuan et al. 2025 — 人形行为基础模型

- 出处：IEEE TPAMI，2025；arXiv:2506.20487[12]。

- 核心框架：传统模型控制 → 任务专用学习 → 行为基础模型；预训练（目标条件/内在奖励/前向−后向表征）、适配（微调/分层）。
- 主要挑战：sim2real、计算/系统集成、数据瓶颈、本体泛化；机会包括多模态、高层 ML 系统、scaling、后训练、多智能体、评测。
- 读后判断：理解 “人形全身控制” 这条路线的最佳入口；它提醒我们：人形通用性不仅是 VLA，还需要低层行为基础模型。

A12. Zhao et al. 2024 — TAMP 的经典−学习融合

- 出处：IEEE TMech，2024；arXiv:2404.02817[15]。
- 核心框架：约束式/采样式/优化式 TAMP；任务规划、运动规划、学习增强。
- 主要挑战：LLM/VLM 的空间推理/长程记忆、扩散模型、多模态传感、策略学习、移动操作、人机协作、真实应用。
- 读后判断：TAMP 领域最完整的 “经典 → 学习” 综述；它说明 “LLM 规划” 不是替代 TAMP，而是需要 TAMP 做物理可行性。

A13. Psiris et al. 2026 — 机器人基础模型的五阶段/六挑战

- 出处：arXiv:2604.15395[22]。
- 核心框架：五阶段（NLP/CV 集成 →VL grounding→VLA→ 记忆/任务组合 → 多感官/部署）；六类挑战（数据、计算、安全、具身、推理、评测）。
- 主要挑战：数据稀缺/异构/质量、实时/边缘、语义−物理错配、对抗、不确定性、动作空间异构、sim2real、触觉、物理常识、长程、可解释、评测。
- 读后判断：覆盖面最广的 2026 年综述之一；它的五阶段框架与本报告的历史分期高度兼容，六类挑战可以作为研究议程的检查表。

A14. Ye et al. 2026 — 数据金字塔

- 出处：arXiv:2607.24744[21]。
- 核心框架：真实机器人、UMI、ego/exo、仿真、通用五层；可扩展性 vs 机器人对齐；质量、多样性、可复用性、物理保真度。
- 主要挑战：触觉、失败/恢复、scalable collection、跨本体状态−动作对齐、ego 先验、数据配方。
- 读后判断：目前最好的 “数据生态” 综述；它把 “数据配比” 从工程经验提升为研究问题。

A15. Li et al. 2026 — 具身安全的能力−风险对偶

- 出处：arXiv:2605.02900[23]。
- 核心框架：感知、认知、规划、行动/交互、Agent 五层；每层能力扩展对应新的攻击面；攻击/防御分类。
- 主要挑战：多模态融合脆弱性、规划越狱、人机交互可信、记忆投毒、级联失败。
- 读后判断：具身安全领域最系统的综述之一；它把安全从 “模型对齐” 扩展到 “系统/物理/Agent” 全栈。

A16. 中关村学院等 2026 — 世界模型嵌入具身系统的三种架构

- 出处：TechRxiv 2026；DOI:10.36227/techrxiv.176531987.77979037/v1[105]。
- 核心框架：按 “梯度流” 和 “信息依赖” 两个维度，把世界模型与策略的耦合分为模块化、顺序、统一三类；分别对应世界模拟器、目标生成器、端到端联合模型。

- **主要挑战**：表征空间选择（视觉 vs 状态/潜空间）、结构化意图生成、想象的可达性/可行性过滤、统一世界—策略模型的状态空间对齐。
- **读后判断**：这是把 “世界模型如何放进 VLA/导航” 讲得最清楚的一篇框架性综述；适合与 VLA-JEPA、ABot-PhysWorld、ABot-M0.5 对照阅读。

A17. Huang et al. 2026 — LLM 控制机器人的安全综述

- **出处**：arXiv:2601.02377[104]。
- **核心框架**：具身鸿沟（embodiment gap）；具身越狱、后门、提示词注入；逻辑/物理防御脱节；全生命周期防御与标准化基准。
- **主要挑战**：静态内容过滤器无法理解物理语境；形式化方法难以覆盖连续动力学；多模态攻击面；长时程环境中的安全评估。
- **读后判断**：与 2026 年另一篇具身安全综述 [23] 互补：前者聚焦 LLM 控制链路，后者覆盖感知—认知—规划—行动—Agent 全栈。两篇都说明安全必须从 “语义对齐” 走向 “物理后果对齐”。

附录 B 关键系统与基准速查

B1. 关键系统

系统 / 时间	类型	关键主张	证据
RT-1（2022）	多任务 Transformer	大规模真实数据 + 高容量模型可缩放	A
RT-2（2023）	VLA	动作作为文本 token，互联网语义迁移	A
Open X-Embodiment（2023）	数据集/模型	22 机器人、527 技能、160,266 任务	A
Octo（2024）	开源通用策略	800k 轨迹，多传感器/动作空间	A/B
OpenVLA（2024）	开源 VLA	7B、970k 演示，超过 RT-2-X 16.5%	A
π0（2024）	流匹配 VLA	多本体、灵巧操作、动作专家	B
RDT-1B（2024）	双臂扩散模型	统一动作空间、双臂操作	B
AgiBot World / GO-1（2025）	数据/策略	100 万 + 轨迹、217 任务；GO-1 >60% 复杂任务	B
GR00T N1（2025）	人形 VLA	双系统、人形基础模型	B
π0.5（2025）	开放世界 VLA	异构 co-training、全新家庭长程任务	B
π*0.6（2025）	RL 后训练	RECAP，吞吐翻倍、失败率减半	B
Gemini Robotics 1.5（2025）	多本体 VLA/ER	Motion Transfer、多级语言推理	B
V-JEPA 2（2025）	世界模型	100 万小时视频 + 62 小时机器人视频	B

系统 / 时间	类型	关键主张	证据
Cosmos 3（2026）	世界—动作模型	语言/图像/视频/音频/动作统一	B
LWD（2026）	车队级 RL	部署—收集—后训练闭环	B
MachEmbodied-U0（2026）	统一具身模型	理解/生成专家 + MoT	B
VioLA（2026）	人形策略	从人类数据学习全身控制	B
GEN-1.5（2026）	上下文学习	3—12 秒单演示 one-shot 59%，few-shot 83%	B
Skild S1（2026）	上下文学习	10 分钟新任务，OOD 66% vs 语言 VLA 9%	B
LingBot-VLA 2.0（2026）	跨本体 VLA	6 万小时、20 构型、130 ms 推理	B
ACoT-VLA（2026）	动作思维链	LIBERO 98.5%、LIBERO-Plus 84.1%	B/A
ABot-PhysWorld（2026）	世界模型	14B DiT、300 万 clips、EZSbench	B
ABot-M0.5（2026）	移动操作 WAM	时间/动作/训练—测试三级对齐	B
ABot-Claw（2026）	具身 Agent	统一本体接口、跨本体记忆、critic 闭环	B
CoorDex（2026）	人形灵巧移动操作	49 DoF，WalkGrab 55%/OpenFridge 66%/WalkPickTurn 89%	B
TwinDEX（2026）	无本体数据/灵巧操作	三指 9 DoF、5.3× 采集效率	C
Figure 02 @ BMW（2025）	产线部署	11 个月、90k+ 件、1,250+ 小时	C

B2. 关键基准

基准	类型 / 规模	优势	局限
LIBERO	终身/多任务操作；多任务、知识迁移	评估持续学习/迁移	仿真、本体有限
CALVIN	长程语言条件操作；连续指令、长程	评估语言条件/长程	仿真、任务有限
RLBench	多任务操作；大量任务、仿真	任务多样	真实感/接触有限
RoboCasa	厨房日常任务；大规模场景/资产	日常任务、生成式资产	仿真、接触/形变有限

基准	类型 / 规模	优势	局限
BEHAVIOR-1K	长程日常活动；1,000 活动、50 场景、9,000+ 物体	长程、物理丰富	难度高、评测成本高
ManiSkill3	GPU 并行操作；30,000+ FPS、接触密集	高吞吐、可扩展	仿真、真实 gap
SimplerEnv	real-to-sim 评估；真实策略的仿真复现	低成本评估	与真实仍有 gap
RoboArena	分布式真实评测；7 机构、600+ 个真实回合	真实、可扩展、双盲	成本高、任务选择偏差
AgiBot World	真实数据/基准；100 万 + 轨迹、217 任务	规模、场景多样	数据偏差、评测待完善
DROID	真实数据；76k 轨迹、564 场景、84 任务	场景多样、标准化	任务/本体有限
Open X-Embodiment	跨本体数据；22 机器人、527 技能	跨本体、规模	异构、质量参差
EgoDex	人类视频；829 小时、194 任务	大规模手部数据	无机器人动作/力

附录 C 术语表

术语	含义
具身智能（Embodied AI）	通过身体与环境闭环交互形成感知、行动、学习、推理的智能
VLA	Vision-Language-Action，视觉—语言—动作模型
WM	World Model，世界模型；预测动作后果/环境演化
WAM	World-Action Model，世界—动作模型；预测与控制联合训练
TAMP	Task and Motion Planning，任务与运动规划
MPC	Model Predictive Control，模型预测控制
WBC	Whole-Body Control，全身控制
IL	Imitation Learning，模仿学习
RL	Reinforcement Learning，强化学习
BC	Behavior Cloning，行为克隆
Sim2Real	仿真到真实的迁移
OXE	Open X-Embodiment，跨本体机器人数据集
UMI	Universal Manipulation Interface，便携式操作数据采集接口
Affordance	可供性；物体/环境提供的可操作方式
Cross-embodiment	跨本体；在不同机器人形态/动作空间之间迁移
Long-horizon	长程；需要多步骤、长时间执行的任务
OOD	Out-of-Distribution，分布外
CBF	Control Barrier Function，控制屏障函数

术语	含义
MTBF	Mean Time Between Failures，平均无故障时间
VLM	Vision-Language Model，视觉—语言模型
LLM	Large Language Model，大语言模型
BFM	Behavior Foundation Model，行为基础模型
Data recipe	数据配方；不同数据源的配比/课程
Generalization gap	泛化差距；训练分布与测试分布的性能差

附录 D 近一年中文科技媒体机器人智能体报道索引

说明：本索引按 “报道时间—媒体—核心主张—一手来源—证据等级” 组织。媒体链接为公开文章；一手来源优先给出论文/技术报告/官方项目页。证据等级沿用正文：A= 同行评议或独立复现，B= 预印本/官方技术报告，C= 公司博客/新闻/未经独立验证。媒体主张与论文结论不一致时，以论文/项目页为准。

- **2026-08** ·量子位：硅谷今日最热具身模型！不用后训练，看一遍就学会。核心主张：Skild S1 用一条视频演示做上下文学习，最长 10 分钟新任务，OOD 66% vs 语言 VLA 9%，单演示约等于 380 条后训练示范。一手来源：Skild AI 官方博客 [84]。证据：B/C。
- **2026** · **Generalist AI**：GEN-1.5: Embodied Foundation Models are One-Shot Learners。核心主张：3—12 秒单演示 one-shot，平均 59%；few-shot 83%；100 Hz 动作；30 秒视频记忆；组合泛化/仿真提示/人手模仿。一手来源：官方博客 [83]。证据：B/C。
- **2026-07** ·机器之心：支持 17 家机器人厂商 20 多种构型，具身基座模型 LingBot-VLA 2.0 正式开源。核心主张：6 万小时数据、20 种构型、统一动作空间、130 ms 推理、GM-100 超过 π0.5。一手来源：技术报告 arXiv:2607.06403[86]；报道 [102]。证据：B。
- **2026-01** ·智元**/CVPR 2026**：ACoT-VLA：在动作空间做思维链。核心主张：Action Chain-of-Thought，LIBERO 98.5%、LIBERO-Plus 84.1%、Genie Sim 3.0 82.9%。一手来源：arXiv:2601.11404[87]。证据：B/A。
- **2026-04** ·量子位：横扫全球 15 项 SOTA！高德首个面向 AGI 的全栈具身技术体系大公开。核心主张：ABot 全栈体系（ABot-World/ABot-N/ABot-M/ABot-Claw），15 项 SOTA。一手来源：ABot 系列论文 [89][90][91][92][93][109]。证据：B/C。
- **2026-04** ·机器之心：高德已拿下具身智能领域 15 项世界第一。核心主张：数据/世界模型/导航/执行/Agent 全栈打通。一手来源：同上。证据：B/C。
- **2026-09** ·量子位：今年最难的机器人 Demo，“机器人含量” 为 0。核心主张：自变量 TwinDEX 三指 9 DoF、数采—执行同构、数百条无本体数据完成后训练、5.3× 采集效率。一手来源：自变量项目页 [96]；报道 [99]。证据：C。
- **2026-04** ·量子位：全球首个世界统一模型发布，机器人家庭成员来了！。核心主张：WALL-B 世界统一模型、原生多模态、100 个家庭、自进化。一手来源：公司报道 [100]。证据：C。
- **2026-09** ·量子位：稚晖君把机器人卖到 2 万元一台，可人可狗可开发！。核心主张：消费级人形/轮足机器人 Q1/T1 以 19999 元起售，开放 SDK/HDK。一手来源：产品发布/公司材料 [107]。证据：C。
- **2026** ·新智元：具身智能数据基建升级！神经腕带 + 全景头环，补全物理操作信号。核心主张：EMG + ego 视觉 + 姿态同步的 “人类操控数据层”，补足意图/发力/微控制信号。一手来源：Nature 2025 sEMG 论文 [106] + 团队方案。证据：B/C。
- **2026** ·新智元：首篇具身智能机器人「安全」综述：LLM 如何跨越物理鸿沟？。核心主张：LLM 控制机器人的 “具身鸿沟”、越狱/后门/注入、逻辑—物理防御脱节。一手来源：arXiv:2601.02377[104]。

证据：B。

- **2026 · 机器之心**：智能体如何学会「想象」？深度解析世界模型嵌入具身系统的三大技术范式。核心主张：世界模型与策略的三种耦合：模块化、顺序、统一。一手来源：TechRxiv 综述 [105]。证据：B。
- **2026-06 · 量子位/BAAI**：人形机器人一用灵巧手就 "站桩"？人形控制全新框架，双运动先验实现移动灵巧操作。核心主张：CoorDex 用身体/手部潜先验协调 49 DoF，WalkGrab 55%、OpenFridge 66%、WalkPickTurn 89%。一手来源：arXiv:2606.23680[94]。证据：B。
- **2026-07 · 机器之心**：WAIC 直击：200 家机器人企业同场竞技，但物理 AI 的入场券属于闭环玩家。核心主张：行业从单点 demo 转向 "数据—模型—场景" 闭环。一手来源：产业观察，无单一论文。证据：C。
- **2026-07 · 机器之心**：浙江人形亮相 WAIC：具身智能驱动 NAVIAI 与 AMR 实现集群调度作业。核心主张：具身智能与 AMR 集群调度结合。一手来源：企业发布。证据：C。

读法：这张表里，B 级论文/技术报告是 "可以进入研究地图" 的证据；C 级公司叙事是 "产业信号"，不应直接写成科学结论。最典型的例子是 WALL-B 与 2 万元机器人：它们说明成本、家庭试点、消费级产品在推进，但不能证明 "通用具身智能已经实现"。

附录 E 参考文献

说明：以下文献按正文引用编号排列。arXiv 链接为公开预印本；期刊/会议信息以公开元数据为准。2026 年文献多为预印本，引用时请保留证据折扣。

[1] Duan, J., Yu, S., Tan, H. L., Zhu, H., & Tan, C. (2022). A Survey of Embodied AI: From Simulators to Research Tasks. *IEEE Transactions on Emerging Topics in Computational Intelligence*. https://arxiv.org/abs/2103.04918

[2] Liu, Y., Chen, W., Bai, Y., Liang, X., Li, G., Gao, W., & Lin, L. (2025). Aligning Cyber Space with Physical World: A Comprehensive Survey on Embodied AI. *IEEE/ASME Transactions on Mechatronics*. https://arxiv.org/abs/2407.06886

[3] Roy, N., Posner, I., Barfoot, T., Beaudoin, P., Bengio, Y., Bohg, J., et al. (2021). From Machine Learning to Robotics: Challenges and Opportunities for Embodied Intelligence. arXiv:2110.15245. https://arxiv.org/abs/2110.15245

[4] Hu, Y., Xie, Q., Jain, V., Francis, J., Patrikar, J., Keetha, N., et al. (2023). Toward General-Purpose Robots via Foundation Models: A Survey and Meta-Analysis. arXiv:2312.08782. https://arxiv.org/abs/2312.08782

[5] Ma, Y., Song, Z., Zhuang, Y., Hao, J., & King, I. (2025). A Survey on Vision-Language-Action Models for Embodied AI. arXiv:2405.14093. https://arxiv.org/abs/2405.14093

[6] Kawaharazuka, K., et al. (2025). Vision-Language-Action Models for Robotics: A Review Towards Real-World Applications. *IEEE Access*. https://arxiv.org/abs/2510.07077

[7] Li, X., Liu, Y., et al. (2025). A Comprehensive Survey on World Models for Embodied AI. arXiv:2510.16732. https://arxiv.org/abs/2510.16732

[8] Long, X., et al. (2025). A Survey: Learning Embodied Intelligence from Physical Simulators and World Models. arXiv:2507.00917. https://arxiv.org/abs/2507.00917

[9] Hou, B., et al. (2026). World Model for Robot Learning: A Comprehensive Survey. arXiv:2605.00080. https://arxiv.org/abs/2605.00080

[10] An, S., et al. (2025). Dexterous Manipulation through Imitation Learning: A Survey. *IEEE Transactions on Automation Science and Engineering*. https://arxiv.org/abs/2504.03515

[11] Li, G., et al. (2025). The Developments and Challenges towards Dexterous and Embodied Robotic Manipulation: A Survey. arXiv:2507.11840. https://arxiv.org/abs/2507.11840

[12] Yuan, M., et al. (2025). A Survey of Behavior Foundation Model: Next-Generation Whole-Body Control System of Humanoid Robots. *IEEE TPAMI*. https://arxiv.org/abs/2506.20487

[13] Cao, L. (2025). Humanoid Robots and Humanoid AI: Review, Perspectives and Directions. *ACM Computing Surveys*. https://arxiv.org/abs/2405.15775

[14] Zeng, F., et al. (2023). Large Language Models for Robotics: A Survey. arXiv:2311.07226. https://arxiv.org/abs/2311.07226

[15] Zhao, Z., et al. (2024). A Survey of Optimization-based Task and Motion Planning: From Classical To Learning Approaches. *IEEE/ASME Transactions on Mechatronics*. https://arxiv.org/abs/2404.02817

[16] Kroemer, O., Niekum, S., & Konidaris, G. (2019). A Review of Robot Learning for Manipulation: Challenges, Representations, and Algorithms. *Journal of Machine Learning Research*. https://arxiv.org/abs/1907.03146

[17] Zhao, W., Queralta, J. P., & Westerlund, T. (2020). Sim-to-Real Transfer in Deep Reinforcement Learning for Robotics: a Survey. arXiv:2009.13303. https://arxiv.org/abs/2009.13303

[18] Da, L., et al. (2025). A Survey of Sim-to-Real Methods in RL: Progress, Prospects and Challenges with Foundation Models. arXiv:2502.13187. https://arxiv.org/abs/2502.13187

[19] Zhong, Y., et al. (2025). A Survey on Vision-Language-Action Models: An Action Tokenization Perspective. arXiv:2507.01925. https://arxiv.org/abs/2507.01925

[20] Wang, Z., et al. (2026). Vision-Language-Action in Robotics: A Survey of Datasets, Benchmarks, and Data Engines. arXiv:2604.23001. https://arxiv.org/abs/2604.23001

[21] Ye, Y., et al. (2026). Data Pyramid for Embodied Manipulation: A Survey. arXiv:2607.24744. https://arxiv.org/abs/2607.24744

[22] Psiris, A., et al. (2026). Foundation Models in Robotics: A Comprehensive Review of Methods, Models, Datasets, Challenges and Future Research Directions. arXiv:2604.15395. https://arxiv.org/abs/2604.15395

[23] Li, X., et al. (2026). Safety in Embodied AI: A Survey of Risks, Attacks, and Defenses. arXiv:2605.02900. https://arxiv.org/abs/2605.02900

[24] Jena, G., et al. (2026). Do World Models Make Better Robots? A Survey of Evaluation Benchmarks for Predictive Embodied Intelligence. arXiv:2609.29669. https://arxiv.org/abs/2609.29669

[25] Ma, J., et al. (2026). Robot Learning from Human Videos: A Survey. arXiv:2604.27621. https://arxiv.org/abs/2604.27621

[26] Feng, Z., et al. (2026). From Human Videos to Robot Manipulation: A Survey on Scalable Vision-Language-Action Learning with Human-Centric Data. arXiv:2606.00054. https://arxiv.org/abs/2606.00054

[27] Wang, L., et al. (2026). A Comprehensive Survey and Systematic Real-World Evaluation of Embodied Vision-and-Language Navigation. arXiv:2607.09792. https://arxiv.org/abs/2607.09792

[28] Cao, Z., et al. (2026). Tactile-based Multimodal Fusion in Embodied Intelligence: A Survey of Vision, Language, and Contact-Driven Paradigms. arXiv:2605.17336. https://arxiv.org/abs/2605.17336

[29] Capuano, F., et al. (2025). Robot Learning: A Tutorial. arXiv:2510.12403. https://arxiv.org/abs/2510.12403

[30] Brohan, A., et al. (2022). RT-1: Robotics Transformer for Real-World Control at Scale. arXiv:2212.06817. https://arxiv.org/abs/2212.06817

[31] Brohan, A., et al. (2023). RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control. arXiv:2307.15818. https://arxiv.org/abs/2307.15818

[32] Open X-Embodiment Collaboration (2023). Open X-Embodiment: Robotic Learning Datasets and RT-X Models. arXiv:2310.08864. https://arxiv.org/abs/2310.08864

[33] Octo Model Team (2024). Octo: An Open-Source Generalist Robot Policy. arXiv:2405.12213. https://arxiv.org/abs/2405.12213

[34] Kim, M. J., et al. (2024). OpenVLA: An Open-Source Vision-Language-Action Model. arXiv:2406.09246. https://arxiv.org/abs/2406.09246

[35] Black, K., et al. (2024). π0: A Vision-Language-Action Flow Model for General Robot Control. arXiv:2410.24164. https://arxiv.org/abs/2410.24164

[36] Physical Intelligence (2025). π0.5: a Vision-Language-Action Model with Open-World Generalization. arXiv:2504.16054. https://arxiv.org/abs/2504.16054

[37] Physical Intelligence (2025). π*0.6: a VLA That Learns From Experience. arXiv:2511.14759. https://arxiv.org/abs/2511.14759

[38] NVIDIA (2025). GR00T N1: An Open Foundation Model for Generalist Humanoid Robots. arXiv:2503.14734. https://arxiv.org/abs/2503.14734

[39] Gemini Robotics Team (2025). Gemini Robotics 1.5: Pushing the Frontier of Generalist Robots with Advanced Embodied Reasoning, Thinking, and Motion Transfer. arXiv:2510.03342. https://arxiv.org/abs/2510.03342

[40] Liu, S., et al. (2024). RDT-1B: a Diffusion Foundation Model for Bimanual Manipulation. arXiv:2410.07864. https://arxiv.org/abs/2410.07864

[41] AgiBot-World-Contributors (2025). AgiBot World Colosseo: A Large-scale Manipulation Platform for Scalable and Intelligent Embodied Systems. arXiv:2503.06669. https://arxiv.org/abs/2503.06669

[42] Atreya, P., et al. (2025). RoboArena: Distributed Real-World Evaluation of Generalist Robot Policies. arXiv:2506.18123. https://arxiv.org/abs/2506.18123

[43] Hoque, R., et al. (2025). EgoDex: Learning Dexterous Manipulation from Large-Scale Egocentric Video. arXiv:2505.11709. https://arxiv.org/abs/2505.11709

[44] Assran, M., et al. (2025). V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning. arXiv:2506.09985. https://arxiv.org/abs/2506.09985

[45] NVIDIA (2025). Cosmos World Foundation Model Platform for Physical AI. arXiv:2501.03575. https://arxiv.org/abs/2501.03575

[46] NVIDIA (2025). World Simulation with Video Foundation Models for Physical AI. arXiv:2511.00062. https://arxiv.org/abs/2511.00062

[47] NVIDIA (2026). Cosmos 3: Omnimodal World Models for Physical AI. arXiv:2606.02800. https://arxiv.org/abs/2606.02800

[48] Google DeepMind (2025). Genie 3: A New Frontier for World Models. https://deepmind.google/discover/blog/genie-3-a-new-frontier-for-world-models/

[49] Figure AI (2025). F.02 Contributed to the Production of 30,000 Cars at BMW. https://www.figure.ai/news/production-at-bmw

[50] Li, C., et al. (2024). BEHAVIOR-1K: A Human-Centered, Embodied AI Benchmark with 1,000 Everyday Activities and Realistic Simulation. arXiv:2403.09227. https://arxiv.org/abs/2403.09227

[51] Liu, B., et al. (2023). LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning. arXiv:2306.03310. https://arxiv.org/abs/2306.03310

[52] Nasiriany, S., et al. (2024). RoboCasa: Large-Scale Simulation of Everyday Tasks for Generalist Robots. arXiv:2406.02523. https://arxiv.org/abs/2406.02523

[53] Tao, S., et al. (2024). ManiSkill3: GPU Parallelized Robotics Simulation and Rendering for Generalizable Embodied AI. arXiv:2410.00425. https://arxiv.org/abs/2410.00425

[54] Khazatsky, A., et al. (2024). DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset. arXiv:2403.12945. https://arxiv.org/abs/2403.12945

[55] Walke, H., et al. (2023). BridgeData V2: A Dataset for Robot Learning at Scale. arXiv:2308.12952. https://arxiv.org/abs/2308.12952

[56] Chi, C., et al. (2023). Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. arXiv:2303.04137. https://arxiv.org/abs/2303.04137

[57] Zhao, T. Z., et al. (2023). Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware. arXiv:2304.13705. https://arxiv.org/abs/2304.13705

[58] Ahn, M., et al. (2022). Do As I Can, Not As I Say: Grounding Language in Robotic Affordances. arXiv:2204.01691. https://arxiv.org/abs/2204.01691

[59] Liang, J., et al. (2022). Code as Policies: Language Model Programs for Embodied Control. arXiv:2209.07753. https://arxiv.org/abs/2209.07753

[60] Huang, W., et al. (2022). Inner Monologue: Embodied Reasoning through Planning with Language Models. arXiv:2207.05608. https://arxiv.org/abs/2207.05608

[61] Huang, W., et al. (2023). VoxPoser: Composable 3D Value Maps for Robotic Manipulation with Language Models. arXiv:2307.05973. https://arxiv.org/abs/2307.05973

[62] Hafner, D., et al. (2023). Mastering Diverse Domains through World Models. arXiv:2301.04104. https://arxiv.org/abs/2301.04104

[63] Hansen, N., et al. (2023). TD-MPC2: Scalable, Robust World Models for Continuous Control. arXiv:2310.16828. https://arxiv.org/abs/2310.16828

[64] Wang, Y., et al. (2026). Learning While Deploying: Fleet-Scale Reinforcement Learning for Generalist Robot Policies. arXiv:2605.00416. https://arxiv.org/abs/2605.00416

[65] Fang, H., et al. (2026). MolmoAct2: Action Reasoning Models for Real-world Deployment. arXiv:2605.02881. https://arxiv.org/abs/2605.02881

[66] Yuan, Y., et al. (2026). Embodied-R1.5: Evolving Physical Intelligence via Embodied Foundation Models. arXiv:2606.11324. https://arxiv.org/abs/2606.11324

[67] Albaba, M., et al. (2026). VioLA: Learning Generalist Humanoid Control Policies from Human Data. arXiv:2610.12435. https://arxiv.org/abs/2610.12435

[68] Chen, Y., et al. (2026). CLIFT: Turning Gemini Robotics On-Device into Humanoid Specialists via Non-Invasive Closed-Loop Iterative Fine-Tuning. arXiv:2607.29172. https://arxiv.org/abs/2607.29172

[69] Wen, H., et al. (2026). MachEmbodied-U0: Unified Understanding and Generation Model for Embodied Intelligence. arXiv:2609.25627. https://arxiv.org/abs/2609.25627

[70] Bu, Q., et al. (2025). UniVLA: Learning to Act Anywhere with Task-centric Latent Actions. arXiv:2505.06111. https://arxiv.org/abs/2505.06111

[71] Fu, Z., et al. (2024). Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation. arXiv:2401.02117. https://arxiv.org/abs/2401.02117

[72] Levine, S., et al. (2016). Learning Hand-Eye Coordination for Robotic Grasping with Deep Learning and Large-Scale Data Collection. *International Journal of Robotics Research*. https://doi.org/10.1177/0278364917710318

[73] Kober, J., Bagnell, J. A., & Peters, J. (2013). Reinforcement Learning in Robotics: A Survey. *International Journal of Robotics Research*. https://doi.org/10.1177/0278364913495721

[74] Brooks, R. A. (1986). A Robust Layered Control System for a Mobile Robot. *IEEE Journal on Robotics and Automation*. https://doi.org/10.1109/JRA.1986.1087032

[75] Nilsson, N. J. (1984). Shakey the Robot. SRI International Technical Note 323. https://www.sri.com/publication/shakey-the-robot/

[76] Thrun, S., Burgard, W., & Fox, D. (2005). *Probabilistic Robotics*. MIT Press. https://mitpress.mit.edu/9780262201629/probabilistic-robotics/

[77] Hwangbo, J., et al. (2019). Learning Agile and Dynamic Motor Skills for Legged Robots. *Science Robotics*. https://doi.org/10.1126/scirobotics.aau5872

[78] Andrychowicz, O. M., et al. (2020). Learning Dexterous In-Hand Manipulation. *International Journal of Robotics Research*. https://doi.org/10.1177/0278364919887447

[79] Ha, D., & Schmidhuber, J. (2018). World Models. arXiv:1803.10122. https://arxiv.org/abs/1803.10122

[80] ISO 10218-1:2025 / ISO 13482. Robots and robotic devices — Safety requirements. https://www.iso.org/standard/76922.html

[81] Interesting Engineering (2026-07-31). The Humanoid Robot Reality Check. https://interestingengineering.com/research/the-humanoid-robot-reality-check

[82] Wang, G., et al. (2023). Voyager: An Open-Ended Embodied Agent with Large Language Models. arXiv:2305.16291. https://arxiv.org/abs/2305.16291

[83] Generalist AI (2026). GEN-1.5: Embodied Foundation Models are One-Shot Learners. https://generalistai.com/blog/gen-1.5

[84] Skild AI (2026). Introducing S1: In-Context Learning for Robotics. https://www.skild.ai/blogs/s1

[85] Jiang, Y., et al. (2026). RoboTTT: Context Scaling for Robot Policies. arXiv:2607.15275. https://arxiv.org/abs/2607.15275

[86] Wu, W., et al. (2026). From Foundation to Application: Improving VLA Models in Practice. arXiv:2607.06403. https://arxiv.org/abs/2607.06403

[87] Zhong, L., et al. (2026). ACoT-VLA: Action Chain-of-Thought for Vision-Language-Action Models. arXiv:2601.11404. https://arxiv.org/abs/2601.11404

[88] Sun, J., et al. (2026). VLA-JEPA: Enhancing Vision-Language-Action Model with Latent World Model. arXiv:2602.10098. https://arxiv.org/abs/2602.10098

[89] Chen, Y., et al. (2026). ABot-PhysWorld: Interactive World Foundation Model for Robotic Manipulation with Physics Alignment. arXiv:2603.23376. https://arxiv.org/abs/2603.23376

[90] Chen, R., et al. (2026). ABot-M0.5: Unified Mobility-and-Manipulation World Action Model. arXiv:2607.00678. https://arxiv.org/abs/2607.00678

[91] Huo, D., et al. (2026). ABot-Claw: A Foundation for Persistent, Cooperative, and Self-Evolving Robotic Agents. arXiv:2604.10096. https://arxiv.org/abs/2604.10096

[92] Ding, Q., et al. (2026). ABot-ER: Unified Embodied Reasoning through Agentic Data-Model Co-Evolution. arXiv:2610.18355. https://arxiv.org/abs/2610.18355

[93] Jiang, F., et al. (2026). ABot-World-0: Infinite Interactive World Rollout on a Single Desktop GPU. arXiv:2607.19191. https://arxiv.org/abs/2607.19191

[94] Li, S., et al. (2026). CoorDex: Coordinating Body and Hand Priors for Continuous Dexterous Humanoid Loco-Manipulation. arXiv:2606.23680. https://arxiv.org/abs/2606.23680

[95] Li, S., et al. (2026). AnyBody: Free-Form Whole-Body Humanoid Control from Arbitrary Keypoint Guidance. arXiv:2606.29209. https://arxiv.org/abs/2606.29209

[96] X Square Robot (2026). TwinDEX: Dexterous Manipulation with Bodyless Data. https://x2robot.com/pages/twindex

[97] 量子位 (2026-07). 60000 小时炼出新开源 VLA！20 多种机器人都能用. https://www.pconline.com.cn/focus/2178/21783889.html

[98] 量子位 (2026-04). 横扫全球 15 项 SOTA！高德首个面向 AGI 的全栈具身技术体系大公开. https://www.qbitai.com/2026/04/403226.html

[99] 量子位 (2026-09). 今年最难的机器人 Demo，“机器人含量”为 0. https://www.qbitai.com/2026/09/483351.html

[100] 量子位 (2026-04). 全球首个世界统一模型发布，机器人家庭成员来了！https://www.qbitai.com/2026/04/404446.html

[101] 机器之心 (2026-04). 高德已拿下具身智能领域 15 项世界第一. https://www.jiqizhixin.com/articles/2026-04-17-6

[102] 机器之心 (2026-07). 支持 17 家机器人厂商 20 多种构型，具身基座模型 LingBot-VLA 2.0 正式开源. https://www.jiqizhixin.com/articles/2026-07-08-5

[103] 新智元 (2026). 具身智能数据基建升级！神经腕带 + 全景头环，补全物理操作信号. https://hub-assets-cache.baai.ac.cn/view/55487

[104] Huang, X., et al. (2026). Trust in LLM-controlled Robotics: a Survey of Security Threats, Defenses and Challenges. arXiv:2601.02377. https://arxiv.org/abs/2601.02377

[105] Zhongguancun Academy et al. (2026). Integrating World Models into Vision Language Action and Navigation: A Comprehensive Survey. TechRxiv. https://doi.org/10.36227/techrxiv.176531987.77979037/v1

[106] Nature (2025). A generic non-invasive neuromotor interface for human-computer interaction. https://www.nature.com/articles/s41586-025-09255-w

[107] 量子位 (2026-09). 稚晖君把机器人卖到 2 万元一台，可人可狗可开发！https://www.qbitai.com/2026/09/496304.html

[108] 机器之心 (2026). 智能体如何学会「想象」？深度解析世界模型嵌入具身系统的三大技术范式. https://cloud.tencent.com.cn/developer/article/2610951

[109] Gong, R., et al. (2026). ABot-N1: Toward a General Visual Language Navigation Foundation Model. arXiv:2607.10383. https://arxiv.org/abs/2607.10383

[110] 量子位 (2026-10). LeCun 押注的世界模型，中国一家清华系公司已经做进了机器人. https://www.qbitai.com/2026/10/504653.html

[111] Zhang, T., et al. (2025). When Do Neural Networks Learn World Models? arXiv:2502.09297. https://arxiv.org/abs/2502.09297

[112] Klindt, D., et al. (2026). When Does LeJEPA Learn a World Model? arXiv:2605.26379. https://arxiv.org/abs/2605.26379

报告版本：v1.1，2026-10-23。
配套文件：具身智能机器人研究地图 _2026.pdf、具身智能机器人研究地图 _2026.docx、figures/、research/（检索与全文提取记录）。
引用提醒：2025—2026 年的部分文献为预印本；产业部署数据多为公司声明，需独立验证。